

CreditLens

Análise Quantitativa de Carteiras de Crédito:
Documentação Metodológica e Estudo de Caso

Baseado em D. J. Bolder, *Credit-Risk Modelling* (Springer, 2018)

Julho de 2026 — versão 0.1

Abstract

O **CreditLens** é um aplicativo de análise de risco de carteiras de crédito construído sobre as bibliotecas numéricas que acompanham o livro *Credit-Risk Modelling: Theoretical Foundations, Diagnostic Tools, Practical Examples, and Numerical Recipes in Python*, de David Jamieson Bolder (Springer, 2018). A partir do upload de uma carteira em padrão CSV definido, o aplicativo estima a distribuição de perdas sob uma suíte de modelos — independentes, de mistura, de limiar e regulatório (IRB de Basileia) —, todos calibrados a um alvo comum de correlação de default, e reporta perda esperada, volatilidade da perda, VaR e *Expected Shortfall* em múltiplos níveis de confiança, capital regulatório com ajuste de granularidade e a decomposição do risco por contraparte. Este documento apresenta a arquitetura do aplicativo, o arcabouço teórico e matemático de cada modelo tal como implementado, e um estudo de caso completo sobre uma carteira hipotética de 250 contrapartes.

Contents

1	O aplicativo	2
1.1	Padrão de carteira	2
2	Arcabouço matemático	2
2.1	A perda da carteira	2
2.2	Medidas de risco	2
2.3	Índices de concentração	3
3	A suíte de modelos	3
3.1	Modelos independentes (Bolder, cap. 2)	3
3.2	Modelos de mistura (cap. 3)	3
3.3	Modelos de limiar (cap. 4)	4
3.4	Capital regulatório IRB e ajuste de granularidade (cap. 6)	4
3.5	Contribuições de risco (cap. 7)	5
3.6	Estratégia de calibração comum	5
4	Estudo de caso: carteira hipotética	5
4.1	A carteira	5
4.2	Parâmetros e calibração	5
4.3	Medidas de risco por modelo	6
4.4	Capital regulatório IRB	7
4.5	Contribuições de risco	7
5	Limitações e extensões	8

1 O aplicativo

O CreditLens opera em quatro etapas. Na *ingestão*, o usuário carrega um arquivo CSV no padrão da ferramenta; o validador verifica unicidade de identificadores, domínios das variáveis, aplica piso regulatório de 3 pontos-base às PDs nulas e trunca prazos ao intervalo $[1, 5]$ anos exigido pelo ajuste de maturidade do IRB. Na *calibração*, os parâmetros de dependência de cada família de modelos são ajustados a um mesmo alvo de correlação de default, o que torna as caudas diretamente comparáveis entre modelos. Na *estimação*, a suíte completa é executada — combinando fórmulas analíticas e simulação de Monte Carlo com M trajetórias — e, na *apresentação*, os resultados são exibidos em tabelas e gráficos interativos, com exportação integral para Excel.

1.1 Padrão de carteira

Cada linha do CSV representa uma contraparte. São obrigatórias as colunas **id_contraparte** (identificador único), **exposicao** (EAD, exposição no default, estritamente positiva) e **pd** (probabilidade de default no horizonte de um ano, em $(0, 1)$). São opcionais **lgd** (perda dado o default em $(0, 1]$; padrão 1,0), **prazo_anos** (prazo efetivo para o ajuste de maturidade do IRB; padrão 2,5) e as descritivas **rating**, **setor** e **nome**. Seguindo a convenção de Bolder, toda a modelagem usa a *severidade*

$$c_n = \text{EAD}_n \times \text{LGD}_n, \quad (1)$$

isto é, a exposição líquida sujeita a perda de cada contraparte, tratada como determinística.

2 Arcabouço matemático

2.1 A perda da carteira

Seja uma carteira com N contrapartes, PDs $p_1, \dots, p_N$ e severidades $c_1, \dots, c_N$. Definindo o indicador de default $\mathbb{I}_{D_n} \in \{0, 1\}$ no horizonte de um ano, a perda da carteira é a variável aleatória

$$L = \sum_{n=1}^N c_n \mathbb{I}_{D_n}. \quad (2)$$

Toda a diferença entre os modelos da suíte está na estrutura de dependência imposta aos indicadores $\mathbb{I}_{D_n}$: é ela que governa a espessura da cauda de L e, portanto, o capital econômico.

2.2 Medidas de risco

Para cada modelo, o CreditLens reporta a perda esperada $\mathbb{E}[L] = \sum_n p_n c_n$, a volatilidade da perda $\text{UL} = \sqrt{\text{Var}(L)}$, o valor em risco

$$\text{VaR}_\alpha(L) = \inf\{\ell : \mathbb{P}(L \leq \ell) \geq \alpha\}, \quad (3)$$

e o *expected shortfall*

$$\text{ES}_\alpha(L) = \mathbb{E}[L \mid L \geq \text{VaR}_\alpha(L)], \quad (4)$$

nos níveis $\alpha \in \{95\%, 99\%, 99,9\%, 99,97\%\}$. Nas implementações por Monte Carlo, as medidas são estatísticas de ordem da distribuição simulada de L ; o capital econômico usual é $\text{VaR}_\alpha - \mathbb{E}[L]$ (parcela inesperada).

2.3 Índices de concentração

O resumo da carteira inclui o índice de Herfindahl–Hirschman das participações $w_n = c_n / \sum_k c_k$,

$$\text{HHI} = \sum_{n=1}^N w_n^2, \quad N_{\text{efetivo}} = \text{HHI}^{-1}, \quad (5)$$

que mede o número efetivo de nomes da carteira e antecipa a magnitude do ajuste de granularidade da Seção 3.4.

3 A suíte de modelos

3.1 Modelos independentes (Bolder, cap. 2)

O ponto de partida — e contrafactual deliberadamente ingênuo — assume defaults independentes. Na versão analítica homogênea, com $p = \bar{p}$ (PD média ponderada por exposição) e severidade média $\bar{c}$, o número de defaults K é binomial,

$$\mathbb{P}(K = k) = \binom{N}{k} \bar{p}^k (1 - \bar{p})^{N-k}, \quad L \approx \bar{c} K, \quad (6)$$

com quantis obtidos por interpolação da distribuição acumulada. Na versão de Monte Carlo heterogênea, simula-se $U_{m,n} \sim \mathcal{U}(0,1)$ e declara-se default quando $U_{m,n} < p_n$, preservando a heterogeneidade de PDs e exposições. Pela lei dos grandes números, a independência elimina quase toda a variabilidade sistemática: a cauda resultante é fina demais para qualquer uso prudencial, e sua função na suíte é servir de piso de referência.

3.2 Modelos de mistura (cap. 3)

Os modelos de mistura induzem dependência fazendo as PDs partilharem um fator aleatório comum. Condicionalmente ao fator, os defaults são independentes; incondicionalmente, são correlacionados.

Beta-binomial. A probabilidade comum de default é sorteada de $Z \sim \text{Beta}(a, b)$ e, dado Z , cada contraparte entra em default independentemente com probabilidade Z . A calibração resolve o sistema linear implícito em

$$\mathbb{E}[Z] = \frac{a}{a+b} = \bar{p}, \quad \rho_D = \frac{1}{a+b+1} = \rho_D^{\text{alvo}}, \quad (7)$$

onde ρ_D é a correlação de default entre pares de contrapartes. É o modelo de mistura mais parcimonioso e tende a produzir caudas pesadas quando ρ_D^{alvo} é alto em relação a $\bar{p}$.

CreditRisk⁺ (Poisson-gama, um fator). O fator sistemático é $S \sim \Gamma(v, 1/v)$, com $\mathbb{E}[S] = 1$ e $\text{Var}(S) = 1/v$. A intensidade condicional de cada contraparte é

$$p_n(S) = p_n (1 - w + wS), \quad (8)$$

onde $w \in (0,1)$ é a carga do fator; os defaults são gerados por $H_n \sim \text{Poisson}(p_n(S))$ com $\mathbb{I}_{D_n} = \mathbb{I}\{H_n \geq 1\}$. O modelo é o arcabouço atuarial clássico de portfólio de crédito e reaparece na Seção 3.4 como base analítica do ajuste de granularidade.

3.3 Modelos de limiar (cap. 4)

Na família gaussiana de um fator — a espinha dorsal da prática de mercado e do próprio IRB —, o estado latente (“retorno do ativo”) da contraparte n é

$$Y_n = \sqrt{\rho} G + \sqrt{1-\rho} \varepsilon_n, \quad G, \varepsilon_1, \dots, \varepsilon_N \stackrel{iid}{\sim} \mathcal{N}(0, 1), \quad (9)$$

com default quando $Y_n < \Phi^{-1}(p_n)$. O parâmetro ρ é a correlação de *ativos*; a correlação de *default* implícita entre duas contrapartes com PDs p e q é

$$\rho_D(p, q; \rho) = \frac{\Phi_2(\Phi^{-1}(p), \Phi^{-1}(q); \rho) - pq}{\sqrt{p(1-p)}\sqrt{q(1-q)}}, \quad (10)$$

onde Φ_2 é a normal bivariada. O CreditLens calibra ρ numericamente para que $\rho_D(\bar{p}, \bar{p}; \rho)$ iguale o alvo comum da suíte.

Variante t-Student. Substituindo o vetor gaussiano por

$$Y_n = \sqrt{\frac{\nu}{V}} \left(\sqrt{\rho} G + \sqrt{1-\rho} \varepsilon_n \right), \quad V \sim \chi_\nu^2, \quad (11)$$

com limiar $t_\nu^{-1}(p_n)$, o choque radial comum V introduz *dependência de cauda*: mesmo com a mesma correlação ρ , defaults conjuntos extremos tornam-se ordens de magnitude mais prováveis. Poucos graus de liberdade (ν baixo) engordam a cauda; $\nu \rightarrow \infty$ recupera o caso gaussiano.

ASRF (carteira assintótica). No limite de carteira infinitamente granular e homogênea, o modelo gaussiano admite solução fechada (Vasicek):

$$\text{VaR}_\alpha = \left(\sum_n c_n \right) \Phi \left(\frac{\Phi^{-1}(\bar{p}) + \sqrt{\rho} \Phi^{-1}(\alpha)}{\sqrt{1-\rho}} \right). \quad (12)$$

É o esqueleto analítico do IRB e, na suíte, funciona como verificação de consistência do modelo de limiar simulado.

3.4 Capital regulatório IRB e ajuste de granularidade (cap. 6)

O requerimento de capital do IRB avaliado por contraparte é a perda inesperada condicional ao cenário sistemático de 99,90%, multiplicada pelo ajuste de maturidade:

$$K_n = \left[\Phi \left(\frac{\Phi^{-1}(p_n) + \sqrt{\rho_B(p_n)} \Phi^{-1}(0,999)}{\sqrt{1-\rho_B(p_n)}} \right) - p_n \right] \cdot \text{MA}(M_n, p_n), \quad \text{Capital} = \sum_n c_n K_n, \quad (13)$$

com a correlação regulatória interpolada exponencialmente entre 12% e 24%,

$$\rho_B(p) = 0,12 q(p) + 0,24 (1 - q(p)), \quad q(p) = \frac{1 - e^{-50p}}{1 - e^{-50}}, \quad (14)$$

e o ajuste de maturidade

$$\text{MA}(M, p) = \frac{1 + (M - 2,5) b(p)}{1 - 1,5 b(p)}, \quad b(p) = (0,11582 - 0,05478 \ln p)^2, \quad (15)$$

conforme implementado na biblioteca do livro.¹ O RWA equivalente é $12,5 \times$ o capital.

¹O texto de Basileia II usa o coeficiente 0,11852; a biblioteca de Bolder implementa 0,11582. O efeito numérico sobre o capital agregado é da ordem de décimos de ponto percentual. O CreditLens preserva a implementação original do livro.

Ajuste de granularidade. A fórmula (13) pressupõe carteira infinitamente granular; carteiras reais carregam risco idiossincrático residual de concentração. O CreditLens adiciona o ajuste de granularidade de Gordy–Lütkebohmert na forma analítica derivada do CreditRisk⁺ (a mesma do exemplo do cap. 6 do livro), estruturalmente

$$\text{GA} = \frac{1}{2K^*} \sum_{n=1}^N c_n^2 \left[\delta(C_n \mathcal{R} \mathcal{K}_n + \mathcal{R} \mathcal{K}_n^2 \gamma) - K_n(C_n + 2\mathcal{R} \mathcal{K}_n \gamma) \right], \quad (16)$$

com $K^* = \sum_n c_n K_n$ e parâmetros de volatilidade setorial e de LGD fixados nos valores de referência do livro ($a = 0,25$, $\xi = 0,25$, $\bar{g} = 1$). O GA cresce com o quadrado das participações — é, em essência, uma penalidade de HHI sobre o capital.

3.5 Contribuições de risco (cap. 7)

A alocação de Euler decompõe o risco total nas parcelas marginais de cada contraparte. Para o VaR e o ES, as contribuições admitem a representação por esperança condicional

$$\text{VaR}_\alpha^{(n)} = \mathbb{E}[c_n \mathbb{I}_{D_n} \mid L = \text{VaR}_\alpha], \quad \text{ES}_\alpha^{(n)} = \mathbb{E}[c_n \mathbb{I}_{D_n} \mid L \geq \text{VaR}_\alpha], \quad (17)$$

que somam exatamente o VaR e o ES da carteira. O CreditLens as estima por decomposição de Monte Carlo no modelo de limiar gaussiano: em cada uma de S repetições independentes com M trajetórias, calcula-se a perda média de cada nome nas trajetórias em que $L = \text{VaR}_\alpha$ (respectivamente $L \geq \text{VaR}_\alpha$), e a média das S repetições reduz o ruído do condicionamento em evento raro. As contribuições de ES são substancialmente mais estáveis que as de VaR — condicionam num conjunto, não num ponto — e são a referência recomendada para *pricing* e alocação de capital.

3.6 Estratégia de calibração comum

Para que as caudas sejam comparáveis, todos os modelos com dependência são ancorados no mesmo par $(\bar{p}, \rho_D^{\text{alvo}})$: a beta-binomial via momentos, o limiar gaussiano/t via (10), e o ASRF herdando o ρ calibrado. As diferenças remanescentes entre modelos refletem, portanto, *forma distributiva* — em particular a presença ou não de dependência de cauda — e não níveis distintos de correlação. O CreditRisk⁺ é parametrizado diretamente por (w, v) , expostos ao usuário. O IRB, por construção regulatória, usa $\rho_B(p) \in [12\%, 24\%]$ — tipicamente acima do ρ_D implícito em carteiras corporativas — e por isso não é ancorado no alvo comum.

4 Estudo de caso: carteira hipotética

4.1 A carteira

A base de teste contém $N = 250$ contrapartes corporativas em oito graus de rating (AAA a C), exposições log-normais (cauda pesada, como é típico do crédito corporativo), LGD por classe de garantia e prazos uniformes em $[1, 5]$ anos. A Tabela 1 resume o perfil.

Com HHI de 0,0112, a carteira “vale” apenas 89 nomes equivalentes — concentração relevante que o ajuste de granularidade da Seção 4.4 quantificará em capital.

4.2 Parâmetros e calibração

A análise usou $M = 100\,000$ simulações, semente 42, alvo de correlação de default $\rho_D^{\text{alvo}} = 5\%$, $\nu = 10$ graus de liberdade na variante t, e $(w, v) = (0,35; 1,2)$ no CreditRisk⁺. A calibração produziu, para a beta-binomial, $(a, b) = (0,410; 18,590)$ — note $a < 1$, densidade explosiva na origem com cauda direita longa — e, para o modelo de limiar, correlação de ativos $\rho = 24,66\%$.

Table 1: Perfil da carteira de teste.

Métrica	Valor
Contrapartes (N)	250
EAD total	10 000,0
Exposição líquida total ($\sum_n c_n$)	4 402,7
PD média simples	2,36%
PD média ponderada por exposição ($\bar{p}$)	2,16%
LGD média	46,0%
Perda esperada ($\mathbb{E}[L]$)	95,0 (2,16% da exposição líquida)
HHI	0,0112
Número efetivo de nomes	88,9
Maior exposição individual	3,39%
Dez maiores exposições	24,4%

Este último número merece registro: para gerar módicos 5% de correlação de *default* numa carteira com $\bar{p} = 2,16\%$, é preciso quase 25% de correlação de *ativos* — a não linearidade de (10) em ação, e a razão pela qual as duas noções de correlação jamais devem ser confundidas.

4.3 Medidas de risco por modelo

Table 2: Medidas de risco por modelo (unidades monetárias; $M = 100\,000$). Entre parênteses, o VaR 99,90% em percentual da exposição líquida.

Modelo	EL	UL	VaR _{99%}	ES _{99%}	VaR _{99,9%}	ES _{99,9%}
Binomial indep. (analítico, homog.)	95,0	40,5	192,0	192,4	233,9 (5,3%)	—
Binomial independente (MC)	94,9	60,5	279,3	320,3	371,2 (8,4%)	407,3
CreditRisk ⁺ (1 fator)	89,1	64,9	295,8	337,7	396,2 (9,0%)	427,5
Limiar Gaussiano 1F	95,2	120,6	563,6	727,9	927,1 (21,1%)	1 116,7
Beta-binomial	94,9	157,9	735,7	930,4	1 187,5 (27,0%)	1 332,1
ASRF (analítico)	95,0	—	701,0	944,9	1 265,6 (28,7%)	1 520,5
Limiar t-Student ($\nu = 10$)	95,2	147,5	707,6	1 000,0	1 372,8 (31,2%)	1 731,4
IRB Basileia ($K^* + \mathbb{E}[L]$)	95,0	—	—	—	805,2 (18,3%)	—

A Tabela 2 contém a mensagem central do exercício. Primeiro, a *verificação de consistência*: a perda esperada é ≈ 95 em todos os modelos (o desvio do CreditRisk⁺, 89,1, decorre da aproximação de Poisson, que admite eventos múltiplos e não é recalibrada em nível). Modelos calibrados ao mesmo primeiro momento diferindo por fator de quase $6\times$ no VaR 99,90% — de 234 a 1 373 — é a demonstração empírica de que *o risco de crédito de carteira vive inteiramente na estrutura de dependência*, não nas PDs individuais.

Segundo, a hierarquia das caudas segue exatamente a teoria: independente < CreditRisk⁺ (com os w, v adotados) < limiar gaussiano < beta-binomial $\approx$ ASRF < t-Student. A variante t, com a *mesma* correlação de ativos do modelo gaussiano, entrega VaR 99,9% 48% maior e ES 99,9% 55% maior — o preço da dependência de cauda que o cópula gaussiano, por construção, não captura.

Terceiro, o ASRF (1 265,6) supera o limiar gaussiano simulado (927,1) apesar de descrever uma carteira *mais* diversificada. A aparente contradição é instrutiva: o ASRF usa a aproximação homogênea $\bar{p}$ ponderada por exposição, e numa carteira heterogênea — em que os nomes de pior rating não são os de maior exposição — essa homogeneização é conservadora, efeito discutido pelo próprio Bolder no capítulo 4.




Figure 1: Distribuição de perdas (esq.) e cauda em escala logarítmica (dir.) sob três modelos. A linha pontilhada marca o quantil de 99,90%. A separação das caudas — indistinguíveis no corpo da distribuição — ilustra por que a escolha do modelo de dependência domina qualquer refinamento de PD individual.




Figure 2: VaR 99,90% por modelo, em percentual da exposição líquida.

4.4 Capital regulatório IRB

Aplicando (13) contraparte a contraparte, o capital IRB da carteira é

$$K^* = \sum_n c_n K_n = 710,1 \quad (16,13\% \text{ da exposição líquida}), \quad \text{RWA} = 12,5 K^* = 8\,876,7.$$

O ajuste de granularidade adiciona $GA = 91,8$, elevando o requerimento a 801,9 — um acréscimo de 12,9% sobre o capital IRB puro, coerente com os 89 nomes efetivos da carteira. Somado à perda esperada para comparação com os VaRs totais dos modelos internos, o IRB+EL de 805,2 (18,3%) situa-se entre o limiar gaussiano calibrado a $\rho_D = 5\%$ e os modelos de cauda pesada: a correlação regulatória $\rho_B \in [12\%, 24\%]$ é deliberadamente conservadora frente a calibrações internas típicas, mas o cópula gaussiano subjacente ao IRB não carrega dependência de cauda — o t-Student o ultrapassa com folga.


4.5 Contribuições de risco

A Tabela 3 e a Figura 3 revelam a anatomia da cauda. A contraparte CP0173 — rating CCC com a segunda maior exposição da carteira — responde sozinha por 11,8% do ES 99%: a combinação

Table 3: Dez maiores contribuições ao ES 99% (decomposição MC, limiar gaussiano, $S = 10$).

Contraparte	Rating	Exposição	PD	Contrib. ES	% do ES
CP0173	CCC	292,3	8,99%	85,7	11,8%
CP0156	BB	217,1	2,34%	40,7	5,6%
CP0051	C	47,5	24,41%	26,4	3,6%
CP0092	B	118,1	6,33%	21,4	3,0%
CP0078	BBB	266,8	0,63%	21,2	2,9%
CP0139	BBB	301,9	0,58%	19,1	2,6%
CP0103	C	44,3	37,05%	19,1	2,6%
CP0228	B	87,3	5,38%	16,1	2,2%
CP0036	B	109,2	3,67%	15,9	2,2%
CP0245	C	101,4	15,55%	15,5	2,1%

multiplicativa de PD alta com exposição alta que a alocação de capital deve penalizar no *pricing*. Mas repare em CP0078 e CP0139: ratings BBB, PDs abaixo de 65 pontos-base, e ainda assim entre os seis maiores contribuintes — puro efeito de tamanho (≈ 300 de exposição cada). A lição operacional é que gestão de limites por rating, isoladamente, não controla a cauda; é a contribuição de risco, não a PD, a métrica correta de concentração. Os dez nomes da tabela somam $\approx 39\%$ do ES total, contra 24% da exposição — a cauda é mais concentrada que a carteira.

**Figure 3:** Quinze maiores contribuições ao ES 99% (percentual do total).

5 Limitações e extensões

A versão atual adota LGD determinística (a extensão estocástica via beta, `crPlusOneFactorLGD`, já existe na biblioteca), um único fator sistemático (as rotinas multifatoriais `crPlusMultifactor` e `getY2r` permitem estender a fatores setoriais/regionais, e a coluna `setor` do padrão de dados já antecipa esse uso), horizonte de um ano sem migração de ratings (o módulo `markovChain` habilita a visão multiperíodo) e Monte Carlo ingênuo (o capítulo 8 do livro, também disponível na biblioteca, fornece *importance sampling* com deslocamento ótimo de média para estimar quantis extremos com fração das simulações). O ajuste de granularidade usa os parâmetros de

referência do livro; em aplicação prudencial, a volatilidade setorial deve ser estimada.

Referências

Bolder, D. J. (2018). *Credit-Risk Modelling: Theoretical Foundations, Diagnostic Tools, Practical Examples, and Numerical Recipes in Python*. Springer. [Referencial teórico e bibliotecas numéricas, github.com/djbolder/credit-risk-modelling, GPL-3.0.]

Basel Committee on Banking Supervision (2005). *An Explanatory Note on the Basel II IRB Risk Weight Functions*. BIS.

Gordy, M. B. (2003). A risk-factor model foundation for ratings-based bank capital rules. *Journal of Financial Intermediation*, 12(3), 199–232.

Gordy, M. B.; Lütkebohmert, E. (2013). Granularity adjustment for regulatory capital assessment. *International Journal of Central Banking*, 9(3), 33–71.

Vasicek, O. (2002). The distribution of loan portfolio value. *Risk*, 15(12), 160–162.