

CreditLens

Análise Quantitativa de Carteiras de Crédito:
Documentação Metodológica e Estudo de Caso

Walter C. Neto

Baseado em D. J. Bolder, *Credit-Risk Modelling* (Springer, 2018)

Julho de 2026 — versão 0.2

Resumo

O **CreditLens** é um aplicativo de análise de risco de carteiras de crédito construído sobre as bibliotecas numéricas que acompanham o livro *Credit-Risk Modelling: Theoretical Foundations, Diagnostic Tools, Practical Examples, and Numerical Recipes in Python*, de David Jamieson Bolder (Springer, 2018). A partir do upload de uma carteira em padrão CSV definido, o aplicativo estima a distribuição de perdas sob um portfólio de modelos — independentes, *mixture models*, *threshold models* e o modelo regulatório (IRB de Basileia) —, todos calibrados a um alvo comum de correlação de default. São reportados a perda esperada, a volatilidade da perda, o VaR e o *Expected Shortfall* em múltiplos níveis de confiança, o capital regulatório com ajuste de granularidade e a decomposição do risco por contraparte. Este documento apresenta a arquitetura do aplicativo, o arcabouço teórico e matemático de cada modelo tal como implementado, e um estudo de caso completo sobre uma carteira hipotética de 250 contrapartes.

Sumário

1	O aplicativo	2
1.1	Padrão de carteira	2
2	Arcabouço matemático	2
2.1	A perda da carteira	2
2.2	Medidas de risco	3
2.3	Índices de concentração	3
3	O portfólio de modelos	3
3.1	Modelos independentes (cap. 2)	3
3.2	<i>Mixture models</i> (cap. 3)	3
3.3	<i>Threshold models</i> (cap. 4)	4
3.4	Capital regulatório IRB e ajuste de granularidade (cap. 6)	5
3.5	Contribuições de risco (cap. 7)	6
3.6	Extensão multifatorial setorial	6
3.7	Estratégia de calibração comum	6
4	Estudo de caso: carteira hipotética	7
4.1	A carteira	7
4.2	Parâmetros e calibração	7
4.3	Medidas de risco por modelo	7
4.4	Capital regulatório IRB	8

4.5	Contribuições de risco	9
4.6	Análise multifatorial setorial	9
4.7	Contribuições por setor: exposição, provisão e cauda	11

5	Limitações e extensões	12
---	------------------------	----

1 O aplicativo

O CreditLens opera em quatro etapas. Na *ingestão*, o usuário carrega um arquivo CSV no padrão da ferramenta; o validador verifica a unicidade dos identificadores e os domínios das variáveis, aplica um piso regulatório de 3 pontos-base às PDs nulas e trunca os prazos ao intervalo $[1, 5]$ anos exigido pelo ajuste de maturidade do IRB. Na *calibração*, os parâmetros de dependência de cada família de modelos são ajustados a um mesmo alvo de correlação de default, o que torna as caudas diretamente comparáveis entre modelos. Na *estimação*, todos os modelos são executados — combinando fórmulas analíticas e simulação de Monte Carlo com M trajetórias — e, na *apresentação*, os resultados são exibidos em tabelas e gráficos interativos, com exportação integral para Excel.

1.1 Padrão de carteira

Cada linha do arquivo CSV representa uma contraparte. As colunas obrigatórias são **id_contraparte** (identificador único da contraparte), **exposicao** (o EAD, *exposure at default* — valor exposto no momento do default, estritamente positivo) e **pd** (probabilidade de default no horizonte de um ano, número em $(0, 1)$). As colunas opcionais são **lgd** (*loss given default* — fração da exposição efetivamente perdida em caso de default, em $(0, 1]$; valor-padrão 1,0), **prazo_anos** (prazo efetivo da operação, em anos, usado no ajuste de maturidade do IRB; valor-padrão 2,5) e as colunas descritivas **rating**, **setor** e **nome**, que não entram nos cálculos e servem à legibilidade dos relatórios. Seguindo a convenção de Bolder, toda a modelagem usa a *severidade*

$$c_n = \text{EAD}_n \times \text{LGD}_n, \quad (1)$$

em que EAD_n é a exposição da contraparte n e LGD_n a sua perda dado o default; c_n é, portanto, a exposição líquida sujeita a perda de cada contraparte, tratada como determinística ao longo de todo o documento.

2 Arcabouço matemático

2.1 A perda da carteira

Considere uma carteira com N contrapartes, em que p_n denota a probabilidade de default da contraparte n e c_n a sua severidade. Definindo o indicador de default $\mathbb{I}_{D_n}$, variável aleatória que vale 1 se a contraparte n entra em default no horizonte de um ano e 0 caso contrário, a perda da carteira é

$$L = \sum_{n=1}^N c_n \mathbb{I}_{D_n}. \quad (2)$$

O que distingue os modelos apresentados neste documento é, essencialmente, a estrutura de dependência imposta aos indicadores $\mathbb{I}_{D_n}$: é ela que governa a espessura da cauda de L e, portanto, o capital econômico da carteira.

2.2 Medidas de risco

Para cada modelo, o CreditLens reporta quatro medidas. A *perda esperada* é $\mathbb{E}[L] = \sum_n p_n c_n$. A *volatilidade da perda* (ou perda não esperada, UL) é $UL = \sqrt{\text{Var}(L)}$. O *valor em risco* no nível de confiança α ,

$$\text{VaR}_\alpha(L) = \inf\{\ell : \mathbb{P}(L \leq \ell) \geq \alpha\}, \quad (3)$$

é o menor valor de perda ℓ que não é excedido com probabilidade de pelo menos α . O *expected shortfall*,

$$\text{ES}_\alpha(L) = \mathbb{E}[L \mid L \geq \text{VaR}_\alpha(L)], \quad (4)$$

é a perda média nos cenários em que o VaR é atingido ou excedido — por construção, $\text{ES}_\alpha \geq \text{VaR}_\alpha$. As medidas são calculadas nos níveis $\alpha \in \{95\%, 99\%, 99,9\%, 99,97\%\}$. Nas implementações por Monte Carlo, elas são obtidas como estatísticas de ordem da distribuição simulada de L . O capital econômico usual é a parcela inesperada $\text{VaR}_\alpha - \mathbb{E}[L]$.

2.3 Índices de concentração

O resumo da carteira inclui o índice de Herfindahl–Hirschman,

$$\text{HHI} = \sum_{n=1}^N w_n^2, \quad N_{\text{efetivo}} = \text{HHI}^{-1}, \quad (5)$$

em que $w_n = c_n / \sum_k c_k$ é a participação da contraparte n na exposição líquida total. O inverso do HHI é o *número efetivo de nomes*: quantas contrapartes de igual tamanho produziriam a mesma concentração. Esse indicador antecipa a magnitude do ajuste de granularidade da Seção 3.4.

3 O portfólio de modelos

3.1 Modelos independentes (cap. 2)

O ponto de partida — e contrafactual deliberadamente ingênuo — assume defaults independentes entre contrapartes. Na versão analítica homogênea, toma-se $\bar{p}$ (a PD média da carteira ponderada por exposição) e a severidade média $\bar{c}$; o número de defaults K segue então uma distribuição binomial,

$$\mathbb{P}(K = k) = \binom{N}{k} \bar{p}^k (1 - \bar{p})^{N-k}, \quad L \approx \bar{c}K, \quad (6)$$

em que k é o número de defaults observado e os quantis de L são obtidos por interpolação da distribuição acumulada. Na versão de Monte Carlo heterogênea, sorteia-se para cada trajetória m e contraparte n um uniforme $U_{m,n} \sim \mathcal{U}(0, 1)$ e declara-se default quando $U_{m,n} < p_n$, preservando a heterogeneidade de PDs e exposições. Pela lei dos grandes números, a independência elimina quase toda a variabilidade sistemática: a cauda resultante é fina demais para qualquer uso prudencial, e o papel do modelo aqui é servir de piso de referência para os demais.

3.2 Mixture models (cap. 3)

Os *mixture models* induzem dependência fazendo as PDs compartilharem um fator aleatório comum. Condicionalmente ao fator, os defaults são independentes; incondicionalmente, tornam-se correlacionados.

Beta-binomial. A probabilidade comum de default é sorteada de $Z \sim \text{Beta}(a, b)$, em que a e b são os parâmetros de forma da distribuição beta; dado o sorteio de Z , cada contraparte entra em default de forma independente com probabilidade Z . A calibração resolve o sistema

$$\mathbb{E}[Z] = \frac{a}{a+b} = \bar{p}, \quad \rho_D = \frac{1}{a+b+1} = \rho_D^{\text{alvo}}, \quad (7)$$

em que ρ_D denota a correlação de default entre pares de contrapartes e ρ_D^{alvo} é o alvo escolhido pelo usuário. É o *mixture model* mais parcimonioso e tende a produzir caudas pesadas quando ρ_D^{alvo} é alto em relação a $\bar{p}$.

CreditRisk⁺ (Poisson-gama, um fator). O fator sistemático é $S \sim \Gamma(v, 1/v)$, distribuição gama parametrizada de modo que $\mathbb{E}[S] = 1$ e $\text{Var}(S) = 1/v$ — ou seja, v controla a volatilidade do ciclo: quanto menor v , mais volátil o fator. A intensidade condicional de default de cada contraparte é

$$p_n(S) = p_n (1 - w + wS), \quad (8)$$

em que $w \in (0, 1)$ é a carga do fator, isto é, a fração da intensidade que responde ao ciclo (o complemento $1 - w$ é a parcela idiossincrática). Os defaults são gerados por uma contagem de Poisson $H_n \sim \text{Poisson}(p_n(S))$, com default declarado quando $H_n \geq 1$. Trata-se do arcabouço atuarial clássico de portfólio de crédito, que reaparece na Seção 3.4 como base analítica do ajuste de granularidade.

3.3 Threshold models (cap. 4)

Nos *threshold models*, o default ocorre quando uma variável latente — interpretada como o retorno dos ativos da contraparte — cai abaixo de um limiar. Na família gaussiana de um fator, espinha dorsal da prática de mercado e do próprio IRB, o estado latente da contraparte n é

$$Y_n = \sqrt{\rho} G + \sqrt{1-\rho} \varepsilon_n, \quad G, \varepsilon_1, \dots, \varepsilon_N \stackrel{iid}{\sim} \mathcal{N}(0, 1), \quad (9)$$

em que G é o fator sistemático comum a toda a carteira, ε_n é o choque idiossincrático da contraparte n e $\rho \in (0, 1)$ é a correlação de *ativos*, que dosa o peso do fator comum. O default ocorre quando $Y_n < \Phi^{-1}(p_n)$, sendo Φ^{-1} a inversa da distribuição normal-padrão acumulada — o limiar é escolhido de modo que a probabilidade incondicional de default seja exatamente p_n . A correlação de *default* implícita entre duas contrapartes com PDs p e q é

$$\rho_D(p, q; \rho) = \frac{\Phi_2(\Phi^{-1}(p), \Phi^{-1}(q); \rho) - pq}{\sqrt{p(1-p)}\sqrt{q(1-q)}}, \quad (10)$$

em que $\Phi_2(\cdot, \cdot; \rho)$ é a distribuição normal bivariada acumulada com correlação ρ — o numerador é a probabilidade de default conjunto menos o produto das marginais. O CreditLens calibra ρ numericamente para que $\rho_D(\bar{p}, \bar{p}; \rho)$ iguale o alvo comum definido pelo usuário.

Variante t-Student. Substituindo o vetor gaussiano por

$$Y_n = \sqrt{\frac{\nu}{V}} \left(\sqrt{\rho} G + \sqrt{1-\rho} \varepsilon_n \right), \quad V \sim \chi_\nu^2, \quad (11)$$

em que V é um choque radial qui-quadrado com ν graus de liberdade, comum a todas as contrapartes, e o limiar passa a ser $t_\nu^{-1}(p_n)$ (inversa da distribuição t de Student), o modelo adquire *dependência de cauda*: mesmo mantida a correlação ρ , defaults conjuntos extremos tornam-se ordens de magnitude mais prováveis, porque um sorteio pequeno de V amplifica simultaneamente todos os Y_n . Poucos graus de liberdade (ν baixo) engordam a cauda; no limite $\nu \rightarrow \infty$ recupera-se o caso gaussiano.

ASRF (carteira assintótica). No limite de uma carteira infinitamente granular e homogênea, o modelo gaussiano admite a solução fechada de Vasicek:

$$\text{VaR}_\alpha = \left(\sum_n c_n \right) \Phi \left(\frac{\Phi^{-1}(\bar{p}) + \sqrt{\rho} \Phi^{-1}(\alpha)}{\sqrt{1-\rho}} \right), \quad (12)$$

em que $\sum_n c_n$ é a exposição líquida total, $\bar{p}$ a PD homogênea da carteira, ρ a correlação de ativos e α o nível de confiança. É o esqueleto analítico do IRB e, neste documento, funciona também como verificação de consistência do modelo *threshold* simulado.

3.4 Capital regulatório IRB e ajuste de granularidade (cap. 6)

O requerimento de capital do IRB, avaliado contraparte a contraparte, é a perda inesperada condicional ao cenário sistemático de 99,90%, multiplicada pelo ajuste de maturidade:

$$K_n = \left[\Phi \left(\frac{\Phi^{-1}(p_n) + \sqrt{\rho_B(p_n)} \Phi^{-1}(0,999)}{\sqrt{1-\rho_B(p_n)}} \right) - p_n \right] \cdot \text{MA}(M_n, p_n), \quad \text{Capital} = \sum_n c_n K_n, \quad (13)$$

em que K_n é o coeficiente de capital da contraparte n (fração da severidade c_n exigida como capital), $\rho_B(p_n)$ é a correlação de ativos regulatória e $\text{MA}(M_n, p_n)$ o ajuste de maturidade, função do prazo efetivo M_n e da PD. A correlação regulatória é interpolada exponencialmente entre 12% e 24%,

$$\rho_B(p) = 0,12 q(p) + 0,24 (1 - q(p)), \quad q(p) = \frac{1 - e^{-50p}}{1 - e^{-50}}, \quad (14)$$

em que $q(p)$ é o peso de interpolação: PDs baixas recebem correlação próxima de 24% (grandes empresas, mais sensíveis ao ciclo) e PDs altas, próxima de 12%. O ajuste de maturidade é

$$\text{MA}(M, p) = \frac{1 + (M - 2,5) b(p)}{1 - 1,5 b(p)}, \quad b(p) = (0,11582 - 0,05478 \ln p)^2, \quad (15)$$

em que $b(p)$ é a inclinação de maturidade, conforme implementado na biblioteca do livro,¹ e prazos acima de 2,5 anos elevam o requerimento (risco de migração cresce com o horizonte). O RWA equivalente é 12,5× o capital.

Ajuste de granularidade. A fórmula (13) pressupõe uma carteira infinitamente granular; carteiras reais carregam risco idiossincrático residual de concentração. O CreditLens adiciona o ajuste de granularidade de Gordy–Lütkebohmert na forma analítica derivada do CreditRisk⁺ — a mesma do exemplo do capítulo 6 do livro —, cuja estrutura é

$$\text{GA} = \frac{1}{2K^*} \sum_{n=1}^N c_n^2 \left[\delta (C_n \mathcal{R} \mathcal{K}_n + \mathcal{R} \mathcal{K}_n^2 \gamma) - K_n (C_n + 2 \mathcal{R} \mathcal{K}_n \gamma) \right], \quad (16)$$

em que $K^* = \sum_n c_n K_n$ é o capital IRB total da carteira, $\mathcal{R} \mathcal{K}_n$ agrupa os termos de capital e PD da contraparte n , e δ , γ e C_n são coeficientes que dependem dos parâmetros de volatilidade setorial e de LGD, fixados nos valores de referência do livro ($a = 0,25$, $\xi = 0,25$, $\bar{g} = 1$). O ponto essencial é que o GA cresce com o *quadrado* das participações c_n^2 — é, em essência, uma penalidade de HHI sobre o capital.

¹O texto de Basileia II usa o coeficiente 0,11852; a biblioteca de Bolder implementa 0,11582. O efeito numérico sobre o capital agregado é da ordem de décimos de ponto percentual. O CreditLens preserva a implementação original do livro.

3.5 Contribuições de risco (cap. 7)

A alocação de Euler decompõe o risco total nas parcelas marginais de cada contraparte. Para o VaR e o ES, as contribuições admitem representação por esperança condicional:

$$\text{VaR}_\alpha^{(n)} = \mathbb{E}[c_n \mathbb{I}_{D_n} \mid L = \text{VaR}_\alpha], \quad \text{ES}_\alpha^{(n)} = \mathbb{E}[c_n \mathbb{I}_{D_n} \mid L \geq \text{VaR}_\alpha], \quad (17)$$

em que $\text{VaR}_\alpha^{(n)}$ e $\text{ES}_\alpha^{(n)}$ são as contribuições da contraparte n : a perda média que ela gera, respectivamente, nos cenários em que a perda total *igual* o VaR e nos cenários em que o *excede ou iguala*. Por construção, as contribuições somam exatamente o VaR e o ES da carteira. O CreditLens as estima por decomposição de Monte Carlo no modelo *threshold* gaussiano: em cada uma de S repetições independentes com M trajetórias, calcula-se a perda média de cada nome nas trajetórias do evento condicionante, e a média das S repetições reduz o ruído inerente ao condicionamento em evento raro. As contribuições de ES são substancialmente mais estáveis que as de VaR — condicionam em um conjunto de cenários, não em um único ponto da distribuição — e são a referência recomendada para *pricing* e alocação de capital.

3.6 Extensão multifatorial setorial

Os modelos anteriores usam um único fator sistemático: implicitamente, duas empresas do mesmo setor estão tão correlacionadas entre si quanto empresas de setores distintos. A extensão multifatorial corrige essa limitação com dois níveis de fatores, na mesma estrutura de correlação do capítulo 4 de Bolder:

$$Y_n = \sqrt{\rho_G} G + \sqrt{\rho_S - \rho_G} F_{s(n)} + \sqrt{1 - \rho_S} \varepsilon_n, \quad (18)$$

em que G é o fator global comum a toda a carteira, $F_{s(n)}$ é o fator do setor $s(n)$ ao qual pertence a contraparte n (informado pela coluna **setor**), ε_n é o choque idiossincrático (todos normais-padrão independentes), ρ_G é a correlação de ativos entre contrapartes de setores *distintos* e $\rho_S \geq \rho_G$ é a correlação de ativos dentro do *mesmo* setor. O default continua ocorrendo quando $Y_n < \Phi^{-1}(p_n)$, e a variante t-Student é obtida como antes, multiplicando Y_n pelo choque radial $\sqrt{\nu/V}$. A calibração espelha a do modelo de um fator: o usuário define dois alvos de correlação de *default* — intra-setor e inter-setor — e o aplicativo resolve numericamente ρ_S e ρ_G por meio de (10).

Além das medidas de risco usuais, o modelo multifatorial habilita o relatório de *contribuições por setor*: as contribuições de ES por contraparte são agregadas pelo setor de cada nome, e a razão entre a participação do setor no ES e a sua participação na exposição identifica os setores que concentram proporcionalmente mais cauda do que carteira — a métrica natural para calibrar limites setoriais. Carteiras sem a coluna **setor** seguem funcionando normalmente no modo de um fator.

3.7 Estratégia de calibração comum

Para que as caudas sejam comparáveis, todos os modelos com dependência são ancorados no mesmo par $(\bar{p}, \rho_D^{\text{alvo}})$ — a PD média ponderada por exposição e a correlação de default alvo: a beta-binomial pelo método dos momentos, o *threshold* gaussiano/t por meio de (10), e o ASRF herdando o ρ calibrado. As diferenças remanescentes entre os modelos refletem, portanto, *forma distributiva* — em particular a presença ou não de dependência de cauda — e não níveis distintos de correlação. O CreditRisk⁺ é parametrizado diretamente por (w, v) , expostos ao usuário na interface. O IRB, por construção regulatória, usa $\rho_B(p) \in [12\%, 24\%]$ — tipicamente acima do ρ_D implícito em carteiras corporativas — e por isso não é ancorado no alvo comum.

4 Estudo de caso: carteira hipotética

4.1 A carteira

A base de teste contém $N = 250$ contrapartes corporativas distribuídas em oito graus de rating (AAA a C), com exposições log-normais (cauda pesada, como é típico do crédito corporativo), LGD atribuída por classe de garantia e prazos uniformes em $[1, 5]$ anos. A Tabela 1 resume o perfil.

Tabela 1: Perfil da carteira de teste.

Métrica	Valor
Contrapartes (N)	250
EAD total	10 000,0
Exposição líquida total ($\sum_n c_n$)	4 402,7
PD média simples	2,36%
PD média ponderada por exposição ($\bar{p}$)	2,16%
LGD média	46,0%
Perda esperada ($\mathbb{E}[L]$)	95,0 (2,16% da exposição líquida)
HHI	0,0112
Número efetivo de nomes	88,9
Maior exposição individual	3,39%
Dez maiores exposições	24,4%

Com HHI de 0,0112, a carteira equivale a apenas 89 nomes de igual tamanho — uma concentração relevante, que o ajuste de granularidade da Seção 4.4 quantificará em capital.

4.2 Parâmetros e calibração

A análise utilizou $M = 100\,000$ simulações, semente 42, alvo de correlação de default $\rho_D^{\text{alvo}} = 5\%$, $\nu = 10$ graus de liberdade na variante t e $(w, v) = (0,35; 1,2)$ no CreditRisk⁺. A calibração produziu, para a beta-binomial, $(a, b) = (0,410; 18,590)$ — note que $a < 1$ implica densidade explosiva na origem com cauda direita longa — e, para o modelo *threshold*, correlação de ativos $\rho = 24,66\%$. Este último número merece registro: para gerar módicos 5% de correlação de *default* numa carteira com $\bar{p} = 2,16\%$, são necessários quase 25% de correlação de *ativos*. É a não linearidade de (10) em ação — e a razão pela qual as duas noções de correlação jamais devem ser confundidas.

4.3 Medidas de risco por modelo

A Tabela 2 contém a mensagem central do exercício, que pode ser lida em três camadas. A primeira é a *verificação de consistência*: a perda esperada é de aproximadamente 95 em todos os modelos (o desvio do CreditRisk⁺, 89,1, decorre da aproximação de Poisson, que admite eventos múltiplos e não é recalibrada em nível). Ora, se modelos calibrados ao mesmo primeiro momento chegam a diferir por um fator de quase seis vezes no VaR 99,90% — de 234 a 1 373 —, fica demonstrado empiricamente que o risco de crédito de uma carteira reside, essencialmente, na estrutura de dependência entre os defaults, e não nas PDs individuais.

A segunda camada é a hierarquia das caudas, que segue exatamente a teoria: independente < CreditRisk⁺ (com os w, v adotados) < *threshold* gaussiano < beta-binomial $\approx$ ASRF < t-Student. A variante t, mantida a *mesma* correlação de ativos do modelo gaussiano, entrega VaR 99,9% 48% maior e ES 99,9% 55% maior — o preço da dependência de cauda, que a cópula gaussiana, por construção, não captura.

A terceira camada é o ASRF (1 265,6) acima do *threshold* gaussiano simulado (927,1), apesar de descrever uma carteira *mais* diversificada. A aparente contradição é instrutiva: o ASRF usa

Tabela 2: Medidas de risco por modelo (unidades monetárias; $M = 100\,000$). Entre parênteses, o VaR 99,90% em percentual da exposição líquida.

Modelo	EL	UL	VaR _{99%}	ES _{99%}	VaR _{99,9%}	ES _{99,9%}
Binomial indep. (analítico, homog.)	95,0	40,5	192,0	192,4	233,9 (5,3%)	—
Binomial independente (MC)	94,9	60,5	279,3	320,3	371,2 (8,4%)	407,3
CreditRisk ⁺ (1 fator)	89,1	64,9	295,8	337,7	396,2 (9,0%)	427,5
Threshold Gaussiano 1F	95,2	120,6	563,6	727,9	927,1 (21,1%)	1 116,7
Beta-binomial (<i>mixture</i>)	94,9	157,9	735,7	930,4	1 187,5 (27,0%)	1 332,1
ASRF (analítico)	95,0	—	701,0	944,9	1 265,6 (28,7%)	1 520,5
Threshold t-Student ($\nu = 10$)	95,2	147,5	707,6	1 000,0	1 372,8 (31,2%)	1 731,4
Threshold Gaussiano multifat.	95,4	107,3	495,8	620,6	784,7 (17,8%)	902,9
Threshold t-Student multifat. ($\nu = 10$)	95,2	135,8	655,1	901,4	1 246,9 (28,3%)	1 493,7
IRB Basileia ($K^* + \mathbb{E}[L]$)	95,0	—	—	—	805,2 (18,3%)	—

a aproximação homogênea com $\bar{p}$ ponderado por exposição e, numa carteira heterogênea — em que os nomes de pior rating não são os de maior exposição —, essa homogeneização é conservadora, efeito discutido pelo próprio Bolder no capítulo 4.




Figura 1: Distribuição de perdas sob cinco modelos: corpo até o quantil de 99,9% (esq.) e cauda em escala logarítmica (dir., linha pontilhada no nível de 99,90%). No corpo, as distribuições são quase indistinguíveis; na cauda, separam-se por fator de até quatro vezes — ilustrando por que a escolha da estrutura de dependência domina qualquer refinamento de PD individual. Note os pares um fator vs. multifatorial (azul/verde e vermelho/laranja): a estrutura setorial desloca a cauda para dentro em ambas as famílias.

4.4 Capital regulatório IRB

Aplicando (13) contraparte a contraparte, o capital IRB da carteira é

$$K^* = \sum_n c_n K_n = 710,1 \quad (16,13\% \text{ da exposição líquida}), \quad \text{RWA} = 12,5 K^* = 8\,876,7.$$

O ajuste de granularidade adiciona $GA = 91,8$, elevando o requerimento a 801,9 — um acréscimo de 12,9% sobre o capital IRB puro, coerente com os 89 nomes efetivos da carteira. Somado à perda esperada para permitir comparação com os VaRs totais dos modelos internos, o IRB+EL de 805,2 (18,3%) situa-se entre o *threshold* gaussiano calibrado a $\rho_D = 5\%$ e os modelos de cauda pesada. A leitura é direta: a correlação regulatória $\rho_B \in [12\%, 24\%]$ é deliberadamente conservadora frente a calibrações internas típicas, mas a cópula gaussiana subjacente ao IRB não carrega dependência de cauda — e o t-Student o ultrapassa com folga.




Figura 2: VaR 99,90% por modelo, em percentual da exposição líquida.

4.5 Contribuições de risco

Tabela 3: Dez maiores contribuições ao ES 99% (decomposição MC, *threshold* gaussiano, $S = 10$).

Contraparte	Rating	Exposição	PD	Contrib. ES	% do ES
CP0173	CCC	292,3	8,99%	85,7	11,8%
CP0156	BB	217,1	2,34%	40,7	5,6%
CP0051	C	47,5	24,41%	26,4	3,6%
CP0092	B	118,1	6,33%	21,4	3,0%
CP0078	BBB	266,8	0,63%	21,2	2,9%
CP0139	BBB	301,9	0,58%	19,1	2,6%
CP0103	C	44,3	37,05%	19,1	2,6%
CP0228	B	87,3	5,38%	16,1	2,2%
CP0036	B	109,2	3,67%	15,9	2,2%
CP0245	C	101,4	15,55%	15,5	2,1%

A Tabela 3 e a Figura 3 revelam a anatomia da cauda. A contraparte CP0173 — rating CCC com a segunda maior exposição da carteira — responde sozinha por 11,8% do ES 99%: a combinação multiplicativa de PD alta com exposição alta que a alocação de capital deve penalizar no *pricing*. Observe, porém, CP0078 e CP0139: ratings BBB, PDs abaixo de 65 pontos-base e, ainda assim, entre os seis maiores contribuintes — puro efeito de tamanho (cerca de 300 de exposição cada). A lição operacional é clara: a gestão de limites por rating, isoladamente, não controla a cauda; a métrica correta de concentração é a contribuição de risco, não a PD. Os dez nomes da tabela somam cerca de 39% do ES total, contra 24% da exposição — a cauda é mais concentrada do que a própria carteira.

4.6 Análise multifatorial setorial

A carteira de teste distribui-se em oito setores, com HHI setorial de 0,1364 — o equivalente a 7,3 setores efetivos, uma diversificação setorial razoável, ainda que desigual: Energia detém 17,5% da exposição líquida, enquanto Agro e Petroquímica, somados, não chegam a 13%. Com alvos de correlação de default de 8% intra-setor e 3% inter-setor, a calibração numérica via (10) produziu correlações de *ativos* de $\rho_S = 33,67\%$ e $\rho_G = 17,02\%$ — novamente a não linearidade em ação: dobrar ou triplicar a correlação de default exige quase o dobro da correlação de ativos.




Figura 3: Quinze maiores contribuições ao ES 99% (percentual do total).

O efeito diversificação. A Tabela 4 compara, nível a nível, o modelo de um fator (calibrado a $\rho_D = 5\%$ uniforme) com o multifatorial. O padrão é consistente nas duas famílias: o multifatorial entrega medidas menores, e a redução *crece com o nível de confiança* — de cerca de -6% no VaR 95% a -15% no VaR 99,90% do modelo gaussiano (-19% no ES). A razão é estrutural. No modelo de um fator, todos os 31 125 pares de contrapartes carregam a mesma correlação de default de 5%; no multifatorial, apenas os pares *dentro* de um mesmo setor (cerca de 13% dos pares) operam ao alvo intra de 8%, enquanto a grande maioria — pares entre setores distintos — opera a apenas 3%.² A correlação média da carteira cai, e cai justamente onde mais importa: nos cenários extremos, em que o fator global sozinho não basta para derrubar simultaneamente nomes de setores diferentes. A estrutura setorial, portanto, *revela um benefício de diversificação que o fator único, ao aplicar 5% indistintamente, não consegue distinguir* — e a Figura 4 mostra que o efeito se preserva, em menor grau (-9% no VaR 99,9%), mesmo sob a dependência de cauda da variante t.

Tabela 4: Um fator vs. multifatorial setorial: VaR e ES por nível de confiança (unidades monetárias; variação percentual do multifatorial sobre o um fator).

Nível α	Gaussiano				t-Student ($\nu = 10$)			
	1 fator	Multif.	ΔVaR	ΔES	1 fator	Multif.	ΔVaR	ΔES
95%	329,3	309,1	$-6,1\%$	$-10,9\%$	354,8	340,6	$-4,0\%$	$-6,9\%$
99%	563,6	495,8	$-12,0\%$	$-14,7\%$	707,6	655,1	$-7,4\%$	$-9,9\%$
99,9%	927,1	784,7	$-15,4\%$	$-19,1\%$	1 372,8	1 246,9	$-9,2\%$	$-13,7\%$
99,97%	1 129,9	959,6	$-15,1\%$	$-24,0\%$	1 822,2	1 592,0	$-12,6\%$	$-18,8\%$

Há uma leitura de gestão importante aqui: o resultado *não* diz que o multifatorial “economiza

²A conta é verificável: com $N = 250$, o total de pares é $\binom{250}{2} = \frac{250 \times 249}{2} = 31\,125$. Os pares intra-setor são $\sum_s \binom{n_s}{2}$ sobre os oito setores; com os tamanhos da carteira de teste (37, 36, 33, 33, 32, 31, 24 e 24 nomes), $666 + 630 + 528 + 528 + 496 + 465 + 276 + 276 = 3\,865$ pares, ou 12,4% do total. A correlação de default média da carteira multifatorial fica, portanto, em torno de $0,124 \times 8\% + 0,876 \times 3\% \approx 3,6\%$ — abaixo dos 5% uniformes do modelo de um fator. Note que a fração intra-setor cresce quadraticamente com a concentração setorial (é o HHI setorial agindo sobre os pares): numa carteira concentrada em poucos setores, a média se aproximaria do alvo intra e a comparação poderia se inverter.




Figura 4: VaR em percentual da exposição líquida, um fator vs. multifatorial, nas famílias gaussiana (esq.) e t-Student (dir.). Os rótulos indicam a variação percentual. O benefício de diversificação setorial cresce com o nível de confiança e persiste sob dependência de cauda.

capital” por construção. Ele diz que, *dada esta carteira bem espalhada em oito setores*, a premissa de correlação uniforme do fator único é conservadora. Numa carteira concentrada em poucos setores a comparação se inverteria — os pares intra-setor a 8% passariam a dominar — e é exatamente essa sensibilidade à composição setorial que o modelo de um fator é incapaz de exibir.

4.7 Contribuições por setor: exposição, provisão e cauda

Tabela 5: Decomposição setorial completa (*threshold* gaussiano multifatorial; contribuições ao ES 99%, $S = 10$). Participações em percentual do total da carteira; razão = contribuição ao ES $\div$ exposição.

Setor	Nomes	Exposição	Exp. (%)	EL	EL (%)	ES (%)	Razão
Indústria	37	548,2	12,5	17,3	18,2	20,6	1,65
Energia	24	772,1	17,5	13,4	14,1	20,5	1,17
Serviços	36	556,3	12,6	23,8	25,1	15,8	1,25
Varejo	33	652,8	14,8	9,1	9,6	12,6	0,85
Construção	33	655,4	14,9	13,4	14,1	11,6	0,78
Logística	31	646,1	14,7	5,6	5,9	9,5	0,65
Agro	24	254,4	5,8	8,3	8,7	5,1	0,89
Petroquímica	32	317,3	7,2	4,2	4,4	4,3	0,60
Total	250	4 402,7	100	95,0	100	100	1,00

A Tabela 5 coloca lado a lado, para cada setor, as três participações que uma mesa de crédito precisa distinguir: na *exposição* (quanto do balanço está ali), na *perda esperada* (quanto da provisão o setor consome) e na *cauda* (quanto do capital econômico o setor exige). A Figura 5 visualiza o contraste, e três perfis setoriais emergem com nitidez:

Setor de provisão: Serviços. Com 12,6% da exposição, Serviços consome 25,1% da perda esperada da carteira — o dobro da sua participação — mas apenas 15,8% da cauda. O setor abriga nomes de PD alta e porte moderado (a contraparte CP0051, rating C com PD de 24,4%, é o caso extremo): inadimplência *frequente*, que corrói resultado via provisão, mas cujo tamanho individual não tem força para produzir os cenários catastróficos que definem o capital.

Setor de cauda: Energia. O espelho invertido. Com a *maior* exposição setorial (17,5%), Energia consome perda esperada *abaixo* da sua participação (14,1%) — os nomes são majoritariamente de boa qualidade — mas responde por 20,5% do ES. O risco aqui não é a frequência de default, e sim o *porte*: o setor concentra as maiores exposições individuais da carteira (CP0038 com 211 e CP0039 com 97 de EAD, por exemplo), e basta o cenário sistemático adverso alcançá-las para a perda saltar. É risco de capital, não de provisão.

Setor misto: Indústria. O pior dos dois mundos, e o líder disparado da razão risco/exposição (1,65): com 12,5% da exposição, o setor pesa 18,2% na provisão e 20,6% na cauda. A explicação está na sua composição: Indústria combina o maior número de nomes (37) com a coexistência de exposições grandes e ratings fracos — CP0173 (CCC, exposição 292,3, o maior contribuinte individual da carteira) e CP0036 (B, 109,2) pertencem ao setor. Concentração de porte e de qualidade no mesmo lugar.

Na outra ponta, Logística e Petroquímica são os setores mais “baratos” em risco por unidade de exposição (razões de 0,65 e 0,60): carregam 14,7% e 7,2% do balanço a custo desproporcionalmente baixo de provisão e capital. Em linguagem de gestão de limites, são os setores com espaço para crescer; Indústria e Energia são os candidatos naturais a teto ou a exigência de garantias adicionais — e a distinção entre os perfis importa para o *tipo* de mitigação: em Serviços (provisão), a alavanca é *pricing* e seleção; em Energia (cauda), é limite de concentração individual; em Indústria, ambas.




Figura 5: Participação de cada setor na exposição líquida, na perda esperada e na cauda (ES 99%). A divergência entre as três barras de um mesmo setor revela o seu perfil de risco: EL acima da exposição indica frequência de default (provisão); ES acima da exposição indica concentração de porte (capital).

Por fim, vale registrar a consistência entre níveis de análise: os dez maiores contribuintes individuais da Tabela 3 concentram-se exatamente nos três setores de razão mais alta — CP0173, CP0036 e CP0228 em Indústria; CP0156 e CP0078 em Energia; CP0051 em Serviços —, de modo que a leitura setorial e a leitura por nome contam a mesma história em granularidades diferentes. É essa coerência que permite usar as duas visões em conjunto: o setor define *onde* apertar limites; a contribuição individual define *quem*.

5 Limitações e extensões

A versão atual adota LGD determinística (a extensão estocástica via distribuição beta, `crPlusOneFactorLGD`, já existe na biblioteca), correlação intra-setor uniforme na extensão multifatorial (cargas setoriais heterogêneas, como em `buildAssetCorrelationMatrix` e `getY2r`, são a generalização

natural), horizonte de um ano sem migração de ratings (o módulo `markovChain` habilita a visão multiperíodo) e Monte Carlo simples (o capítulo 8 do livro, também disponível na biblioteca, fornece *importance sampling* com deslocamento ótimo de média, capaz de estimar quantis extremos com uma fração das simulações). O ajuste de granularidade usa os parâmetros de referência do livro; em aplicação prudencial, a volatilidade setorial deve ser estimada a partir dos dados.

Referências

- Bolder, D. J. (2018). *Credit-Risk Modelling: Theoretical Foundations, Diagnostic Tools, Practical Examples, and Numerical Recipes in Python*. Springer. [Referencial teórico e bibliotecas numéricas, github.com/djbolder/credit-risk-modelling, GPL-3.0.]
- Basel Committee on Banking Supervision (2005). *An Explanatory Note on the Basel II IRB Risk Weight Functions*. BIS.
- Gordy, M. B. (2003). A risk-factor model foundation for ratings-based bank capital rules. *Journal of Financial Intermediation*, 12(3), 199–232.
- Gordy, M. B.; Lütkebohmert, E. (2013). Granularity adjustment for regulatory capital assessment. *International Journal of Central Banking*, 9(3), 33–71.
- Vasicek, O. (2002). The distribution of loan portfolio value. *Risk*, 15(12), 160–162.