

CreditLens

Análise Quantitativa de Carteiras de Crédito:
Documentação Metodológica e Estudo de Caso

Walter C. Neto

Baseado em D. J. Bolder, *Credit-Risk Modelling* (Springer, 2018)

Julho de 2026 — versão 0.6

Resumo

O **CreditLens** é um aplicativo de análise de risco de carteiras de crédito construído sobre as bibliotecas numéricas que acompanham o livro *Credit-Risk Modelling: Theoretical Foundations, Diagnostic Tools, Practical Examples, and Numerical Recipes in Python*, de David Jamieson Bolder (Springer, 2018). A partir do upload de uma carteira em padrão CSV definido, o aplicativo estima a distribuição de perdas sob um portfólio de modelos — independentes, *mixture models*, *threshold models* e o modelo regulatório (IRB de Basileia) —, todos calibrados a um alvo comum de correlação de default. São reportados a perda esperada, a volatilidade da perda, o VaR e o *Expected Shortfall* em múltiplos níveis de confiança, o capital regulatório com ajuste de granularidade e a decomposição do risco por contraparte. Este documento apresenta a arquitetura do aplicativo, o arcabouço teórico e matemático de cada modelo tal como implementado, e dois estudos de caso completos: uma carteira granular de 250 contrapartes, que percorre todo o portfólio de modelos, e uma base analítica de alta granularidade com 300 mil contratos, que exercita a camada de agregação, o motor *pooled* e a migração multiperíodo de ponta a ponta.

Sumário

1	O aplicativo	2
1.1	Padrão de carteira	2
2	Arcabouço matemático	3
2.1	A perda da carteira	3
2.2	Medidas de risco	3
2.3	Índices de concentração	3
3	O portfólio de modelos	3
3.1	Modelos independentes (cap. 2)	3
3.2	<i>Mixture models</i> (cap. 3)	4
3.3	<i>Threshold models</i> (cap. 4)	4
3.4	Capital regulatório IRB e ajuste de granularidade (cap. 6)	5
3.5	Contribuições de risco (cap. 7)	6
3.6	Modelo multifatorial setorial	6
3.7	Migração de ratings, ECL e horizonte multiperíodo	7
3.8	Camada de agregação e o motor <i>pooled</i>	8
3.9	Estratégia de calibração comum	9

4	Estudo de caso 1: carteira granular (250 contrapartes)	9
4.1	A carteira	9
4.2	Parâmetros e calibração	9
4.3	Medidas de risco por modelo	10
4.4	Capital regulatório IRB	10
4.5	Contribuições de risco	11
4.6	Análise multifatorial setorial	11
4.7	Contribuições por setor: exposição, provisão e cauda	13
4.8	Migração, ECL e capital multiperíodo	14
5	Estudo de caso 2: alta granularidade (300 mil contratos)	16
5.1	Fluxo de uso	16
5.2	Agregação	16
5.3	Capital: o portfólio de modelos no motor <i>pooled</i>	16
5.4	Setores	17
5.5	Migração: ECL e capital multiperíodo	17
5.6	Boas práticas para bases analíticas	18
6	Limitações e extensões	19

1 O aplicativo

O CreditLens opera em quatro etapas. Na *ingestão*, o usuário carrega um arquivo CSV no padrão da ferramenta; o validador verifica a unicidade dos identificadores e os domínios das variáveis, aplica um piso regulatório de 3 pontos-base às PDs nulas e trunca os prazos ao intervalo $[1, 5]$ anos exigido pelo ajuste de maturidade do IRB. Na *calibração*, os parâmetros de dependência de cada família de modelos são ajustados a um mesmo alvo de correlação de default, o que torna as caudas diretamente comparáveis entre modelos. Na *estimação*, todos os modelos são executados — combinando fórmulas analíticas e simulação de Monte Carlo com M trajetórias — e, na *apresentação*, os resultados são exibidos em tabelas e gráficos interativos, com exportação integral para Excel.

1.1 Padrão de carteira

Cada linha do arquivo CSV representa uma contraparte. As colunas obrigatórias são **id_contraparte** (identificador único da contraparte), **exposicao** (o EAD, *exposure at default* — valor exposto no momento do default, estritamente positivo) e **pd** (probabilidade de default no horizonte de um ano, número em $(0, 1)$). As colunas opcionais são **lgd** (*loss given default* — fração da exposição efetivamente perdida em caso de default, em $(0, 1]$; valor-padrão 1,0), **prazo_anos** (prazo efetivo da operação, em anos, usado no ajuste de maturidade do IRB; valor-padrão 2,5) e as colunas **rating** (funcional nos módulos de migração e ECL, em que mapeia a contraparte à linha da matriz de transição), **rating_origem** (rating na originação, usado na classificação de estágios), **setor** (funcional no modelo multifatorial) e **nome** (descritiva). Seguindo a convenção de Bolder, toda a modelagem usa a *severidade*

$$c_n = \text{EAD}_n \times \text{LGD}_n, \quad (1)$$

em que EAD_n é a exposição da contraparte n e LGD_n a sua perda dado o default; c_n é, portanto, a exposição líquida sujeita a perda de cada contraparte, tratada como determinística ao longo de todo o documento.

2 Arcabouço matemático

2.1 A perda da carteira

Considere uma carteira com N contrapartes, em que p_n denota a probabilidade de default da contraparte n e c_n a sua severidade. Definindo o indicador de default $\mathbb{I}_{D_n}$, variável aleatória que vale 1 se a contraparte n entra em default no horizonte de um ano e 0 caso contrário, a perda da carteira é

$$L = \sum_{n=1}^N c_n \mathbb{I}_{D_n}. \quad (2)$$

O que distingue os modelos apresentados neste documento é, essencialmente, a estrutura de dependência imposta aos indicadores $\mathbb{I}_{D_n}$: é ela que governa a espessura da cauda de L e, portanto, o capital econômico da carteira.

2.2 Medidas de risco

Para cada modelo, o CreditLens reporta quatro medidas. A *perda esperada* é $\mathbb{E}[L] = \sum_n p_n c_n$. A *volatilidade da perda* (ou perda não esperada, UL) é $UL = \sqrt{\text{Var}(L)}$. O *valor em risco* no nível de confiança α ,

$$\text{VaR}_\alpha(L) = \inf\{\ell : \mathbb{P}(L \leq \ell) \geq \alpha\}, \quad (3)$$

é o menor valor de perda ℓ que não é excedido com probabilidade de pelo menos α . O *expected shortfall*,

$$\text{ES}_\alpha(L) = \mathbb{E}[L \mid L \geq \text{VaR}_\alpha(L)], \quad (4)$$

é a perda média nos cenários em que o VaR é atingido ou excedido — por construção, $\text{ES}_\alpha \geq \text{VaR}_\alpha$. As medidas são calculadas nos níveis $\alpha \in \{95\%, 99\%, 99,9\%, 99,97\%\}$. Nas implementações por Monte Carlo, elas são obtidas como estatísticas de ordem da distribuição simulada de L . O capital econômico usual é a parcela inesperada $\text{VaR}_\alpha - \mathbb{E}[L]$.

2.3 Índices de concentração

O resumo da carteira inclui o índice de Herfindahl–Hirschman,

$$\text{HHI} = \sum_{n=1}^N w_n^2, \quad N_{\text{efetivo}} = \text{HHI}^{-1}, \quad (5)$$

em que $w_n = c_n / \sum_k c_k$ é a participação da contraparte n na exposição líquida total. O inverso do HHI é o *número efetivo de nomes*: quantas contrapartes de igual tamanho produziriam a mesma concentração. Esse indicador antecipa a magnitude do ajuste de granularidade da Seção 3.4.

3 O portfólio de modelos

3.1 Modelos independentes (cap. 2)

O ponto de partida — e contrafactual deliberadamente ingênuo — assume defaults independentes entre contrapartes. Na versão analítica homogênea, toma-se $\bar{p}$ (a PD média da carteira ponderada por exposição) e a severidade média $\bar{c}$; o número de defaults K segue então uma distribuição binomial,

$$\mathbb{P}(K = k) = \binom{N}{k} \bar{p}^k (1 - \bar{p})^{N-k}, \quad L \approx \bar{c} K, \quad (6)$$

em que k é o número de defaults observado e os quantis de L são obtidos por interpolação da distribuição acumulada. Na versão de Monte Carlo heterogênea, sorteia-se para cada trajetória m e contraparte n um uniforme $U_{m,n} \sim \mathcal{U}(0, 1)$ e declara-se default quando $U_{m,n} < p_n$, preservando a heterogeneidade de PDs e exposições. Pela lei dos grandes números, a independência elimina quase toda a variabilidade sistemática: a cauda resultante é fina demais para qualquer uso prudencial, e o papel do modelo aqui é servir de piso de referência para os demais.

3.2 *Mixture models* (cap. 3)

Os *mixture models* induzem dependência fazendo as PDs compartilharem um fator aleatório comum. Condicionalmente ao fator, os defaults são independentes; incondicionalmente, tornam-se correlacionados.

Beta-binomial. A probabilidade comum de default é sorteada de $Z \sim \text{Beta}(a, b)$, em que a e b são os parâmetros de forma da distribuição beta; dado o sorteio de Z , cada contraparte entra em default de forma independente com probabilidade Z . A calibração resolve o sistema

$$\mathbb{E}[Z] = \frac{a}{a+b} = \bar{p}, \quad \rho_D = \frac{1}{a+b+1} = \rho_D^{\text{alvo}}, \quad (7)$$

em que ρ_D denota a correlação de default entre pares de contrapartes e ρ_D^{alvo} é o alvo escolhido pelo usuário. É o *mixture model* mais parcimonioso e tende a produzir caudas pesadas quando ρ_D^{alvo} é alto em relação a $\bar{p}$.

CreditRisk⁺ (Poisson-gama, um fator). O fator sistemático é $S \sim \Gamma(v, 1/v)$, distribuição gama parametrizada de modo que $\mathbb{E}[S] = 1$ e $\text{Var}(S) = 1/v$ — ou seja, v controla a volatilidade do ciclo: quanto menor v , mais volátil o fator. A intensidade condicional de default de cada contraparte é

$$p_n(S) = p_n (1 - w + wS), \quad (8)$$

em que $w \in (0, 1)$ é a carga do fator, isto é, a fração da intensidade que responde ao ciclo (o complemento $1 - w$ é a parcela idiossincrática). Os defaults são gerados por uma contagem de Poisson $H_n \sim \text{Poisson}(p_n(S))$, com default declarado quando $H_n \geq 1$. Trata-se do arcabouço atuarial clássico de portfólio de crédito, que reaparece na Seção 3.4 como base analítica do ajuste de granularidade.

3.3 *Threshold models* (cap. 4)

Nos *threshold models*, o default ocorre quando uma variável latente — interpretada como o retorno dos ativos da contraparte — cai abaixo de um limiar. Na família gaussiana de um fator, espinha dorsal da prática de mercado e do próprio IRB, o estado latente da contraparte n é

$$Y_n = \sqrt{\rho} G + \sqrt{1 - \rho} \varepsilon_n, \quad G, \varepsilon_1, \dots, \varepsilon_N \stackrel{iid}{\sim} \mathcal{N}(0, 1), \quad (9)$$

em que G é o fator sistemático comum a toda a carteira, ε_n é o choque idiossincrático da contraparte n e $\rho \in (0, 1)$ é a correlação de *ativos*, que dosa o peso do fator comum. O default ocorre quando $Y_n < \Phi^{-1}(p_n)$, sendo Φ^{-1} a inversa da distribuição normal-padrão acumulada — o limiar é escolhido de modo que a probabilidade incondicional de default seja exatamente p_n . A correlação de *default* implícita entre duas contrapartes com PDs p e q é

$$\rho_D(p, q; \rho) = \frac{\Phi_2(\Phi^{-1}(p), \Phi^{-1}(q); \rho) - pq}{\sqrt{p(1-p)}\sqrt{q(1-q)}}, \quad (10)$$

em que $\Phi_2(\cdot, \cdot; \rho)$ é a distribuição normal bivariada acumulada com correlação ρ — o numerador é a probabilidade de default conjunto menos o produto das marginais. O CreditLens calibra ρ numericamente para que $\rho_D(\bar{p}, \bar{p}; \rho)$ iguale o alvo comum definido pelo usuário.

Variante t-Student. Substituindo o vetor gaussiano por

$$Y_n = \sqrt{\frac{\nu}{V}} \left(\sqrt{\rho} G + \sqrt{1-\rho} \varepsilon_n \right), \quad V \sim \chi_\nu^2, \quad (11)$$

em que V é um choque radial qui-quadrado com ν graus de liberdade, comum a todas as contrapartes, e o limiar passa a ser $t_\nu^{-1}(p_n)$ (inversa da distribuição t de Student), o modelo adquire *dependência de cauda*: mesmo mantida a correlação ρ , defaults conjuntos extremos tornam-se ordens de magnitude mais prováveis, porque um sorteio pequeno de V amplifica simultaneamente todos os Y_n . Poucos graus de liberdade (ν baixo) engordam a cauda; no limite $\nu \rightarrow \infty$ recupera-se o caso gaussiano.

ASRF (carteira assintótica). No limite de uma carteira infinitamente granular e homogênea, o modelo gaussiano admite a solução fechada de Vasicek:

$$\text{VaR}_\alpha = \left(\sum_n c_n \right) \Phi \left(\frac{\Phi^{-1}(\bar{p}) + \sqrt{\rho} \Phi^{-1}(\alpha)}{\sqrt{1-\rho}} \right), \quad (12)$$

em que $\sum_n c_n$ é a exposição líquida total, $\bar{p}$ a PD homogênea da carteira, ρ a correlação de ativos e α o nível de confiança. É o esqueleto analítico do IRB e, neste documento, funciona também como verificação de consistência do modelo *threshold* simulado.

3.4 Capital regulatório IRB e ajuste de granularidade (cap. 6)

O requerimento de capital do IRB, avaliado contraparte a contraparte, é a perda inesperada condicional ao cenário sistemático de 99,90%, multiplicada pelo ajuste de maturidade:

$$K_n = \left[\Phi \left(\frac{\Phi^{-1}(p_n) + \sqrt{\rho_B(p_n)} \Phi^{-1}(0,999)}{\sqrt{1-\rho_B(p_n)}} \right) - p_n \right] \cdot \text{MA}(M_n, p_n), \quad \text{Capital} = \sum_n c_n K_n, \quad (13)$$

em que K_n é o coeficiente de capital da contraparte n (fração da severidade c_n exigida como capital), $\rho_B(p_n)$ é a correlação de ativos regulatória e $\text{MA}(M_n, p_n)$ o ajuste de maturidade, função do prazo efetivo M_n e da PD. A correlação regulatória é interpolada exponencialmente entre 12% e 24%,

$$\rho_B(p) = 0,12 q(p) + 0,24 (1 - q(p)), \quad q(p) = \frac{1 - e^{-50p}}{1 - e^{-50}}, \quad (14)$$

em que $q(p)$ é o peso de interpolação: PDs baixas recebem correlação próxima de 24% (grandes empresas, mais sensíveis ao ciclo) e PDs altas, próxima de 12%. O ajuste de maturidade é

$$\text{MA}(M, p) = \frac{1 + (M - 2,5) b(p)}{1 - 1,5 b(p)}, \quad b(p) = (0,11582 - 0,05478 \ln p)^2, \quad (15)$$

em que $b(p)$ é a inclinação de maturidade, conforme implementado na biblioteca do livro,¹ e prazos acima de 2,5 anos elevam o requerimento (risco de migração cresce com o horizonte). O RWA equivalente é $12,5 \times$ o capital.

¹O texto de Basileia II usa o coeficiente 0,11852; a biblioteca de Bolder implementa 0,11582. O efeito numérico sobre o capital agregado é da ordem de décimos de ponto percentual. O CreditLens preserva a implementação original do livro.

Ajuste de granularidade. A fórmula (13) pressupõe uma carteira infinitamente granular; carteiras reais carregam risco idiossincrático residual de concentração. O CreditLens adiciona o ajuste de granularidade de Gordy–Lütkebohmert na forma analítica derivada do CreditRisk⁺ — a mesma do exemplo do capítulo 6 do livro —, cuja estrutura é

$$\text{GA} = \frac{1}{2K^*} \sum_{n=1}^N c_n^2 \left[\delta(C_n \mathcal{R}\mathcal{K}_n + \mathcal{R}\mathcal{K}_n^2 \gamma) - K_n(C_n + 2\mathcal{R}\mathcal{K}_n \gamma) \right], \quad (16)$$

em que $K^* = \sum_n c_n K_n$ é o capital IRB total da carteira, $\mathcal{R}\mathcal{K}_n$ agrupa os termos de capital e PD da contraparte n , e δ , γ e C_n são coeficientes que dependem dos parâmetros de volatilidade setorial e de LGD, fixados nos valores de referência do livro ($a = 0,25$, $\xi = 0,25$, $\bar{g} = 1$). O ponto essencial é que o GA cresce com o *quadrado* das participações c_n^2 — é, em essência, uma penalidade de HHI sobre o capital.

3.5 Contribuições de risco (cap. 7)

A alocação de Euler decompõe o risco total nas parcelas marginais de cada contraparte. Para o VaR e o ES, as contribuições admitem representação por esperança condicional:

$$\text{VaR}_\alpha^{(n)} = \mathbb{E}[c_n \mathbb{I}_{D_n} \mid L = \text{VaR}_\alpha], \quad \text{ES}_\alpha^{(n)} = \mathbb{E}[c_n \mathbb{I}_{D_n} \mid L \geq \text{VaR}_\alpha], \quad (17)$$

em que $\text{VaR}_\alpha^{(n)}$ e $\text{ES}_\alpha^{(n)}$ são as contribuições da contraparte n : a perda média que ela gera, respectivamente, nos cenários em que a perda total *igual* o VaR e nos cenários em que o *excede ou iguala*. Por construção, as contribuições somam exatamente o VaR e o ES da carteira. O CreditLens as estima por decomposição de Monte Carlo no modelo *threshold* gaussiano: em cada uma de S repetições independentes com M trajetórias, calcula-se a perda média de cada nome nas trajetórias do evento condicionante, e a média das S repetições reduz o ruído inerente ao condicionamento em evento raro. As contribuições de ES são substancialmente mais estáveis que as de VaR — condicionam em um conjunto de cenários, não em um único ponto da distribuição — e são a referência recomendada para *pricing* e alocação de capital.

3.6 Modelo multifatorial setorial

Os modelos de um fator carregam uma premissa implícita: duas empresas do mesmo setor estão tão correlacionadas entre si quanto empresas de setores distintos. O modelo multifatorial generaliza essa premissa com dois níveis de fatores, na mesma estrutura de correlação do capítulo 4 de Bolder:

$$Y_n = \sqrt{\rho_G} G + \sqrt{\rho_S - \rho_G} F_{s(n)} + \sqrt{1 - \rho_S} \varepsilon_n, \quad (18)$$

em que G é o fator global comum a toda a carteira, $F_{s(n)}$ é o fator do setor $s(n)$ ao qual pertence a contraparte n (informado pela coluna **setor**), ε_n é o choque idiossincrático (todos normais-padrão independentes), ρ_G é a correlação de ativos entre contrapartes de setores *distintos* e $\rho_S \geq \rho_G$ é a correlação de ativos dentro do *mesmo* setor. O default continua ocorrendo quando $Y_n < \Phi^{-1}(p_n)$, e a variante t-Student é obtida como antes, multiplicando Y_n pelo choque radial $\sqrt{\nu/\bar{V}}$. A calibração espelha a do modelo de um fator: o usuário define dois alvos de correlação de *default* — intra-setor e inter-setor — e o aplicativo resolve numericamente ρ_S e ρ_G por meio de (10).

Além das medidas de risco usuais, o modelo multifatorial habilita o relatório de *contribuições por setor*: as contribuições de ES por contraparte são agregadas pelo setor de cada nome, e a razão entre a participação do setor no ES e a sua participação na exposição identifica os setores que concentram proporcionalmente mais cauda do que carteira — a métrica natural para calibrar limites setoriais. Carteiras sem a coluna **setor** seguem funcionando normalmente no modo de um fator.

3.7 Migração de ratings, ECL e horizonte multiperíodo

O insumo deste módulo é a matriz de transição anual P , de dimensão $(K + 1) \times (K + 1)$, em que $P_{r,s}$ é a probabilidade de uma contraparte de rating r terminar o ano no estado s ; os K primeiros estados são os ratings, do melhor para o pior, e o último é o default (D), absorvente ($P_{D,D} = 1$). A matriz é carregada em CSV, validada (linhas somando um, não negatividade, absorção do default) e a coluna **rating** da carteira, meramente descritiva nos demais módulos, passa a mapear cada contraparte à sua linha.

Estrutura a termo de PD. A probabilidade acumulada de default até o ano t de um rating r é a entrada de default da t -ésima potência da matriz,

$$\text{PD}_r^{\text{acum}}(t) = [P^t]_{r,D}, \quad \text{PD}_r^{\text{marg}}(t) = \text{PD}_r^{\text{acum}}(t) - \text{PD}_r^{\text{acum}}(t-1), \quad (19)$$

em que $\text{PD}_r^{\text{marg}}(t)$ é a probabilidade de o default ocorrer exatamente no ano t . Toda a dinâmica plurianual — inclusive o efeito de passar por rebaixamentos intermediários antes do default — fica embutida nas potências de P .

ECL 12 meses vs. *lifetime*. Com a estrutura a termo, a perda esperada de crédito da contraparte n , de rating r_n , severidade c_n e prazo τ_n , é

$$\text{ECL}_n^{12m} = \text{PD}_{r_n}^{\text{acum}}(1) c_n, \quad \text{ECL}_n^{\text{life}} = \sum_{t=1}^{\lceil \tau_n \rceil} \text{PD}_{r_n}^{\text{marg}}(t) f_{n,t} c_n (1+i)^{-t}, \quad (20)$$

em que i é a taxa de desconto, $f_{n,t} \in (0, 1]$ é a fração do ano t coberta pelo prazo residual (igual a um, exceto no último ano) e a EAD é mantida constante ao longo da vida — premissa simplificadora explícita, na ausência de cronograma de amortização no padrão de dados. A classificação de estágios segue uma regra objetiva de deterioração significativa: a contraparte vai a estágio 2 quando seu rating atual está dois ou mais degraus (*notches*) abaixo do rating de origem (coluna **rating_origem**); a provisão é o ECL^{12m} no estágio 1 e o ECL^{life} no estágio 2 — a mecânica central de IFRS 9 e da Resolução CMN 4.966.

Simulação multiperíodo. Para capital de horizonte longo, a regra binária de default do modelo *threshold* generaliza-se para uma *escada de limiares*: ordenando os estados do default (banda inferior) ao melhor rating (banda superior), os cortes da linha r são

$$b_{r,s} = \Phi^{-1}\left(\sum_{j \leq s} P_{r,j}\right), \quad (21)$$

em que a soma percorre os estados do default até s nessa ordem — exatamente a construção do **pMap** de Bolder. A cada ano, o estado latente Y_n é sorteado com a *mesma* estrutura de dependência dos demais módulos (um fator ou multifatorial setorial, equações (9) e (18)), e a contraparte migra para o estado da banda em que Y_n cair: default se $Y_n < b_{r,D}$, rebaixamentos e melhoras nas bandas seguintes. O default é absorvente, a perda c_n é descontada ao ano em que ocorre, e a distribuição das perdas acumuladas a valor presente em T anos entrega VaR e ES multiperíodo. A simulação é executada em blocos para controle de memória.

Multiperíodo em carteiras agregadas. Para a carteira *pooled* da Seção 3.8, o estado de cada bucket deixa de ser um rating e passa a ser um *vetor de frações por rating*, que evolui ano a ano pela *matriz de transição condicional* ao cenário sistemático: as probabilidades de banda da escada (21), avaliadas no fator sorteado do ano,

$$P_{r,s}^{\text{cond}}(Z) = \Phi\left(\frac{b_{r,s}-Z}{\sqrt{1-\rho_S}}\right) - \Phi\left(\frac{b_{r,s-1}-Z}{\sqrt{1-\rho_S}}\right), \quad f_g^{(t)} = f_g^{(t-1)} P^{\text{cond}}(Z_{s(g)}^{(t)}), \quad (22)$$

em que $Z_{s(g)}^{(t)}$ é a parte sistemática (global + setorial) do ano t para o setor do bucket e $f_g^{(t)}$ é o vetor de frações do bucket g . É a mesma lei dos grandes números do motor de um período: dentro do pool, a fração que migra converge para a probabilidade condicional, e o incremento da fração em default, multiplicado por C_g e descontado, é a perda do ano. As grandes exposições ($n = 1$) mantêm trajetória *discreta*, compartilhando os mesmos fatores — de modo que o cenário que rebaixa o pool também rebaixa o nome grande do mesmo setor. A perda esperada simulada reproduz a esperança analítica da matriz descontada (verificação de sanidade com desvio inferior a 0,1% no estudo de caso).

3.8 Camada de agregação e o motor *pooled*

Bases analíticas reais têm centenas de milhares ou milhões de contratos, e a matriz de simulação $M \times N$ do Monte Carlo torna-se proibitiva nessa escala. O CreditLens resolve o problema com uma camada de agregação que converte a base analítica — contrato a contrato, no mesmo padrão de colunas — numa carteira compacta de duas partes, preservando o que importa para a cauda.

Grandes exposições e grupos homogêneos. Os contratos acima de um corte de materialidade (por valor e/ou os K maiores) passam *individualmente*, preservando a informação de concentração de nomes que, como visto na Seção 4.7, domina a cauda. O resíduo pulverizado é agregado por grupo homogêneo (GH) $\times$ setor — o GH pode vir de uma coluna própria do usuário ou, na sua ausência, da banda de rating —, com parâmetros ponderados de modo a preservar a perda esperada *exatamente*:

$$C_g = \sum_{i \in g} \text{EAD}_i \text{LGD}_i, \quad p_g = \frac{\sum_{i \in g} p_i \text{EAD}_i \text{LGD}_i}{C_g}, \quad n_g = \#\{i \in g\}, \quad (23)$$

em que C_g é a severidade total do bucket g , p_g a sua PD ponderada por severidade e n_g o número de contratos — atributo carregado pela coluna `n_contratos`. Com esses pesos, $\text{EL}_g = p_g C_g = \sum_{i \in g} p_i \text{EAD}_i \text{LGD}_i$, e a EL da carteira agregada coincide ao centavo com a analítica (teste de sanidade reportado na agregação).

O motor *pooled*. O ponto crítico é o bucket *não* virar “uma contraparte gigante” — tratá-lo assim inflaria o risco idiossincrático de forma espúria. Condicional ao(s) fator(es) sistemático(s), os defaults dentro do bucket são independentes com probabilidade condicional $p_g(\cdot)$ (as mesmas expressões de limiar das Seções anteriores, com a parte sistemática de um fator ou de dois níveis), e a perda do bucket é gerada em três regimes:

$$L_g = \begin{cases} C_g \cdot \mathbb{I}\{\text{default}\}, & n_g = 1 \quad (\text{grande exposição}), \\ \frac{C_g}{n_g} \cdot \text{Binomial}(n_g, p_g(\cdot)), & 1 < n_g \leq 50, \\ C_g \cdot p_g(\cdot), & n_g > 50 \quad (\text{large pool}), \end{cases} \quad (24)$$

em que o terceiro regime é a aproximação de carteira grande de Vasicek: pela lei dos grandes números, a fração em default do pool converge para a probabilidade condicional, e o risco idiossincrático interno desaparece. A dimensão efetiva da simulação passa a ser o número de linhas agregadas — não de contratos — e uma base de milhões de linhas roda em segundos. O ajuste de granularidade acompanha a lógica: no somatório de c^2 da fórmula de Gordy–Lütkebohmert, o bucket homogêneo contribui com C_g^2/n_g , de modo que pools grandes têm GA desprezível — como devem, já que sua granularidade interna é quase perfeita — e o ajuste passa a medir essencialmente as grandes exposições nominais.

O cuidado de Jensen. A PD ponderada preserva a EL, que é linear; as funções de capital, porém, são não lineares em PD, e um GH que misture PDs muito dispersas introduz viés (desigualdade de Jensen). Por isso o relatório de agregação reporta o coeficiente de variação de PD dentro de cada bucket: valores altos ($CV > 0,5$) sinalizam que a formação dos GHs deve ser refinada — o mesmo requisito de homogeneidade que a CMN 4.966 impõe aos grupos homogêneos de provisão.

3.9 Estratégia de calibração comum

Para que as caudas sejam comparáveis, todos os modelos com dependência são ancorados no mesmo par $(\bar{p}, \rho_D^{\text{alvo}})$ — a PD média ponderada por exposição e a correlação de default alvo: a beta-binomial pelo método dos momentos, o *threshold* gaussiano/t por meio de (10), e o ASRF herdando o ρ calibrado. As diferenças remanescentes entre os modelos refletem, portanto, *forma distributiva* — em particular a presença ou não de dependência de cauda — e não níveis distintos de correlação. O CreditRisk⁺ é parametrizado diretamente por (w, v) , expostos ao usuário na interface. O IRB, por construção regulatória, usa $\rho_B(p) \in [12\%, 24\%]$ — tipicamente acima do ρ_D implícito em carteiras corporativas — e por isso não é ancorado no alvo comum.

4 Estudo de caso 1: carteira granular (250 contrapartes)

4.1 A carteira

A base de teste contém $N = 250$ contrapartes corporativas distribuídas em oito graus de rating (AAA a C), com exposições log-normais (cauda pesada, como é típico do crédito corporativo), LGD atribuída por classe de garantia e prazos uniformes em $[1, 5]$ anos. A Tabela 1 resume o perfil.

Tabela 1: Perfil da carteira de teste.

Métrica	Valor
Contrapartes (N)	250
EAD total	10 000,0
Exposição líquida total ($\sum_n c_n$)	4 402,7
PD média simples	2,36%
PD média ponderada por exposição ($\bar{p}$)	2,16%
LGD média	46,0%
Perda esperada ($\mathbb{E}[L]$)	95,0 (2,16% da exposição líquida)
HHI	0,0112
Número efetivo de nomes	88,9
Maior exposição individual	3,39%
Dez maiores exposições	24,4%

Com HHI de 0,0112, a carteira equivale a apenas 89 nomes de igual tamanho — uma concentração relevante, que o ajuste de granularidade da Seção 4.4 quantificará em capital.

4.2 Parâmetros e calibração

A análise utilizou $M = 100\,000$ simulações, semente 42, alvo de correlação de default $\rho_D^{\text{alvo}} = 5\%$, $\nu = 10$ graus de liberdade na variante t e $(w, v) = (0,35; 1,2)$ no CreditRisk⁺. A calibração produziu, para a beta-binomial, $(a, b) = (0,410; 18,590)$ — note que $a < 1$ implica densidade explosiva na origem com cauda direita longa — e, para o modelo *threshold*, correlação de ativos $\rho = 24,66\%$. Este último número merece registro: para gerar módicos 5% de correlação de *default* numa carteira com $\bar{p} = 2,16\%$, são necessários quase 25% de correlação de *ativos*. É

a não linearidade de (10) em ação — e a razão pela qual as duas noções de correlação jamais devem ser confundidas.

4.3 Medidas de risco por modelo

Tabela 2: Medidas de risco por modelo (unidades monetárias; $M = 100\,000$). Entre parênteses, o VaR 99,90% em percentual da exposição líquida.

Modelo	EL	UL	VaR _{99%}	ES _{99%}	VaR _{99,9%}	ES _{99,9%}
Binomial indep. (analítico, homog.)	95,0	40,5	192,0	192,4	233,9 (5,3%)	—
Binomial independente (MC)	94,9	60,5	279,3	320,3	371,2 (8,4%)	407,3
CreditRisk ⁺ (1 fator)	89,1	64,9	295,8	337,7	396,2 (9,0%)	427,5
Threshold Gaussiano 1F	95,2	120,6	563,6	727,9	927,1 (21,1%)	1 116,7
Beta-binomial (<i>mixture</i>)	94,9	157,9	735,7	930,4	1 187,5 (27,0%)	1 332,1
ASRF (analítico)	95,0	—	701,0	944,9	1 265,6 (28,7%)	1 520,5
Threshold t-Student ($\nu = 10$)	95,2	147,5	707,6	1 000,0	1 372,8 (31,2%)	1 731,4
Threshold Gaussiano multifat.	95,4	107,3	495,8	620,6	784,7 (17,8%)	902,9
Threshold t-Student multifat. ($\nu = 10$)	95,2	135,8	655,1	901,4	1 246,9 (28,3%)	1 493,7
IRB Basileia ($K^* + E[L]$)	95,0	—	—	—	805,2 (18,3%)	—

A Tabela 2 contém a mensagem central do exercício, que pode ser lida em três camadas. A primeira é a *verificação de consistência*: a perda esperada é de aproximadamente 95 em todos os modelos (o desvio do CreditRisk⁺, 89,1, decorre da aproximação de Poisson, que admite eventos múltiplos e não é recalibrada em nível). Ora, se modelos calibrados ao mesmo primeiro momento chegam a diferir por um fator de quase seis vezes no VaR 99,90% — de 234 a 1 373 —, fica demonstrado empiricamente que o risco de crédito de uma carteira reside, essencialmente, na estrutura de dependência entre os defaults, e não nas PDs individuais.

A segunda camada é a hierarquia das caudas, que segue exatamente a teoria: independente < CreditRisk⁺ (com os w, v adotados) < *threshold* gaussiano < beta-binomial $\approx$ ASRF < t-Student. A variante t, mantida a *mesma* correlação de ativos do modelo gaussiano, entrega VaR 99,9% 48% maior e ES 99,9% 55% maior — o preço da dependência de cauda, que a cópula gaussiana, por construção, não captura.

A terceira camada é o ASRF (1 265,6) acima do *threshold* gaussiano simulado (927,1), apesar de descrever uma carteira *mais* diversificada. A aparente contradição é instrutiva: o ASRF usa a aproximação homogênea com $\bar{p}$ ponderado por exposição e, numa carteira heterogênea — em que os nomes de pior rating não são os de maior exposição —, essa homogeneização é conservadora, efeito discutido pelo próprio Bolder no capítulo 4.

4.4 Capital regulatório IRB

Aplicando (13) contraparte a contraparte, o capital IRB da carteira é

$$K^* = \sum_n c_n K_n = 710,1 \quad (16,13\% \text{ da exposição líquida}), \quad \text{RWA} = 12,5 K^* = 8\,876,7.$$

O ajuste de granularidade adiciona GA = 91,8, elevando o requerimento a 801,9 — um acréscimo de 12,9% sobre o capital IRB puro, coerente com os 89 nomes efetivos da carteira. Somado à perda esperada para permitir comparação com os VaRs totais dos modelos internos, o IRB+EL de 805,2 (18,3%) situa-se entre o *threshold* gaussiano calibrado a $\rho_D = 5\%$ e os modelos de cauda pesada. A leitura é direta: a correlação regulatória $\rho_B \in [12\%, 24\%]$ é deliberadamente conservadora frente a calibrações internas típicas, mas a cópula gaussiana subjacente ao IRB não carrega dependência de cauda — e o t-Student o ultrapassa com folga.




Figura 1: Distribuição de perdas sob cinco modelos: corpo até o quantil de 99,9% (esq.) e cauda em escala logarítmica (dir., linha pontilhada no nível de 99,90%). No corpo, as distribuições são quase indistinguíveis; na cauda, separam-se por fator de até quatro vezes — ilustrando por que a escolha da estrutura de dependência domina qualquer refinamento de PD individual. Note os pares um fator vs. multifatorial (azul/verde e vermelho/laranja): a estrutura setorial desloca a cauda para dentro em ambas as famílias.




Figura 2: VaR 99,90% por modelo, em percentual da exposição líquida.

4.5 Contribuições de risco

A Tabela 3 e a Figura 3 revelam a anatomia da cauda. A contraparte CP0173 — rating CCC com a segunda maior exposição da carteira — responde sozinha por 11,8% do ES 99%: a combinação multiplicativa de PD alta com exposição alta que a alocação de capital deve penalizar no *pricing*. Observe, porém, CP0078 e CP0139: ratings BBB, PDs abaixo de 65 pontos-base e, ainda assim, entre os seis maiores contribuintes — puro efeito de tamanho (cerca de 300 de exposição cada). A lição operacional é clara: a gestão de limites por rating, isoladamente, não controla a cauda; a métrica correta de concentração é a contribuição de risco, não a PD. Os dez nomes da tabela somam cerca de 39% do ES total, contra 24% da exposição — a cauda é mais concentrada do que a própria carteira.

4.6 Análise multifatorial setorial

A carteira de teste distribui-se em oito setores, com HHI setorial de 0,1364 — o equivalente a 7,3 setores efetivos, uma diversificação setorial razoável, ainda que desigual: Energia detém

Tabela 3: Dez maiores contribuições ao ES 99% (decomposição MC, *threshold* gaussiano, $S = 10$).

Contraparte	Rating	Exposição	PD	Contrib. ES	% do ES
CP0173	CCC	292,3	8,99%	85,7	11,8%
CP0156	BB	217,1	2,34%	40,7	5,6%
CP0051	C	47,5	24,41%	26,4	3,6%
CP0092	B	118,1	6,33%	21,4	3,0%
CP0078	BBB	266,8	0,63%	21,2	2,9%
CP0139	BBB	301,9	0,58%	19,1	2,6%
CP0103	C	44,3	37,05%	19,1	2,6%
CP0228	B	87,3	5,38%	16,1	2,2%
CP0036	B	109,2	3,67%	15,9	2,2%
CP0245	C	101,4	15,55%	15,5	2,1%




Figura 3: Quinze maiores contribuições ao ES 99% (percentual do total).

17,5% da exposição líquida, enquanto Agro e Petroquímica, somados, não chegam a 13%. Com alvos de correlação de default de 8% intra-setor e 3% inter-setor, a calibração numérica via (10) produziu correlações de *ativos* de $\rho_S = 33,67\%$ e $\rho_G = 17,02\%$ — novamente a não linearidade em ação: dobrar ou triplicar a correlação de default exige quase o dobro da correlação de ativos.

O efeito diversificação. A Tabela 4 compara, nível a nível, o modelo de um fator (calibrado a $\rho_D = 5\%$ uniforme) com o multifatorial. O padrão é consistente nas duas famílias: o multifatorial entrega medidas menores, e a redução *cresce com o nível de confiança* — de cerca de -6% no VaR 95% a -15% no VaR 99,90% do modelo gaussiano (-19% no ES). A razão é estrutural. No modelo de um fator, todos os 31 125 pares de contrapartes carregam a mesma correlação de default de 5%; no multifatorial, apenas os pares *dentro* de um mesmo setor (cerca de 13% dos pares) operam ao alvo intra de 8%, enquanto a grande maioria — pares entre setores distintos — opera a apenas 3%.² A correlação média da carteira cai, e cai justamente onde

²A conta é verificável: com $N = 250$, o total de pares é $\binom{250}{2} = \frac{250 \times 249}{2} = 31\,125$. Os pares intra-setor são $\sum_s \binom{n_s}{2}$ sobre os oito setores; com os tamanhos da carteira de teste (37, 36, 33, 33, 32, 31, 24 e 24 nomes), $666 + 630 + 528 + 528 + 496 + 465 + 276 + 276 = 3\,865$ pares, ou 12,4% do total. A correlação de default média da carteira multifatorial fica, portanto, em torno de $0,124 \times 8\% + 0,876 \times 3\% \approx 3,6\%$ — abaixo dos 5% uniformes do modelo de um fator. Note que a fração intra-setor cresce quadraticamente com a concentração setorial (é o

mais importa: nos cenários extremos, em que o fator global sozinho não basta para derrubar simultaneamente nomes de setores diferentes. A estrutura setorial, portanto, *revela um benefício de diversificação que o fator único, ao aplicar 5% indistintamente, não consegue distinguir* — e a Figura 4 mostra que o efeito se preserva, em menor grau (−9% no VaR 99,9%), mesmo sob a dependência de cauda da variante t.

Tabela 4: Um fator vs. multifatorial setorial: VaR e ES por nível de confiança (unidades monetárias; variação percentual do multifatorial sobre o um fator).

Nível α	Gaussiano				t-Student ($\nu = 10$)			
	1 fator	Multif.	Δ VaR	Δ ES	1 fator	Multif.	Δ VaR	Δ ES
95%	329,3	309,1	−6,1%	−10,9%	354,8	340,6	−4,0%	−6,9%
99%	563,6	495,8	−12,0%	−14,7%	707,6	655,1	−7,4%	−9,9%
99,9%	927,1	784,7	−15,4%	−19,1%	1 372,8	1 246,9	−9,2%	−13,7%
99,97%	1 129,9	959,6	−15,1%	−24,0%	1 822,2	1 592,0	−12,6%	−18,8%




Figura 4: VaR em percentual da exposição líquida, um fator vs. multifatorial, nas famílias gaussiana (esq.) e t-Student (dir.). Os rótulos indicam a variação percentual. O benefício de diversificação setorial cresce com o nível de confiança e persiste sob dependência de cauda.

Há uma leitura de gestão importante aqui: o resultado *não* diz que o multifatorial “economiza capital” por construção. Ele diz que, *dada esta carteira bem espalhada em oito setores*, a premissa de correlação uniforme do fator único é conservadora. Numa carteira concentrada em poucos setores a comparação se inverteria — os pares intra-setor a 8% passariam a dominar — e é exatamente essa sensibilidade à composição setorial que o modelo de um fator é incapaz de exhibir.

4.7 Contribuições por setor: exposição, provisão e cauda

A Tabela 5 coloca lado a lado, para cada setor, as três participações que uma mesa de crédito precisa distinguir: na *exposição* (quanto do balanço está ali), na *perda esperada* (quanto da provisão o setor consome) e na *cauda* (quanto do capital econômico o setor exige). A Figura 5 visualiza o contraste, e três perfis setoriais emergem com nitidez:

Setor de provisão: Serviços. Com 12,6% da exposição, Serviços consome 25,1% da perda esperada da carteira — o dobro da sua participação — mas apenas 15,8% da cauda. O setor

HHI setorial agindo sobre os pares): numa carteira concentrada em poucos setores, a média se aproximaria do alvo intra e a comparação poderia se inverter.

Tabela 5: Decomposição setorial completa (*threshold* gaussiano multifatorial; contribuições ao ES 99%, $S = 10$). Participações em percentual do total da carteira; razão = contribuição ao ES $\div$ exposição.

Setor	Nomes	Exposição	Exp. (%)	EL	EL (%)	ES (%)	Razão
Indústria	37	548,2	12,5	17,3	18,2	20,6	1,65
Energia	24	772,1	17,5	13,4	14,1	20,5	1,17
Serviços	36	556,3	12,6	23,8	25,1	15,8	1,25
Varejo	33	652,8	14,8	9,1	9,6	12,6	0,85
Construção	33	655,4	14,9	13,4	14,1	11,6	0,78
Logística	31	646,1	14,7	5,6	5,9	9,5	0,65
Agro	24	254,4	5,8	8,3	8,7	5,1	0,89
Petroquímica	32	317,3	7,2	4,2	4,4	4,3	0,60
Total	250	4 402,7	100	95,0	100	100	1,00

abriga nomes de PD alta e porte moderado (a contraparte CP0051, rating C com PD de 24,4%, é o caso extremo): inadimplência *frequente*, que corrói resultado via provisão, mas cujo tamanho individual não tem força para produzir os cenários catastróficos que definem o capital.

Setor de cauda: Energia. O espelho invertido. Com a *maior* exposição setorial (17,5%), Energia consome perda esperada *abaixo* da sua participação (14,1%) — os nomes são majoritariamente de boa qualidade — mas responde por 20,5% do ES. O risco aqui não é a frequência de default, e sim o *porte*: o setor concentra as maiores exposições individuais da carteira (CP0038 com 211 e CP0039 com 97 de EAD, por exemplo), e basta o cenário sistemático adverso alcançá-las para a perda saltar. É risco de capital, não de provisão.

Setor misto: Indústria. O pior dos dois mundos, e o líder disparado da razão risco/exposição (1,65): com 12,5% da exposição, o setor pesa 18,2% na provisão e 20,6% na cauda. A explicação está na sua composição: Indústria combina o maior número de nomes (37) com a coexistência de exposições grandes e ratings fracos — CP0173 (CCC, exposição 292,3, o maior contribuinte individual da carteira) e CP0036 (B, 109,2) pertencem ao setor. Concentração de porte e de qualidade no mesmo lugar.

Na outra ponta, Logística e Petroquímica são os setores mais “baratos” em risco por unidade de exposição (razões de 0,65 e 0,60): carregam 14,7% e 7,2% do balanço a custo desproporcionalmente baixo de provisão e capital. Em linguagem de gestão de limites, são os setores com espaço para crescer; Indústria e Energia são os candidatos naturais a teto ou a exigência de garantias adicionais — e a distinção entre os perfis importa para o *tipo* de mitigação: em Serviços (provisão), a alavanca é *pricing* e seleção; em Energia (cauda), é limite de concentração individual; em Indústria, ambas.

Por fim, vale registrar a consistência entre níveis de análise: os dez maiores contribuintes individuais da Tabela 3 concentram-se exatamente nos três setores de razão mais alta — CP0173, CP0036 e CP0228 em Indústria; CP0156 e CP0078 em Energia; CP0051 em Serviços —, de modo que a leitura setorial e a leitura por nome contam a mesma história em granularidades diferentes. É essa coerência que permite usar as duas visões em conjunto: o setor define *onde* apertar limites; a contribuição individual define *quem*.

4.8 Migração, ECL e capital multiperíodo

A matriz de exemplo (disponível em `templates/matriz_migracao_modelo.csv`) é diagonal-dominante, com massa concentrada nos estados vizinhos e coluna de default calibrada às PDs centrais dos oito graus da carteira de teste (de 3 pontos-base em AAA a 25% em C). A Figura 6




Figura 5: Participação de cada setor na exposição líquida, na perda esperada e na cauda (ES 99%). A divergência entre as três barras de um mesmo setor revela o seu perfil de risco: EL acima da exposição indica frequência de default (provisão); ES acima da exposição indica concentração de porte (capital).

(painel esquerdo) mostra a estrutura a termo resultante: em escala logarítmica, as PDs acumuladas dos graus de investimento *aceleram* com o horizonte — um AAA praticamente não defaulta no ano 1, mas acumula risco à medida que a cadeia o deixa migrar para graus piores antes de defaultar —, enquanto os graus especulativos, já próximos do default, crescem de forma quase linear. É o efeito de segunda ordem que nenhuma PD de 12 meses captura.

Aplicando (20) com desconto de 10% a.a., o ECL^{12m} total é de 84,3 — próximo, mas não idêntico, à perda esperada de 95,0 da Tabela 1: a diferença decorre de a matriz operar com a PD *do grau*, enquanto a coluna *pd* da carteira carrega dispersão idiossincrática em torno do central de cada grau. O ECL^{life} total é de 266,9 — **3,17 vezes o de 12 meses** —, concentrado nos graus especulativos: B (63,1), CCC (63,0) e C (59,0) respondem juntos por 69% do *lifetime*, contra 75% do 12 meses; os graus de investimento, irrelevantes no horizonte curto, passam a pesar via acumulação plurianual (painel direito da Figura 6). Na classificação de estágios, 20 contrapartes apresentam deterioração de dois ou mais *notches* frente à originação e migram a estágio 2; a provisão por estágio resultante é de 94,9 — 13% acima do ECL^{12m} puro, o custo da regra de deterioração significativa nesta carteira.




Figura 6: Esquerda: estrutura a termo de PD acumulada por rating (escala logarítmica), obtida das potências da matriz de transição. Direita: ECL 12 meses vs. *lifetime* por grau de rating (desconto de 10% a.a.). A razão *lifetime*/12m da carteira é de 3,17.

Na simulação multiperíodo de 5 anos ($M = 100\,000$, blocos de 10 000, estrutura multifatorial

setorial com os ρ calibrados da Seção 4.6, desconto de 10% a.a.), a fração da carteira em default é estável em torno de 2,3% ao ano — coerente com a PD média —, e a distribuição das perdas descontadas acumuladas entrega $\mathbb{E}[L] = 354,1$, $UL = 186,7$, $VaR_{99,9\%} = 1\,223,4$ e $ES_{99,9\%} = 1\,340,5$. A comparação com o horizonte anual é instrutiva: o VaR 99,9% de cinco anos (27,8% da exposição líquida) é apenas 56% maior que o de um ano do mesmo modelo multifatorial (784,7), e não cinco vezes — a diversificação *temporal* (os cenários sistemáticos adversos não se repetem todos os anos) e o desconto comprimem a cauda acumulada. É precisamente o risco que o ajuste de maturidade do IRB aproxima por fórmula: aqui ele aparece medido por simulação, com a migração explícita.

5 Estudo de caso 2: alta granularidade (300 mil contratos)

O segundo estudo de caso reproduz, ponta a ponta, uma execução real no aplicativo sobre a base analítica de demonstração de 300 000 contratos — varejo pulverizado combinado a 300 operações *corporate* de porte duas ordens de grandeza maior, concentradas em poucos setores — exercitando a camada de agregação (Seção 3.8), o motor *pooled* e o módulo de migração em modo agregado. Parâmetros: $M = 100\,000$, semente 42, alvos de correlação de default de 5% (um fator), 8% intra-setor e 3% inter-setor, $\nu = 10$, matriz de transição de exemplo e desconto de 10% a.a.

5.1 Fluxo de uso

No aplicativo, o ponto de entrada é o carregador “*Base analítica (CSV)*” da seção de carga (ou a opção de gerar a base de demonstração), com o teto de grandes exposições configurável. A agregação roda automaticamente e apresenta o relatório de qualidade — EL analítica vs. agregada, exposição nos grandes e CV de PD por bucket, com alerta acima de 0,5 —, e todas as abas passam a operar sobre a carteira agregada. Para bases maiores que o limite de upload (20 MB, ≈ 350 –400 mil linhas) ou dados sensíveis, o fluxo local por linha de comando:

```
python run_analysis.py base.csv -analitica -max-grandes 200 -M 100000 \
  -migracao matriz.csv -horizonte 5 -taxa-desconto 0.10 -out saida/
```

salva também a `carteira_agregada.csv`, que pode ser carregada no aplicativo pelo carregador padrão (o modo *pooled* é detectado pela coluna `n_contratos`) — o fluxo híbrido: agrega localmente, analisa na nuvem.

5.2 Agregação

A base foi reduzida a **264 linhas** — 200 grandes exposições e 64 buckets $GH \times \text{setor}$ — em segundos, com **perda esperada de 1 227,2 preservada exatamente** (diferença de 0,0000% entre a base analítica e a agregada), exposição líquida total de 45 082,5 e CV de PD intra-bucket dentro do padrão de homogeneidade. A calibração produziu $\rho = 22,67\%$ de correlação de ativos no modelo de um fator e $(\rho_S, \rho_G) = (31,48\%, 15,36\%)$ no multifatorial, para $\bar{p} = 2,72\%$.

5.3 Capital: o portfólio de modelos no motor *pooled*

A Tabela 6 e as Figuras 7 e 8 exibem a assinatura da alta granularidade, ausente por construção numa carteira de poucas centenas de nomes. A primeira leitura é a *morte do risco idiossincrático*: o modelo binomial independente colapsa para UL de 67,7 contra 1 279,9 do *threshold* gaussiano — dezenove vezes menos — porque a lei dos grandes números, agindo sobre 300 mil contratos, elimina praticamente toda a variabilidade não sistemática. O risco remanescente é inteiramente ciclo: a premissa assintótica do ASRF materializada empiricamente, e a razão pela qual capital de carteiras pulverizadas é uma discussão sobre correlação com o fator sistemático,

Tabela 6: Estudo de caso 2 — medidas de risco da carteira agregada (motor *pooled*, $M = 100\,000$; unidades monetárias; entre parênteses, percentual da exposição líquida).

Modelo	EL	UL	VaR _{99%}	VaR _{99,9%}	ES _{99,9%}
Binomial independente	1 226,8	67,7	1 413,0	1 490,9 (3,3%)	1 520,4
Threshold Gaussiano 1F	1 224,2	1 279,9	6 162,3	10 036,0 (22,3%)	11 742,9
Threshold t-Student 1F ($\nu = 10$)	1 223,7	1 639,3	8 158,4	15 013,5 (33,3%)	18 403,2
Threshold Gaussiano multifatorial	1 227,5	1 112,1	5 368,9	8 221,1 (18,2%)	9 706,4
Threshold t multifatorial ($\nu = 10$)	1 233,4	1 490,3	7 374,1	12 737,8 (28,3%)	15 183,4
ASRF (analítico)	1 227,2	—	7 982,0	13 688,8 (30,4%)	16 207,2
IRB Basileia ($K^* + \mathbb{E}[L]$)	1 227,2	—	—	9 553,7 (21,2%)	—

não sobre PDs individuais. A segunda leitura é a coerência do ajuste de granularidade: o capital IRB soma 8 326,5 (18,47% da exposição líquida; RWA equivalente de 104 081) com **GA de apenas 9,5** — ante 91,8 na carteira de 250 nomes — porque os pools têm granularidade interna quase perfeita ($C_g^2/n_g \rightarrow 0$) e o ajuste passa a medir somente as 200 exposições nominais, exatamente como deve. E a diversificação setorial segue material: o multifatorial reduz o VaR 99,9% gaussiano em 18% ($10\,036 \rightarrow 8\,221$).




Figura 7: Estudo de caso 2 — distribuição de perdas da carteira agregada. A curva do modelo independente, quase degenerada em torno da EL, ilustra a eliminação do risco idiossincrático pela lei dos grandes números; toda a dispersão remanescente é risco sistemático.

5.4 Setores

A decomposição setorial (Figura 9) mostra razões risco/exposição entre 0,83 (Petroquímica) e 1,09 (Varejo): nesta base de demonstração, com composição de rating parecida entre setores, a cauda distribui-se quase proporcionalmente à exposição — Varejo lidera por concentrar a maior massa de contratos nos graus especulativos. Numa carteira real, é exatamente esta decomposição que revelaria assimetrias setoriais relevantes, computáveis — com a camada de agregação — sobre milhões de contratos.

5.5 Migração: ECL e capital multiperíodo

Com a matriz de transição de exemplo e desconto de 10% a.a., o ECL de 12 meses da carteira agregada é de 1 061,6 e o *lifetime*, de 3 416,2 — **razão de 3,22** —, com os graus especulativos dominando ambos (Figura 10). Vale registrar a reconciliação entre as duas óticas: o ECL 12m (1 061,6) difere da EL da carteira (1 227,2) porque a matriz opera com a PD *do grau*, enquanto




Figura 8: Estudo de caso 2 — VaR 99,90% por modelo, em percentual da exposição líquida, incluindo o capital multiperíodo de cinco anos.




Figura 9: Estudo de caso 2 — participação setorial na exposição e na cauda (contribuições ao ES 99%, modelo multifatorial *pooled*).

a EL usa a PD ponderada de cada bucket — a distância entre os dois números mede, na prática, a dispersão de PD dentro dos graus.

No capital multiperíodo — cinco anos, estrutura multifatorial setorial, matriz condicional da equação (22) —, a perda descontada acumulada tem $\mathbb{E}[L] = 4\,600,2$ (que reproduz a esperança analítica da matriz descontada com desvio inferior a 0,5%, a verificação de sanidade do motor), $\text{VaR}_{99,9\%} = 13\,475,5$ (29,9% da exposição líquida) e $\text{ES}_{99,9\%} = 14\,793,4$. Duas leituras fecham o caso: o VaR de cinco anos é 1,64 vez o de um ano do mesmo modelo — não cinco vezes, pela diversificação *temporal* e pelo desconto, o risco que o ajuste de maturidade do IRB aproxima por fórmula e que aqui aparece medido por simulação — e a fração de contratos em default cresce de 2,56% para 2,72% ao ano ao longo do horizonte: a deriva de migração da carteira, invisível a qualquer análise de 12 meses.

5.6 Boas práticas para bases analíticas

Quatro recomendações operacionais fecham o fluxo. *Grupos homogêneos*: se a base tiver segmentação própria, informe-a na coluna *gh* (prioritária sobre o rating) e vigie o CV de PD por bucket — acima de 0,5, refine. *Corte de grandes exposições*: o parâmetro é computacionalmente




Figura 10: Estudo de caso 2 — esquerda: estrutura a termo de PD acumulada por rating (potências da matriz de transição, escala logarítmica); direita: ECL 12 meses vs. *lifetime* por grau na carteira agregada (desconto de 10% a.a.).

barato; na dúvida sobre nomes materiais no limiar, suba o teto. *Ambiente*: o motor *pooled* opera em blocos e consumiu ~540 MB neste estudo de caso, com folga no plano gratuito de nuvem; carteiras reais e confidenciais, porém, devem usar exclusivamente o fluxo local. *Colunas habilitadoras*: **setor** ativa o multifatorial, **rating** mapeia à matriz de migração, **rating_origem** habilita os estágios e **gh** refina a agregação — todas opcionais, com degradação graciosa ao subconjunto aplicável.

6 Limitações e extensões

O CreditLens carrega quatro premissas simplificadoras, cada qual com extensão natural já mapeada na própria biblioteca de Bolder.

A LGD é determinística. A generalização estocástica — severidade sorteada de uma distribuição beta, correlacionada ou não com o ciclo — está implementada na rotina **crPlusOneFactorLGD** e seria o primeiro refinamento em aplicação prudencial, dado o papel conhecido da volatilidade de LGD nas caudas.

A correlação intra-setor é uniforme: todos os setores compartilham o mesmo ρ_S . Cargas setoriais heterogêneas — setores cíclicos mais correlacionados que defensivos — são a generalização direta, na estrutura de **buildAssetCorrelationMatrix** e **getY2r**.

O Monte Carlo é simples. Para quantis muito extremos (99,97% e além) ou carteiras grandes, o capítulo 8 do livro fornece *importance sampling* com deslocamento ótimo de média, capaz de estimar a cauda com uma fração das simulações; as rotinas correspondentes já acompanham a biblioteca.

Na camada de agregação, os buckets são tratados como internamente homogêneos (mesma PD e severidade média por contrato); dispersões intra-bucket relevantes pedem GHs mais finos, e o relatório de CV de PD existe para vigiar essa premissa. A matriz de transição é insumo do usuário, e o ajuste de granularidade usa os parâmetros de volatilidade setorial de referência do livro. As extensões naturais são, respectivamente: estimar a matriz a partir do histórico de ratings da própria carteira, pelos métodos de coorte e de *hazard rate* com intervalos de confiança por *bootstrap* (módulo **markovChain**); estimar a volatilidade setorial a partir dos dados; e evoluir o módulo de migração para o modo *mark-to-market* à la CreditMetrics, que reutilizaria a mesma escada de limiares da Seção 3.7 com revalorização por banda de destino.

Referências

- Bolder, D. J. (2018). *Credit-Risk Modelling: Theoretical Foundations, Diagnostic Tools, Practical Examples, and Numerical Recipes in Python*. Springer. [Referencial teórico e bibliotecas numéricas, github.com/djbolder/credit-risk-modelling, GPL-3.0.]
- Basel Committee on Banking Supervision (2005). *An Explanatory Note on the Basel II IRB Risk Weight Functions*. BIS.
- Gordy, M. B. (2003). A risk-factor model foundation for ratings-based bank capital rules. *Journal of Financial Intermediation*, 12(3), 199–232.
- Gordy, M. B.; Lütkebohmert, E. (2013). Granularity adjustment for regulatory capital assessment. *International Journal of Central Banking*, 9(3), 33–71.
- Vasicek, O. (2002). The distribution of loan portfolio value. *Risk*, 15(12), 160–162.