

CreditLens

Análise Quantitativa de Carteiras de Crédito:
Documentação Metodológica e Estudo de Caso

Walter C. Neto

Baseado em D. J. Bolder, *Credit-Risk Modelling* (Springer, 2018)

Julho de 2026 — versão 0.1

Resumo

O **CreditLens** é um aplicativo de análise de risco de carteiras de crédito construído sobre as bibliotecas numéricas que acompanham o livro *Credit-Risk Modelling: Theoretical Foundations, Diagnostic Tools, Practical Examples, and Numerical Recipes in Python*, de David Jamieson Bolder (Springer, 2018). A partir do upload de uma carteira em padrão CSV definido, o aplicativo estima a distribuição de perdas sob um portfólio de modelos — independentes, *mixture models*, *threshold models* e o modelo regulatório (IRB de Basileia) —, todos calibrados a um alvo comum de correlação de default. São reportados a perda esperada, a volatilidade da perda, o VaR e o *Expected Shortfall* em múltiplos níveis de confiança, o capital regulatório com ajuste de granularidade e a decomposição do risco por contraparte. Este documento apresenta a arquitetura do aplicativo, o arcabouço teórico e matemático de cada modelo tal como implementado, e um estudo de caso completo sobre uma carteira hipotética de 250 contrapartes.

Sumário

1	O aplicativo	2
1.1	Padrão de carteira	2
2	Arcabouço matemático	2
2.1	A perda da carteira	2
2.2	Medidas de risco	2
2.3	Índices de concentração	3
3	O portfólio de modelos	3
3.1	Modelos independentes (cap. 2)	3
3.2	<i>Mixture models</i> — modelos de mistura (cap. 3)	3
3.3	<i>Threshold models</i> — modelos de limiar (cap. 4)	4
3.4	Capital regulatório IRB e ajuste de granularidade (cap. 6)	5
3.5	Contribuições de risco (cap. 7)	5
3.6	Estratégia de calibração comum	6
4	Estudo de caso: carteira hipotética	6
4.1	A carteira	6
4.2	Parâmetros e calibração	6
4.3	Medidas de risco por modelo	7
4.4	Capital regulatório IRB	7
4.5	Contribuições de risco	8

1 O aplicativo

O CreditLens opera em quatro etapas. Na *ingestão*, o usuário carrega um arquivo CSV no padrão da ferramenta; o validador verifica a unicidade dos identificadores e os domínios das variáveis, aplica um piso regulatório de 3 pontos-base às PDs nulas e trunca os prazos ao intervalo $[1, 5]$ anos exigido pelo ajuste de maturidade do IRB. Na *calibração*, os parâmetros de dependência de cada família de modelos são ajustados a um mesmo alvo de correlação de default, o que torna as caudas diretamente comparáveis entre modelos. Na *estimação*, todos os modelos são executados — combinando fórmulas analíticas e simulação de Monte Carlo com M trajetórias — e, na *apresentação*, os resultados são exibidos em tabelas e gráficos interativos, com exportação integral para Excel.

1.1 Padrão de carteira

Cada linha do arquivo CSV representa uma contraparte. As colunas obrigatórias são **id_contraparte** (identificador único da contraparte), **exposicao** (o EAD, *exposure at default* — valor exposto no momento do default, estritamente positivo) e **pd** (probabilidade de default no horizonte de um ano, número em $(0, 1)$). As colunas opcionais são **lgd** (*loss given default* — fração da exposição efetivamente perdida em caso de default, em $(0, 1]$; valor-padrão 1,0), **prazo_anos** (prazo efetivo da operação, em anos, usado no ajuste de maturidade do IRB; valor-padrão 2,5) e as colunas descritivas **rating**, **setor** e **nome**, que não entram nos cálculos e servem à legibilidade dos relatórios. Seguindo a convenção de Bolder, toda a modelagem usa a *severidade*

$$c_n = \text{EAD}_n \times \text{LGD}_n, \quad (1)$$

em que EAD_n é a exposição da contraparte n e LGD_n a sua perda dado o default; c_n é, portanto, a exposição líquida sujeita a perda de cada contraparte, tratada como determinística ao longo de todo o documento.

2 Arcabouço matemático

2.1 A perda da carteira

Considere uma carteira com N contrapartes, em que p_n denota a probabilidade de default da contraparte n e c_n a sua severidade. Definindo o indicador de default $\mathbb{I}_{D_n}$, variável aleatória que vale 1 se a contraparte n entra em default no horizonte de um ano e 0 caso contrário, a perda da carteira é

$$L = \sum_{n=1}^N c_n \mathbb{I}_{D_n}. \quad (2)$$

O que distingue os modelos apresentados neste documento é, essencialmente, a estrutura de dependência imposta aos indicadores $\mathbb{I}_{D_n}$: é ela que governa a espessura da cauda de L e, portanto, o capital econômico da carteira.

2.2 Medidas de risco

Para cada modelo, o CreditLens reporta quatro medidas. A *perda esperada* é $\mathbb{E}[L] = \sum_n p_n c_n$. A *volatilidade da perda* (ou perda não esperada, UL) é $\text{UL} = \sqrt{\text{Var}(L)}$. O *valor em risco* no nível de confiança α ,

$$\text{VaR}_\alpha(L) = \inf\{\ell : \mathbb{P}(L \leq \ell) \geq \alpha\}, \quad (3)$$

é o menor valor de perda ℓ que não é excedido com probabilidade de pelo menos α . O *expected shortfall*,

$$\text{ES}_\alpha(L) = \mathbb{E}[L \mid L \geq \text{VaR}_\alpha(L)], \quad (4)$$

é a perda média nos cenários em que o VaR é atingido ou excedido — por construção, $\text{ES}_\alpha \geq \text{VaR}_\alpha$. As medidas são calculadas nos níveis $\alpha \in \{95\%, 99\%, 99,9\%, 99,97\%\}$. Nas implementações por Monte Carlo, elas são obtidas como estatísticas de ordem da distribuição simulada de L . O capital econômico usual é a parcela inesperada $\text{VaR}_\alpha - \mathbb{E}[L]$.

2.3 Índices de concentração

O resumo da carteira inclui o índice de Herfindahl–Hirschman,

$$\text{HHI} = \sum_{n=1}^N w_n^2, \quad N_{\text{efetivo}} = \text{HHI}^{-1}, \quad (5)$$

em que $w_n = c_n / \sum_k c_k$ é a participação da contraparte n na exposição líquida total. O inverso do HHI é o *número efetivo de nomes*: quantas contrapartes de igual tamanho produziriam a mesma concentração. Esse indicador antecipa a magnitude do ajuste de granularidade da Seção 3.4.

3 O portfólio de modelos

3.1 Modelos independentes (cap. 2)

O ponto de partida — e contrafactual deliberadamente ingênuo — assume defaults independentes entre contrapartes. Na versão analítica homogênea, toma-se $\bar{p}$ (a PD média da carteira ponderada por exposição) e a severidade média $\bar{c}$; o número de defaults K segue então uma distribuição binomial,

$$\mathbb{P}(K = k) = \binom{N}{k} \bar{p}^k (1 - \bar{p})^{N-k}, \quad L \approx \bar{c} K, \quad (6)$$

em que k é o número de defaults observado e os quantis de L são obtidos por interpolação da distribuição acumulada. Na versão de Monte Carlo heterogênea, sorteia-se para cada trajetória m e contraparte n um uniforme $U_{m,n} \sim \mathcal{U}(0, 1)$ e declara-se default quando $U_{m,n} < p_n$, preservando a heterogeneidade de PDs e exposições. Pela lei dos grandes números, a independência elimina quase toda a variabilidade sistemática: a cauda resultante é fina demais para qualquer uso prudencial, e o papel do modelo aqui é servir de piso de referência para os demais.

3.2 Mixture models — modelos de mistura (cap. 3)

Os *mixture models* induzem dependência fazendo as PDs compartilharem um fator aleatório comum. Condicionalmente ao fator, os defaults são independentes; incondicionalmente, tornam-se correlacionados.

Beta-binomial. A probabilidade comum de default é sorteada de $Z \sim \text{Beta}(a, b)$, em que a e b são os parâmetros de forma da distribuição beta; dado o sorteio de Z , cada contraparte entra em default de forma independente com probabilidade Z . A calibração resolve o sistema

$$\mathbb{E}[Z] = \frac{a}{a+b} = \bar{p}, \quad \rho_D = \frac{1}{a+b+1} = \rho_D^{\text{alvo}}, \quad (7)$$

em que ρ_D denota a correlação de default entre pares de contrapartes e ρ_D^{alvo} é o alvo escolhido pelo usuário. É o modelo de mistura mais parcimonioso e tende a produzir caudas pesadas quando ρ_D^{alvo} é alto em relação a $\bar{p}$.

CreditRisk⁺ (Poisson-gama, um fator). O fator sistemático é $S \sim \Gamma(v, 1/v)$, distribuição gama parametrizada de modo que $\mathbb{E}[S] = 1$ e $\text{Var}(S) = 1/v$ — ou seja, v controla a volatilidade do ciclo: quanto menor v , mais volátil o fator. A intensidade condicional de default de cada contraparte é

$$p_n(S) = p_n(1 - w + wS), \quad (8)$$

em que $w \in (0, 1)$ é a carga do fator, isto é, a fração da intensidade que responde ao ciclo (o complemento $1 - w$ é a parcela idiossincrática). Os defaults são gerados por uma contagem de Poisson $H_n \sim \text{Poisson}(p_n(S))$, com default declarado quando $H_n \geq 1$. Trata-se do arcabouço atuarial clássico de portfólio de crédito, que reaparece na Seção 3.4 como base analítica do ajuste de granularidade.

3.3 *Threshold models* — modelos de limiar (cap. 4)

Nos *threshold models*, o default ocorre quando uma variável latente — interpretada como o retorno dos ativos da contraparte — cai abaixo de um limiar. Na família gaussiana de um fator, espinha dorsal da prática de mercado e do próprio IRB, o estado latente da contraparte n é

$$Y_n = \sqrt{\rho} G + \sqrt{1 - \rho} \varepsilon_n, \quad G, \varepsilon_1, \dots, \varepsilon_N \stackrel{iid}{\sim} \mathcal{N}(0, 1), \quad (9)$$

em que G é o fator sistemático comum a toda a carteira, ε_n é o choque idiossincrático da contraparte n e $\rho \in (0, 1)$ é a correlação de *ativos*, que dosa o peso do fator comum. O default ocorre quando $Y_n < \Phi^{-1}(p_n)$, sendo Φ^{-1} a inversa da distribuição normal-padrão acumulada — o limiar é escolhido de modo que a probabilidade incondicional de default seja exatamente p_n . A correlação de *default* implícita entre duas contrapartes com PDs p e q é

$$\rho_D(p, q; \rho) = \frac{\Phi_2(\Phi^{-1}(p), \Phi^{-1}(q); \rho) - pq}{\sqrt{p(1-p)}\sqrt{q(1-q)}}, \quad (10)$$

em que $\Phi_2(\cdot, \cdot; \rho)$ é a distribuição normal bivariada acumulada com correlação ρ — o numerador é a probabilidade de default conjunto menos o produto das marginais. O CreditLens calibra ρ numericamente para que $\rho_D(\bar{p}, \bar{p}; \rho)$ iguale o alvo comum definido pelo usuário.

Variante t-Student. Substituindo o vetor gaussiano por

$$Y_n = \sqrt{\frac{\nu}{V}} \left(\sqrt{\rho} G + \sqrt{1 - \rho} \varepsilon_n \right), \quad V \sim \chi_\nu^2, \quad (11)$$

em que V é um choque radial qui-quadrado com ν graus de liberdade, comum a todas as contrapartes, e o limiar passa a ser $t_\nu^{-1}(p_n)$ (inversa da distribuição t de Student), o modelo adquire *dependência de cauda*: mesmo mantida a correlação ρ , defaults conjuntos extremos tornam-se ordens de magnitude mais prováveis, porque um sorteio pequeno de V amplifica simultaneamente todos os Y_n . Poucos graus de liberdade (ν baixo) engordam a cauda; no limite $\nu \rightarrow \infty$ recupera-se o caso gaussiano.

ASRF (carteira assintótica). No limite de uma carteira infinitamente granular e homogênea, o modelo gaussiano admite a solução fechada de Vasicek:

$$\text{VaR}_\alpha = \left(\sum_n c_n \right) \Phi \left(\frac{\Phi^{-1}(\bar{p}) + \sqrt{\rho} \Phi^{-1}(\alpha)}{\sqrt{1 - \rho}} \right), \quad (12)$$

em que $\sum_n c_n$ é a exposição líquida total, $\bar{p}$ a PD homogênea da carteira, ρ a correlação de ativos e α o nível de confiança. É o esqueleto analítico do IRB e, neste documento, funciona também como verificação de consistência do modelo de limiar simulado.

3.4 Capital regulatório IRB e ajuste de granularidade (cap. 6)

O requerimento de capital do IRB, avaliado contraparte a contraparte, é a perda inesperada condicional ao cenário sistemático de 99,90%, multiplicada pelo ajuste de maturidade:

$$K_n = \left[\Phi\left(\frac{\Phi^{-1}(p_n) + \sqrt{\rho_B(p_n)} \Phi^{-1}(0,999)}{\sqrt{1-\rho_B(p_n)}}\right) - p_n \right] \cdot \text{MA}(M_n, p_n), \quad \text{Capital} = \sum_n c_n K_n, \quad (13)$$

em que K_n é o coeficiente de capital da contraparte n (fração da severidade c_n exigida como capital), $\rho_B(p_n)$ é a correlação de ativos regulatória e $\text{MA}(M_n, p_n)$ o ajuste de maturidade, função do prazo efetivo M_n e da PD. A correlação regulatória é interpolada exponencialmente entre 12% e 24%,

$$\rho_B(p) = 0,12 q(p) + 0,24 (1 - q(p)), \quad q(p) = \frac{1 - e^{-50p}}{1 - e^{-50}}, \quad (14)$$

em que $q(p)$ é o peso de interpolação: PDs baixas recebem correlação próxima de 24% (grandes empresas, mais sensíveis ao ciclo) e PDs altas, próxima de 12%. O ajuste de maturidade é

$$\text{MA}(M, p) = \frac{1 + (M - 2,5) b(p)}{1 - 1,5 b(p)}, \quad b(p) = (0,11582 - 0,05478 \ln p)^2, \quad (15)$$

em que $b(p)$ é a inclinação de maturidade, conforme implementado na biblioteca do livro,¹ e prazos acima de 2,5 anos elevam o requerimento (risco de migração cresce com o horizonte). O RWA equivalente é $12,5 \times$ o capital.

Ajuste de granularidade. A fórmula (13) pressupõe uma carteira infinitamente granular; carteiras reais carregam risco idiossincrático residual de concentração. O CreditLens adiciona o ajuste de granularidade de Gordy–Lütkebohmert na forma analítica derivada do CreditRisk⁺ — a mesma do exemplo do capítulo 6 do livro —, cuja estrutura é

$$\text{GA} = \frac{1}{2K^*} \sum_{n=1}^N c_n^2 \left[\delta(C_n \mathcal{R}K_n + \mathcal{R}K_n^2 \gamma) - K_n(C_n + 2\mathcal{R}K_n \gamma) \right], \quad (16)$$

em que $K^* = \sum_n c_n K_n$ é o capital IRB total da carteira, $\mathcal{R}K_n$ agrupa os termos de capital e PD da contraparte n , e δ , γ e C_n são coeficientes que dependem dos parâmetros de volatilidade setorial e de LGD, fixados nos valores de referência do livro ($a = 0,25$, $\xi = 0,25$, $\bar{g} = 1$). O ponto essencial é que o GA cresce com o *quadrado* das participações c_n^2 — é, em essência, uma penalidade de HHI sobre o capital.

3.5 Contribuições de risco (cap. 7)

A alocação de Euler decompõe o risco total nas parcelas marginais de cada contraparte. Para o VaR e o ES, as contribuições admitem representação por esperança condicional:

$$\text{VaR}_\alpha^{(n)} = \mathbb{E}[c_n \mathbb{I}_{D_n} \mid L = \text{VaR}_\alpha], \quad \text{ES}_\alpha^{(n)} = \mathbb{E}[c_n \mathbb{I}_{D_n} \mid L \geq \text{VaR}_\alpha], \quad (17)$$

em que $\text{VaR}_\alpha^{(n)}$ e $\text{ES}_\alpha^{(n)}$ são as contribuições da contraparte n : a perda média que ela gera, respectivamente, nos cenários em que a perda total *igual* o VaR e nos cenários em que o *excede ou iguala*. Por construção, as contribuições somam exatamente o VaR e o ES da carteira. O CreditLens as estima por decomposição de Monte Carlo no modelo de limiar gaussiano: em cada

¹O texto de Basileia II usa o coeficiente 0,11852; a biblioteca de Bolder implementa 0,11582. O efeito numérico sobre o capital agregado é da ordem de décimos de ponto percentual. O CreditLens preserva a implementação original do livro.

uma de S repetições independentes com M trajetórias, calcula-se a perda média de cada nome nas trajetórias do evento condicionante, e a média das S repetições reduz o ruído inerente ao condicionamento em evento raro. As contribuições de ES são substancialmente mais estáveis que as de VaR — condicionam em um conjunto de cenários, não em um único ponto da distribuição — e são a referência recomendada para *pricing* e alocação de capital.

3.6 Estratégia de calibração comum

Para que as caudas sejam comparáveis, todos os modelos com dependência são ancorados no mesmo par $(\bar{p}, \rho_D^{\text{alvo}})$ — a PD média ponderada por exposição e a correlação de default alvo: a beta-binomial pelo método dos momentos, o limiar gaussiano/t por meio de (10), e o ASRF herdando o ρ calibrado. As diferenças remanescentes entre os modelos refletem, portanto, *forma distributiva* — em particular a presença ou não de dependência de cauda — e não níveis distintos de correlação. O CreditRisk⁺ é parametrizado diretamente por (w, v) , expostos ao usuário na interface. O IRB, por construção regulatória, usa $\rho_B(p) \in [12\%, 24\%]$ — tipicamente acima do ρ_D implícito em carteiras corporativas — e por isso não é ancorado no alvo comum.

4 Estudo de caso: carteira hipotética

4.1 A carteira

A base de teste contém $N = 250$ contrapartes corporativas distribuídas em oito graus de rating (AAA a C), com exposições log-normais (cauda pesada, como é típico do crédito corporativo), LGD atribuída por classe de garantia e prazos uniformes em $[1, 5]$ anos. A Tabela 1 resume o perfil.

Tabela 1: Perfil da carteira de teste.

Métrica	Valor
Contrapartes (N)	250
EAD total	10 000,0
Exposição líquida total ($\sum_n c_n$)	4 402,7
PD média simples	2,36%
PD média ponderada por exposição ($\bar{p}$)	2,16%
LGD média	46,0%
Perda esperada ($\mathbb{E}[L]$)	95,0 (2,16% da exposição líquida)
HHI	0,0112
Número efetivo de nomes	88,9
Maior exposição individual	3,39%
Dez maiores exposições	24,4%

Com HHI de 0,0112, a carteira equivale a apenas 89 nomes de igual tamanho — uma concentração relevante, que o ajuste de granularidade da Seção 4.4 quantificará em capital.

4.2 Parâmetros e calibração

A análise utilizou $M = 100\,000$ simulações, semente 42, alvo de correlação de default $\rho_D^{\text{alvo}} = 5\%$, $\nu = 10$ graus de liberdade na variante t e $(w, v) = (0,35; 1,2)$ no CreditRisk⁺. A calibração produziu, para a beta-binomial, $(a, b) = (0,410; 18,590)$ — note que $a < 1$ implica densidade explosiva na origem com cauda direita longa — e, para o modelo de limiar, correlação de ativos $\rho = 24,66\%$. Este último número merece registro: para gerar módicos 5% de correlação de *default* numa carteira com $\bar{p} = 2,16\%$, são necessários quase 25% de correlação de *ativos*. É

a não linearidade de (10) em ação — e a razão pela qual as duas noções de correlação jamais devem ser confundidas.

4.3 Medidas de risco por modelo

Tabela 2: Medidas de risco por modelo (unidades monetárias; $M = 100\,000$). Entre parênteses, o VaR 99,90% em percentual da exposição líquida.

Modelo	EL	UL	VaR _{99%}	ES _{99%}	VaR _{99,9%}	ES _{99,9%}
Binomial indep. (analítico, homog.)	95,0	40,5	192,0	192,4	233,9 (5,3%)	—
Binomial independente (MC)	94,9	60,5	279,3	320,3	371,2 (8,4%)	407,3
CreditRisk ⁺ (1 fator)	89,1	64,9	295,8	337,7	396,2 (9,0%)	427,5
Limiar Gaussiano 1F	95,2	120,6	563,6	727,9	927,1 (21,1%)	1 116,7
Beta-binomial	94,9	157,9	735,7	930,4	1 187,5 (27,0%)	1 332,1
ASRF (analítico)	95,0	—	701,0	944,9	1 265,6 (28,7%)	1 520,5
Limiar t-Student ($\nu = 10$)	95,2	147,5	707,6	1 000,0	1 372,8 (31,2%)	1 731,4
IRB Basileia ($K^* + \mathbb{E}[L]$)	95,0	—	—	—	805,2 (18,3%)	—

A Tabela 2 contém a mensagem central do exercício, que pode ser lida em três camadas. A primeira é a *verificação de consistência*: a perda esperada é de aproximadamente 95 em todos os modelos (o desvio do CreditRisk⁺, 89,1, decorre da aproximação de Poisson, que admite eventos múltiplos e não é recalibrada em nível). Ora, se modelos calibrados ao mesmo primeiro momento chegam a diferir por um fator de quase seis vezes no VaR 99,90% — de 234 a 1 373 —, fica demonstrado empiricamente que o risco de crédito de uma carteira reside, essencialmente, na estrutura de dependência entre os defaults, e não nas PDs individuais.

A segunda camada é a hierarquia das caudas, que segue exatamente a teoria: independente < CreditRisk⁺ (com os w, v adotados) < limiar gaussiano < beta-binomial $\approx$ ASRF < t-Student. A variante t, mantida a *mesma* correlação de ativos do modelo gaussiano, entrega VaR 99,9% 48% maior e ES 99,9% 55% maior — o preço da dependência de cauda, que a cópula gaussiana, por construção, não captura.

A terceira camada é o ASRF (1 265,6) acima do limiar gaussiano simulado (927,1), apesar de descrever uma carteira *mais* diversificada. A aparente contradição é instrutiva: o ASRF usa a aproximação homogênea com $\bar{p}$ ponderado por exposição e, numa carteira heterogênea — em que os nomes de pior rating não são os de maior exposição —, essa homogeneização é conservadora, efeito discutido pelo próprio Bolder no capítulo 4.

4.4 Capital regulatório IRB

Aplicando (13) contraparte a contraparte, o capital IRB da carteira é

$$K^* = \sum_n c_n K_n = 710,1 \quad (16,13\% \text{ da exposição líquida}), \quad \text{RWA} = 12,5 K^* = 8\,876,7.$$

O ajuste de granularidade adiciona GA = 91,8, elevando o requerimento a 801,9 — um acréscimo de 12,9% sobre o capital IRB puro, coerente com os 89 nomes efetivos da carteira. Somado à perda esperada para permitir comparação com os VaRs totais dos modelos internos, o IRB+EL de 805,2 (18,3%) situa-se entre o limiar gaussiano calibrado a $\rho_D = 5\%$ e os modelos de cauda pesada. A leitura é direta: a correlação regulatória $\rho_B \in [12\%, 24\%]$ é deliberadamente conservadora frente a calibrações internas típicas, mas a cópula gaussiana subjacente ao IRB não carrega dependência de cauda — e o t-Student o ultrapassa com folga.




Figura 1: Distribuição de perdas (esq.) e cauda em escala logarítmica (dir.) sob três modelos. A linha pontilhada marca o quantil de 99,90%. A separação das caudas — indistinguíveis no corpo da distribuição — ilustra por que a escolha do modelo de dependência domina qualquer refinamento de PD individual.




Figura 2: VaR 99,90% por modelo, em percentual da exposição líquida.

4.5 Contribuições de risco

A Tabela 3 e a Figura 3 revelam a anatomia da cauda. A contraparte CP0173 — rating CCC com a segunda maior exposição da carteira — responde sozinha por 11,8% do ES 99%: a combinação multiplicativa de PD alta com exposição alta que a alocação de capital deve penalizar no *pricing*. Observe, porém, CP0078 e CP0139: ratings BBB, PDs abaixo de 65 pontos-base e, ainda assim, entre os seis maiores contribuintes — puro efeito de tamanho (cerca de 300 de exposição cada). A lição operacional é clara: a gestão de limites por rating, isoladamente, não controla a cauda; a métrica correta de concentração é a contribuição de risco, não a PD. Os dez nomes da tabela somam cerca de 39% do ES total, contra 24% da exposição — a cauda é mais concentrada do que a própria carteira.

5 Limitações e extensões

A versão atual adota LGD determinística (a extensão estocástica via distribuição beta, `crPlusOneFactorLGD`, já existe na biblioteca), um único fator sistemático (as rotinas multifatoriais `crPlusMultifactor` e `getY2r` permitem estender a fatores setoriais ou regionais, e a coluna `setor` do padrão de da-

Tabela 3: Dez maiores contribuições ao ES 99% (decomposição MC, limiar gaussiano, $S = 10$).

Contraparte	Rating	Exposição	PD	Contrib. ES	% do ES
CP0173	CCC	292,3	8,99%	85,7	11,8%
CP0156	BB	217,1	2,34%	40,7	5,6%
CP0051	C	47,5	24,41%	26,4	3,6%
CP0092	B	118,1	6,33%	21,4	3,0%
CP0078	BBB	266,8	0,63%	21,2	2,9%
CP0139	BBB	301,9	0,58%	19,1	2,6%
CP0103	C	44,3	37,05%	19,1	2,6%
CP0228	B	87,3	5,38%	16,1	2,2%
CP0036	B	109,2	3,67%	15,9	2,2%
CP0245	C	101,4	15,55%	15,5	2,1%




Figura 3: Quinze maiores contribuições ao ES 99% (percentual do total).

dos já antecipa esse uso), horizonte de um ano sem migração de ratings (o módulo `markovChain` habilita a visão multiperíodo) e Monte Carlo simples (o capítulo 8 do livro, também disponível na biblioteca, fornece *importance sampling* com deslocamento ótimo de média, capaz de estimar quantis extremos com uma fração das simulações). O ajuste de granularidade usa os parâmetros de referência do livro; em aplicação prudencial, a volatilidade setorial deve ser estimada a partir dos dados.

Referências

- Bolder, D. J. (2018). *Credit-Risk Modelling: Theoretical Foundations, Diagnostic Tools, Practical Examples, and Numerical Recipes in Python*. Springer. [Referencial teórico e bibliotecas numéricas, github.com/djbolder/credit-risk-modelling, GPL-3.0.]
- Basel Committee on Banking Supervision (2005). *An Explanatory Note on the Basel II IRB Risk Weight Functions*. BIS.
- Gordy, M. B. (2003). A risk-factor model foundation for ratings-based bank capital rules. *Journal of Financial Intermediation*, 12(3), 199–232.

- Gordy, M. B.; Lütkebohmert, E. (2013). Granularity adjustment for regulatory capital assessment. *International Journal of Central Banking*, 9(3), 33–71.
- Vasicek, O. (2002). The distribution of loan portfolio value. *Risk*, 15(12), 160–162.