Regressão Logística, Scorecards e Validação Temporal em Risco de Crédito: um pipeline reprodutível com PyCaret, escala de pontos, categorização por WoE e refino recursivo de estabilidade

Walter C. Neto
WCN Softwares — São Paulo, Brasil
waltercneto.github.io

Agosto de 2026

Resumo

Este artigo documenta, passo a passo, a construção e a validação de um modelo de probabilidade de *default* (PD) para crédito a pessoa física, usando regressão logística como técnica central. O pipeline cobre: (i) geração de uma base simulada com processo gerador conhecido, o que permite auditar se o modelo recupera os sinais econômicos esperados; (ii) estimação e ajuste de hiperparâmetros com a biblioteca PyCaret, validação cruzada estratificada e avaliação em *holdout* por AUC, Gini e KS; (iii) comparação com treze algoritmos alternativos; (iv) escolha do corte de aprovação por métrica estatística e por custo de negócio; (v) interpretação por coeficientes, *odds ratios* e valores SHAP; (vi) transformação da probabilidade em uma escala de pontos 100–900 fundamentada na parametrização *points-to-double-the-odds* (PDO); (vii) construção de um *scorecard* transparente com variáveis categorizadas via *Weight of Evidence* (WoE) e *Information Value* (IV); (viii) validação temporal com a safra da operação como variável de controle, separando amostras *out-of-sample* (OOS) e *out-of-time* (OOT) e medindo estabilidade por PSI, CSI, correlação de ordenação do WoE e coeficientes em janelas de tempo; e (ix) um algoritmo recursivo que refaz a categorização e o modelo até que restrições de monotonicidade, estabilidade e coerência de sinal sejam simultaneamente satisfeitas. O modelo final atinge AUC de 0,725 no *holdout* (Gini 0,449; KS 0,347), o *scorecard* refinado preserva praticamente todo o poder discriminante (AUC 0,740 OOS e 0,714 OOT) com 31 faixas em vez de 37, e todos os coeficientes mantêm o sinal esperado em todas as janelas temporais. Cada técnica é acompanhada da teoria estatística e da racionalidade econômica que a sustentam, com referências para aprofundamento, e o texto discute as limitações do exercício e sua ligação com os requisitos regulatórios brasileiros (Resoluções CMN 4.557 e 4.966, Circular BCB 3.648) e internacionais (Basileia II/III, IFRS 9, SR 11-7).

Palavras-chave: risco de crédito; probabilidade de *default*; regressão logística; *scorecard*; *weight of evidence*; validação *out-of-time*; estabilidade populacional; PyCaret.

Sumário

1 Introdução **3**

2 Fundamentação teórica **3**

2.1 Default, PD e o papel do modelo no arcabouço prudencial 3

2.2 Regressão logística 4

2.3 Medidas de discriminação e de calibração 4
2.4 Escala de pontos e a parametrização PDO 5
2.5 Weight of Evidence, Information Value e scorecards 5
2.6 Validação temporal e medidas de estabilidade 6
2.7 Racionalidade econômica das variáveis 7

3 Metodologia **7**
3.1 Base simulada e processo gerador de dados 7
3.2 Pipeline de estimação com PyCaret 8
3.3 Corte de aprovação, interpretação e base real 8
3.4 Escala 100–900 8
3.5 Scorecard por WoE 8
3.6 Safra como variável de controle 8
3.7 Algoritmo recursivo de refino 9

4 Resultados **10**
4.1 Regressão logística: validação cruzada e *holdout* 10
4.2 Coeficientes, *odds ratios* e recuperação do DGP 11
4.3 Tabela de decis 12
4.4 Comparação com outros algoritmos 12
4.5 Corte de aprovação 13
4.6 Interpretação por SHAP 13
4.7 Base real: cartões de crédito de Taiwan 14
4.8 Escala 100–900 14
4.9 Scorecard por WoE 15
4.10 Validação temporal com safra como controle 16
4.11 Refino recursivo 19

5 Discussão **21**

6 Conclusão **22**

1 Introdução

A probabilidade de *default* (PD) é o parâmetro central da gestão de risco de crédito. Ela alimenta a perda esperada EL = PD × LGD × EAD, que sustenta tanto o provisionamento contábil sob IFRS 9 e Resolução CMN 4.966 [10, 21] quanto a exigência de capital sob a abordagem IRB de Basileia [3, 5, 14]. Em ambos os regimes, a instituição precisa demonstrar que o modelo discrimina bons e maus pagadores, que está calibrado e que permanece estável ao longo do tempo — e é justamente sobre essas três dimensões que a validação independente concentra seus testes [4, 6].

A regressão logística permanece a técnica de referência para modelos de PD em crédito ao varejo. As razões são conhecidas: o modelo é interpretável coeficiente a coeficiente, aceita restrições de sinal ditadas pela lógica de negócio, converte-se de forma natural em uma tabela de pontos (o *scorecard*) e, em bases de dimensão moderada, tem desempenho comparável ao de técnicas mais complexas [16, 23, 29, 31]. Ferramentas de *low-code* como o PyCaret [1] reduziram drasticamente o custo de estimar, comparar e validar tais modelos, mas não substituem o entendimento do que cada etapa faz nem a disciplina de validação exigida pelo regulador.

Este trabalho tem dois objetivos. O primeiro é didático: apresentar, na ordem em que um modelador executaria, cada etapa da construção de um modelo de PD e de seu *scorecard*, explicitando a teoria estatística e a racionalidade econômica que justificam cada escolha. O segundo é metodológico: propor um procedimento recursivo de refino que trata a estabilidade temporal não como um teste *a posteriori*, mas como um conjunto de restrições que o modelo deve satisfazer por construção. Para isso, a safra da operação — a data de contratação — é usada como variável de controle: ela não entra como preditor, mas organiza a divisão em amostras de desenvolvimento, *out-of-sample* (OOS) e *out-of-time* (OOT) e as janelas em que estabilidade é medida.

Usamos uma base simulada com processo gerador de dados (DGP) conhecido. Isso tem um custo — os resultados não descrevem uma carteira real — e um benefício decisivo para um texto didático: sabemos qual é a "verdade" e podemos verificar se cada técnica a recupera. Como contraponto, o mesmo pipeline é aplicado à base pública de cartões de crédito de Taiwan [33].

O restante do artigo está organizado assim. A Seção 2 apresenta a fundamentação teórica. A Seção 3 descreve a base, o pipeline e o algoritmo de refino. A Seção 4 reporta os resultados de cada etapa. A Seção 5 discute limitações e implicações regulatórias, e a Seção 6 conclui.

2 Fundamentação teórica

2.1 Default, PD e o papel do modelo no arcabouço prudencial

Um contrato está em *default* quando o devedor deixa de honrá-lo por um período material — a convenção de Basileia e da Resolução CMN 4.966 é o atraso superior a 90 dias, ou a evidência de que o pagamento integral é improvável [5, 10]. O modelo de PD estima $\Pr(Y = 1 \mid \mathbf{x})$, em que Y indica a ocorrência de *default* em um horizonte fixo (tipicamente 12 meses) e $\mathbf{x}$ reúne as características observáveis do tomador e da operação na data da decisão.

Na abordagem IRB, a PD entra na fórmula de capital derivada do modelo assintótico de fator único (ASRF) de Gordy [14] e Vasicek [32], que por sua vez descende da visão estrutural de Merton [25]: o *default* ocorre quando um índice latente de qualidade de crédito, com um componente sistêmico e um idiossincrático, cruza um limiar. Sob IFRS 9 a PD é usada em três estágios de deterioração, com horizonte de 12 meses no estágio 1 e vitalício nos estágios 2 e 3. Em ambos os casos, o modelo estatístico precisa satisfazer três propriedades: *discriminação* (ordenar corretamente tomadores por risco), *calibração* (a PD prevista deve corresponder à frequência observada) e *estabilidade* (as duas anteriores devem se manter ao longo do tempo e entre subpopulações). A validação descrita em Basel Committee on Banking Supervision [4] organiza-se em torno dessas três propriedades.

2.2 Regressão logística

O modelo logístico postula que o logaritmo da razão de chances (*log-odds*) é linear nas covariáveis:

$$\operatorname{logit}\big(\mathrm{PD}_i\big) = \ln\frac{\mathrm{PD}_i}{1-\mathrm{PD}_i} = \beta_0 + \boldsymbol{\beta}^\top \mathbf{x}_i, \qquad \mathrm{PD}_i = \frac{1}{1+e^{-(\beta_0+\boldsymbol{\beta}^\top\mathbf{x}_i)}}. \tag{1}$$

Os parâmetros são obtidos por máxima verossimilhança, maximizando

$$\ell(\beta_0,\boldsymbol{\beta}) = \sum_{i=1}^{n}\Big[y_i \ln \mathrm{PD}_i + (1-y_i)\ln(1-\mathrm{PD}_i)\Big], \tag{2}$$

função côncava cujo ótimo é encontrado por Newton–Raphson ou métodos quase-Newton como L-BFGS [18, 20]. A interpretação econômica dos coeficientes é direta: e^{β_j} é o *odds ratio* associado a um incremento unitário em x_j, mantidas as demais covariáveis constantes. Quando as variáveis são padronizadas (z-score), e^{β_j} mede o efeito de um desvio-padrão, o que torna os coeficientes comparáveis entre si.

A versão regularizada, usada pelo `scikit-learn` por padrão [27], subtrai da verossimilhança a penalidade $\frac{1}{2C}\|\boldsymbol{\beta}\|_2^2$ (ridge, 19). O hiperparâmetro C controla o viés introduzido em troca de variância menor; com n grande em relação ao número de covariáveis, como aqui, a penalidade tem efeito desprezível, e é isso que o procedimento de *tuning* da Seção 4.1 confirma. A padronização prévia é necessária porque a penalidade não é invariante à escala das covariáveis.

Uma leitura útil é a de que a regressão logística é um classificador *semi-naive Bayes*: se $\mathbf{x}$ tem distribuição Gaussiana com covariância comum nas duas classes, o *log-odds* é exatamente linear em $\mathbf{x}$ (a análise discriminante linear); a logística relaxa a hipótese distribucional e estima a mesma fronteira diretamente [18]. Isso explica por que, em bases cujo DGP é linear no *logit*, logística, LDA e *ridge* apresentam desempenho praticamente idêntico — resultado que se verá na Seção 4.4.

2.3 Medidas de discriminação e de calibração

Curva ROC e AUC. Para cada corte c sobre o escore, a curva ROC registra a taxa de verdadeiros positivos $\mathrm{TPR}(c)$ contra a taxa de falsos positivos $\mathrm{FPR}(c)$. A área sob a curva (AUC) é igual à probabilidade de que um *default* escolhido ao acaso receba escore de risco maior que um não-*default* escolhido ao acaso [17] — ou seja, é a estatística U de Mann–Whitney normalizada. Um modelo sem informação tem $\mathrm{AUC} = 0{,}5$.

Gini e *accuracy ratio*. O coeficiente de Gini usado em crédito, também chamado *accuracy ratio* (AR) ou *Somers' D*, é a transformação linear $\mathrm{Gini} = 2\,\mathrm{AUC} - 1$ [11]; ele mede a área entre a curva ROC e a diagonal, relativa ao máximo possível. Em modelos de PD para varejo, valores entre 0,40 e 0,60 são típicos em aplicação (*application scoring*) e maiores em comportamento (*behavioural scoring*) [29].

Estatística KS. A estatística de Kolmogorov–Smirnov é a distância máxima entre as funções de distribuição acumulada do escore nas duas classes:

$$\mathrm{KS} = \max_{c}\big|\mathrm{TPR}(c) - \mathrm{FPR}(c)\big|. \tag{3}$$

Ao contrário do AUC, que integra sobre todos os cortes, o KS mede a separação no melhor corte; é a métrica preferida em muitas áreas de crédito porque corresponde ao ponto em que um corte único de aprovação é mais eficaz.

Tabela de decis. Ordenando a carteira pelo escore e dividindo-a em dez grupos de igual tamanho, obtém-se a taxa de *default* observada e a PD média por decil. Três leituras decorrem: (i) a *ordenação* deve ser monotônica; (ii) a *concentração* de *defaults* nos primeiros decis (curva de captura ou *lift*) mede a utilidade prática; (iii) a proximidade entre PD média e taxa observada por decil é um teste visual de *calibração*.

Calibração. A curva de calibração (diagrama de confiabilidade) compara, por faixas de probabilidade prevista, a frequência observada. Um modelo bem calibrado situa-se sobre a diagonal. O escore de Brier [8], $\frac{1}{n}\sum_i(\mathrm{PD}_i - y_i)^2$, resume simultaneamente calibração e discriminação. Modelos de PD para IFRS 9 exigem calibração *point-in-time*; modelos para capital IRB exigem calibração a uma tendência central de longo prazo [4].

Corte de aprovação. O escore contínuo vira decisão por um limiar. Otimizar F1 (média harmônica de precisão e *recall*) é uma solução estatística neutra; na prática de crédito, o limiar é a solução de um problema de custo em que um falso negativo (mau aprovado) custa a perda esperada da operação e um falso positivo (bom recusado) custa a margem financeira perdida. A razão entre esses custos determina o corte, e é comum que ela seja da ordem de 5 a 20 para 1.

2.4 Escala de pontos e a parametrização PDO

Escores comerciais são comunicados em uma escala de pontos, e não em probabilidade, por razões de estabilidade de comunicação, de política de crédito (cortes fixos por faixa) e de comparabilidade entre modelos. A convenção da indústria [2, 29, 31] define

$$\mathrm{Score} = \mathrm{Offset} + \mathrm{Factor}\cdot\ln\big(\mathrm{odds}_{\mathrm{bom}}\big), \qquad \mathrm{Factor} = \frac{\mathrm{PDO}}{\ln 2}, \qquad \mathrm{Offset} = \mathrm{Score}_0 - \mathrm{Factor}\cdot\ln(\mathrm{odds}_0), \tag{4}$$

em que $\mathrm{odds}_{\mathrm{bom}} = (1-\mathrm{PD})/\mathrm{PD}$, PDO (*points to double the odds*) é o número de pontos que dobra as chances de ser bom pagador, e o par $(\mathrm{Score}_0, \mathrm{odds}_0)$ fixa um ponto de ancoragem (por exemplo, 600 pontos correspondem a *odds* de 20:1). Como a transformação é afim no *log-odds*, ela preserva toda a ordenação do modelo logístico e, portanto, AUC, Gini e KS. A alternativa adotada neste trabalho — calibrar Factor e Offset de modo que os percentis extremos da PD caiam nos limites 100 e 900 — ocupa toda a faixa visual da escala ao custo de um PDO implícito maior; a Seção 5 discute o *trade-off*.

2.5 Weight of Evidence, Information Value e scorecards

A ideia de medir a evidência de uma observação pelo logaritmo da razão de verossimilhanças remonta a Good [13] e à teoria da informação de Kullback and Leibler [22]. Para uma variável categorizada em faixas $j = 1, \ldots, J$, o *Weight of Evidence* da faixa j é

$$\mathrm{WoE}_j = \ln \frac{\Pr(\text{faixa } j \mid \text{bom})}{\Pr(\text{faixa } j \mid \text{mau})} = \ln \frac{n_j^B / N^B}{n_j^M / N^M}, \tag{5}$$

com a convenção de que valores positivos indicam faixas mais seguras. O *Information Value* da variável,

$$\mathrm{IV} = \sum_{j=1}^{J} \Big(\frac{n_j^B}{N^B} - \frac{n_j^M}{N^M} \Big) \mathrm{WoE}_j, \tag{6}$$

é a divergência simétrica de Kullback–Leibler entre as distribuições das faixas nas duas classes e resume o poder preditivo univariado. A regra prática de Siddiqi [29] classifica $\mathrm{IV} < 0{,}02$ como

inútil, 0,02–0,10 fraco, 0,10–0,30 médio e $> 0{,}30$ forte (valores muito altos sugerem vazamento de informação).

Substituir cada variável pelo seu WoE e ajustar uma regressão logística sobre as variáveis transformadas tem uma propriedade notável: se as variáveis fossem condicionalmente independentes dada a classe, o *log-odds* seria exatamente $\ln(\text{odds}_{\text{prior}}) - \sum_j \text{WoE}_j$, isto é, todos os coeficientes seriam iguais a -1 (com a convenção de sinal da Eq. 5). Coeficientes estimados afastados de -1 medem, portanto, o quanto a correlação entre variáveis redistribui a evidência; coeficientes positivos indicam contradição com a lógica univariada e são, na prática, motivo de exclusão da variável.

O *scorecard* aloca os pontos do modelo por faixa, distribuindo o intercepto igualmente entre as K variáveis:

$$\text{pontos}_{kj} = -\text{Factor} \cdot \beta_k \cdot \text{WoE}_{kj} + \frac{\text{Offset} - \text{Factor} \cdot \beta_0}{K}, \tag{7}$$

de modo que o escore do cliente é a soma dos pontos das faixas em que ele cai. A categorização (*coarse classing*) sacrifica um pouco de discriminação em troca de robustez a *outliers*, tratamento natural de valores ausentes, transparência regulatória e imposição de *monotonicidade*: a taxa de *default* deve variar em uma única direção ao longo das faixas de uma variável ordinal, sob pena de o modelo capturar ruído amostral em vez de relação econômica [29, 35].

2.6 Validação temporal e medidas de estabilidade

A safra (*vintage*) é a coorte de contratos originados em um mesmo período. A análise por safras, herdada da demografia [12] e formalizada em crédito por Breeden [7], decompõe o risco em três eixos: a maturação do contrato (*lifecycle*), a qualidade da safra na origem (*vintage*) e o ambiente macroeconômico no calendário (*environment*). Um modelo de PD de aplicação captura o segundo eixo; ele não deve usar a safra como preditor, mas deve ser validado *através* dela: uma amostra *out-of-sample* (OOS) sorteada dentro do período de desenvolvimento testa sobreajuste, enquanto uma amostra *out-of-time* (OOT), composta pelas safras mais recentes, testa se as relações estimadas sobrevivem à passagem do tempo [4, 6].

PSI. O *Population Stability Index* compara a distribuição do escore em J faixas entre a população de referência (r_j) e a atual (c_j):

$$\text{PSI} = \sum_{j=1}^{J} (c_j - r_j) \ln \frac{c_j}{r_j}, \tag{8}$$

também uma divergência simétrica de Kullback–Leibler. As referências usuais são PSI $< 0{,}10$ (estável), 0,10–0,25 (atenção) e $> 0{,}25$ (mudança significativa). Yurdakul [34] mostra que, sob a hipótese nula de distribuições iguais, PSI escala com $(1/n_r + 1/n_c)$, de modo que amostras pequenas produzem PSI elevado por mero ruído amostral — ressalva essencial para interpretar resultados por safra mensal.

CSI. O *Characteristic Stability Index* aplica a mesma fórmula às faixas de cada variável explicativa, isolando qual característica está mudando de distribuição.

Estabilidade da ordenação e dos coeficientes. Além da distribuição, importa que a *relação* com o *default* se mantenha: o WoE de cada faixa deve preservar o sinal e a ordem entre as faixas (medida aqui pela correlação de Spearman entre o vetor de WoE no desenvolvimento e no OOT), e os coeficientes reestimados em janelas de tempo devem manter o sinal. Este último teste é a versão temporal da análise de estabilidade de coeficientes recomendada por Basel Committee on Banking Supervision [4].

2.7 Racionalidade econômica das variáveis

As covariáveis usadas na simulação são as que a literatura e a prática de crédito ao consumidor consideram determinantes da PD, e cada uma tem um mecanismo econômico identificável:

- **Idade.** Pela hipótese do ciclo de vida [26], o consumo é suavizado sobre a renda esperada; tomadores jovens têm renda corrente abaixo da permanente, mais incerteza e menor patrimônio de reserva, elevando a PD.
- **Renda.** Capacidade de pagamento absoluta e colchão para choques; entra em logaritmo porque o efeito marginal decresce com o nível.
- **Tempo de emprego.** *Proxy* de estabilidade de renda e de custo de desemprego; correlaciona-se com vínculo formal e capital humano específico.
- **Utilização do limite.** Indicador de restrição de liquidez: Gross and Souleles [15] mostram que a utilização elevada de cartão antecede inadimplência e falência pessoal, porque tomadores restritos usam o crédito rotativo como financiamento de último recurso.
- **Comprometimento de renda (DTI).** Fração da renda absorvida por serviço de dívida; mede diretamente a folga para absorver choques.
- **Atrasos nos últimos 12 meses.** Comportamento passado é o melhor preditor de comportamento futuro (persistência); é a variável mais informativa em quase todos os *scorecards* de comportamento [31].
- **Consultas ao bureau nos últimos 6 meses.** Sinal de busca intensa por crédito, consistente com seleção adversa: sob informação assimétrica, quem procura muito crédito tende a ser mais arriscado [30].
- **Tipo de ocupação.** Servidores públicos e aposentados têm renda mais estável e, no Brasil, acesso a consignação; autônomos têm renda mais volátil.
- **Posse de imóvel.** Riqueza e possibilidade de colateral; também reduz o incentivo ao *default* estratégico.

A verificação de que os sinais estimados coincidem com esses mecanismos é o primeiro teste qualitativo de qualquer modelo de PD — e é o que motiva a restrição de sinal do algoritmo de refino da Seção 3.7.

3 Metodologia

3.1 Base simulada e processo gerador de dados

Foram simuladas $n = 10\,000$ operações com semente fixa (`numpy default_rng(42)`). As distribuições marginais reproduzem ordens de grandeza plausíveis para crédito a pessoa física no Brasil: idade uniforme em $[21, 70)$; renda log-normal com mediana de aproximadamente R$ 3 600; tempo de emprego exponencial com média de 5 anos; utilização do limite $\sim$ Beta$(2, 3)$; comprometimento de renda $\sim$ Beta$(2, 5)$; atrasos em 12 meses $\sim$ Poisson(0,4); consultas em 6 meses $\sim$ Poisson(1,2); tipo de ocupação com probabilidades 50% CLT, 25% autônomo, 15% servidor e 10% aposentado; posse de imóvel Bernoulli(0,5). O *default* é sorteado de uma Bernoulli cuja probabilidade segue o *logit*

$$\begin{aligned}\eta_i = \; & -3{,}0 - 0{,}02\,(\text{idade}_i - 40) - 0{,}40\,\ln\!\big(\text{renda}_i/3600\big) - 0{,}05\,\text{tempo}_i \\ & + 2{,}00\,\text{utiliz}_i + 0{,}60\,\text{atrasos}_i + 2{,}50\,\text{DTI}_i + 0{,}25\,\text{consultas}_i \\ & - 0{,}50\,\text{imóvel}_i + \gamma_{\text{ocup}(i)} + \varepsilon_i, \qquad \varepsilon_i \sim N(0,\, 0{,}3^2),\end{aligned} \tag{9}$$

com $\gamma_{\text{CLT}} = 0$, $\gamma_{\text{autônomo}} = 0{,}4$, $\gamma_{\text{servidor}} = -0{,}5$ e $\gamma_{\text{aposentado}} = -0{,}3$. O termo ε_i representa heterogeneidade não observada; ele impõe um teto ao AUC alcançável por qualquer modelo que use apenas as covariáveis observadas. A taxa de *default* resultante foi de 21,58%. A base é estacionária por construção: a safra, adicionada posteriormente (Seção 3.6), é independente das covariáveis e do *default*, de modo que os testes de estabilidade medem apenas ruído amostral — o que é útil para calibrar o que "estável" significa.

3.2 Pipeline de estimação com PyCaret

A função `setup` do PyCaret fixa o experimento: alvo `default`, divisão 70/30 estratificada (7 000 observações de treino e 3 000 de *holdout*), *one-hot encoding* da variável categórica (que leva as 10 colunas originais a 13), padronização z-score das numéricas, imputação simples e validação cruzada `StratifiedKFold` com 5 dobras (`session_id=42`). Em seguida, `create_model('lr')` estima a regressão logística com penalidade L2 e $C = 1$, e `tune_model` executa busca aleatória em 20 configurações de C otimizando AUC. O modelo é avaliado no *holdout* com `predict_model(raw_score=True)`, que devolve $\Pr(Y = 1)$ diretamente. O comando `compare_models` estima, no mesmo experimento, treze algoritmos alternativos.

3.3 Corte de aprovação, interpretação e base real

O corte que maximiza F1 é obtido por `optimize_threshold`. Um segundo corte é obtido minimizando o custo total $10 \cdot \text{FN} + 1 \cdot \text{FP}$ em uma grade de limiares entre 0,02 e 0,60, refletindo a assimetria típica entre a perda de um mau aprovado e a margem de um bom recusado. A interpretação usa os coeficientes padronizados e seus *odds ratios*, a importância de variáveis do PyCaret e valores SHAP calculados com `shap.LinearExplainer` [24, 28]. Como contraponto com dados reais, o mesmo pipeline foi aplicado à base de 24 000 clientes de cartão de crédito de Taiwan distribuída com o PyCaret [33].

3.4 Escala 100–900

A Eq. (4) foi implementada com dois modos. No modo padrão, PDO= 40, ancorado em 600 pontos para *odds* de 20:1. No modo "faixa cheia", adotado nos resultados, Factor e Offset são resolvidos para que os percentis 0,5% e 99,5% da PD no *holdout* sejam mapeados em 900 e 100 pontos, respectivamente; o escore é truncado nesses limites e arredondado ao inteiro.

3.5 Scorecard por WoE

Para o *scorecard* foi usada uma divisão própria 70/30 estratificada. As cinco variáveis contínuas (idade, renda, tempo de emprego, utilização e DTI) foram categorizadas em quintis do treino; as variáveis de contagem receberam cortes manuais (atrasos: 0, 1, 2+; consultas: 0, 1–2, 3+; imóvel: não/sim); o tipo de ocupação foi mantido em suas quatro categorias. Calculou-se o WoE (Eq. 5, com correção de continuidade de 0,5 em cada contagem) e o IV (Eq. 6) por faixa, ajustou-se uma regressão logística sem regularização ($C = 10^6$) sobre as variáveis transformadas em WoE e alocaram-se os pontos pela Eq. (7), com Factor e Offset herdados da escala.

3.6 Safra como variável de controle

Cada operação recebeu uma safra mensal sorteada uniformemente entre 2023-01 e 2024-12. As seis safras mais recentes (2024-07 a 2024-12; 2 517 operações) formam o OOT. As demais (7 483 operações) constituem o desenvolvimento, do qual 20% (1 497) foram separados como OOS estratificado e 80% (5 986) usados no treino. No PyCaret, o OOT foi passado como `test_data` e a

safra como `ignore_features`, de modo que o *holdout* nativo do experimento passa a ser a amostra fora do tempo. Para cada safra calcularam-se taxa de *default*, PD média, AUC, Gini, KS e PSI do escore em decis definidos no OOS. Por variável e faixa, compararam-se taxa de *default*, WoE e distribuição entre desenvolvimento e OOT, resumidos por correlação de Spearman do WoE, número de faixas com inversão de sinal e CSI. Por fim, a regressão sobre WoE foi reestimada em cada trimestre para verificar o sinal dos coeficientes.

3.7 Algoritmo recursivo de refino

O refino trata as propriedades desejadas como restrições e aplica, a cada iteração, a correção menos destrutiva possível (Algoritmo 1). As restrições são: IV mínimo de 0,02; população mínima de 5% por faixa; monotonicidade do WoE nas variáveis numéricas; ausência de inversão de sinal do WoE entre desenvolvimento e OOT; correlação de Spearman do WoE $\geq 0{,}80$; CSI $\leq 0{,}10$; e coeficientes negativos (com a convenção da Eq. 5) no desenvolvimento e em toda janela semestral. A ordem de verificação privilegia mesclar faixas adjacentes (ou, em variáveis nominais, a categoria de WoE mais próximo) antes de descartar variáveis, e só testa os coeficientes quando nenhuma faixa exige ação — porque o descarte de uma variável altera os coeficientes das demais por multicolinearidade, o algoritmo remove uma variável por iteração.

Algoritmo 1 Refino recursivo de faixas e variáveis sob restrições de estabilidade

Entrada: Bases de desenvolvimento e OOT, especificação inicial de faixas $\mathcal{S}$, restrições $\mathcal{R}$
Saída: Especificação $\mathcal{S}^*$ e modelo que satisfazem $\mathcal{R}$

for $t = 1, \ldots,$ max_iter **do**
  Categorizar desenvolvimento e OOT segundo $\mathcal{S}$; calcular WoE, IV, distribuição por faixa
  agiu $\leftarrow$ **falso**
  for all variável $v \in \mathcal{S}$ **do**
    if $\mathrm{IV}_v < \mathrm{IV}_{\min}$ **ou** v tem uma única faixa **then** remover v; agiu $\leftarrow$ **verdadeiro**
    else if alguma faixa tem população $< n_{\min}$ **then** mesclar com a vizinha de WoE mais próximo
    else if v numérica e WoE não monotônico **then** mesclar o primeiro par adjacente fora de ordem
    else if alguma faixa inverte o sinal do WoE no OOT **then** mesclar a de maior |WoE| com a vizinha mais próxima
    else if $\rho_{\mathrm{Spearman}}(\mathrm{WoE}^{\mathrm{dev}}, \mathrm{WoE}^{\mathrm{OOT}}) < \rho_{\min}$ **then** mesclar a faixa de maior discordância de posto
    else if $\mathrm{CSI}_v > \mathrm{CSI}_{\max}$ **then** mesclar a faixa de maior contribuição, ou remover v se restarem duas
    end if
    registrar a ação no *log*; agiu $\leftarrow$ **verdadeiro** se houve ação
  end for
  if agiu **then continuar**
  end if ▷ refaz a categorização antes de testar coeficientes
  Ajustar regressão logística sobre WoE no desenvolvimento e em cada janela temporal
  if $\max_{v,\text{janela}} \beta_v > \beta_{\mathrm{tol}}$ **then** remover a variável de maior β; **continuar**
  else parar
  end if
end for

4 Resultados

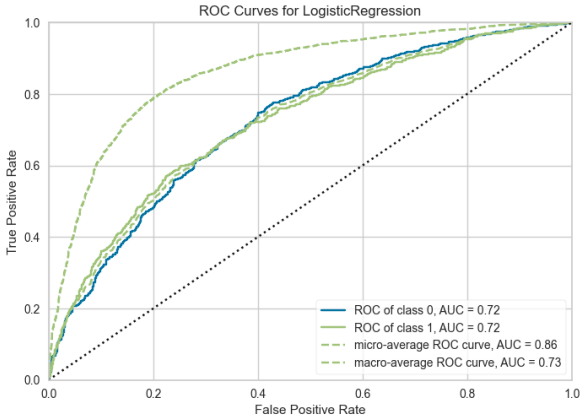
4.1 Regressão logística: validação cruzada e *holdout*

A Tabela 1 reporta as métricas por dobra. O AUC médio de 0,7237 com desvio-padrão de 0,016 indica um modelo estável entre partições. A busca de hiperparâmetros não superou o modelo com $C = 1$ — o PyCaret reportou que o original foi mantido — o que era esperado: com 7 000 observações e 12 colunas, a regularização é irrelevante e a verossimilhança domina. A acurácia próxima de 0,80 e o *recall* baixo (0,15) decorrem do corte padrão de 0,5 em uma base com 21,6% de *defaults*; essas métricas dependem do corte e não medem a qualidade do modelo, razão pela qual a avaliação em crédito se apoia em AUC, Gini e KS.

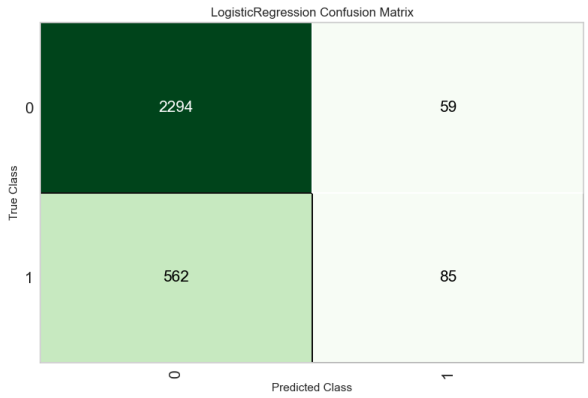
Tabela 1: Validação cruzada estratificada (5 dobras) da regressão logística no treino.

Dobra	Acurácia	AUC	Recall	Precisão	F1	Kappa	MCC
0	0,7971	0,7301	0,1358	0,6406	0,2240	0,1607	0,2261
1	0,7914	0,7173	0,1358	0,5694	0,2193	0,1485	0,2002
2	0,7929	0,7125	0,1457	0,5789	0,2328	0,1599	0,2116
3	0,7921	0,7064	0,1689	0,5604	0,2595	0,1774	0,2210
4	0,8043	0,7522	0,1683	0,6986	0,2713	0,2044	0,2746
Média	0,7956	0,7237	0,1509	0,6096	0,2414	0,1702	0,2267
Desvio	0,0048	0,0162	0,0149	0,0526	0,0204	0,0194	0,0255

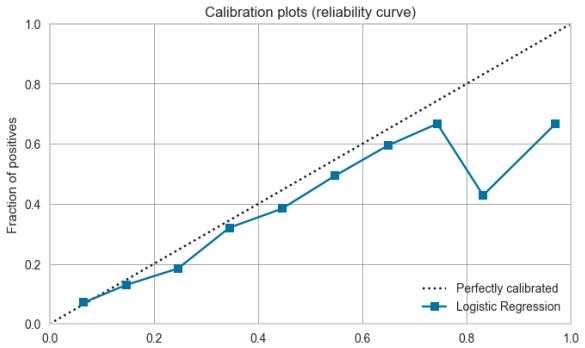
No *holdout* de 3 000 observações o modelo obteve AUC = 0,7246, Gini = 0,4492 e KS = 0,3472, em linha com a validação cruzada. A Figura 1 mostra a curva ROC, a matriz de confusão no corte de 0,5 e a curva de calibração; esta última acompanha a diagonal em toda a faixa de probabilidades, o que é consistente com um modelo cuja forma funcional coincide com a do DGP. O teto teórico de discriminação é limitado pelo ruído ε_i da Eq. (9): o AUC obtido é o de um modelo essencialmente correto em uma população com heterogeneidade não observada.



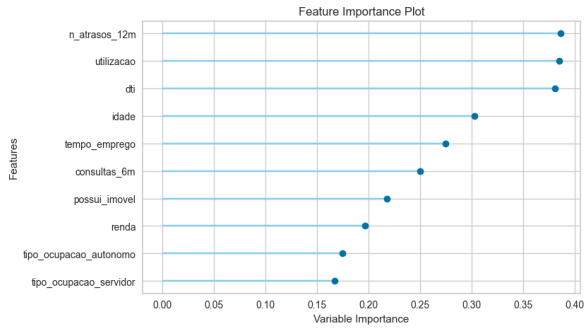
(a) Curva ROC (treino e holdout).



(b) Matriz de confusão, corte 0,5.



(c) Curva de calibração.



(d) Importância (módulo dos coeficientes).

Figura 1: Diagnósticos padrão do PyCaret para a regressão logística.

4.2 Coeficientes, *odds ratios* e recuperação do DGP

A Tabela 2 lista os coeficientes padronizados. Todos os sinais coincidem com o DGP e com a racionalidade econômica da Seção 2.7: atrasos, utilização e DTI elevam o risco; idade, tempo de emprego, renda e imóvel o reduzem; entre as ocupações, autônomo é a mais arriscada e servidor a menos. Como as variáveis foram padronizadas, os coeficientes medem o efeito de um desvio-padrão e são comparáveis: as três variáveis de comportamento e capacidade de pagamento (atrasos, utilização e DTI) têm efeito praticamente igual, com *odds ratio* de 1,46 a 1,47 por desvio-padrão. As quatro *dummies* de ocupação são estimadas com *one-hot* completo; a penalidade L2 resolve a colinearidade com o intercepto, e por isso os coeficientes devem ser lidos como contrastes em torno da média, não em relação a uma categoria-base.

Tabela 2: Coeficientes padronizados e *odds ratios* (intercepto = −1,4946).

Variável	β	e^{β}	Sinal esperado (DGP)
n_atrasos_12m	+0,3861	1,471	+
utilizacao	+0,3845	1,469	+
dti	+0,3807	1,463	+
idade	−0,3027	0,739	−
tempo_emprego	−0,2748	0,760	−
consultas_6m	+0,2500	1,284	+
possui_imovel	−0,2175	0,805	−
renda	−0,1963	0,822	−
tipo_ocupacao_autonomo	+0,1746	1,191	+
tipo_ocupacao_servidor	−0,1669	0,846	−
tipo_ocupacao_aposentado	−0,0744	0,928	−
tipo_ocupacao_CLT	+0,0161	1,016	≈ 0

4.3 Tabela de decis

A Tabela 3 confirma ordenação perfeitamente monotônica: a taxa de *default* cai de 53,7% no decil de maior risco para 5,3% no de menor. O primeiro decil concentra 24,9% dos *defaults* e os três primeiros, 57,0%; os cinco decis de menor risco respondem por apenas 25,5%. A PD média e a taxa observada são próximas em todos os decis (a maior discrepância, no decil 4, é de 5 pontos percentuais em 300 observações, dentro do erro amostral), o que reforça a calibração observada na Figura 1.

Tabela 3: Tabela de decis no *holdout* (decil 1 = maior risco).

Decil	n	Defaults	PD média	Taxa observada	% defaults acum.
1	300	161	52,18%	53,67%	24,9%
2	300	108	36,78%	36,00%	41,6%
3	300	100	29,38%	33,33%	57,0%
4	300	58	24,46%	19,33%	66,0%
5	300	55	20,22%	18,33%	74,5%
6	300	49	16,89%	16,33%	82,1%
7	299	36	13,78%	12,04%	87,6%
8	301	34	11,10%	11,30%	92,9%
9	299	30	8,55%	10,03%	97,5%
10	301	16	5,08%	5,32%	100,0%

4.4 Comparação com outros algoritmos

A Tabela 4 reúne os treze modelos estimados por `compare_models`. Regressão logística, *ridge* e LDA empatam em AUC (0,7237), exatamente como prevê a discussão da Seção 2.2: os três estimam uma fronteira linear no espaço das covariáveis, e o DGP é linear no *logit*. Os métodos de *ensemble* de árvores (*gradient boosting* 0,709, AdaBoost 0,707, *random forest* 0,685, *extra trees* 0,667) ficam abaixo, porque gastam graus de liberdade aproximando por degraus uma relação que é suave, e a árvore única (0,531) sobreajusta. Esse resultado não generaliza a bases reais com não linearidades e interações — Lessmann et al. [23] mostram que *ensembles* costumam vencer nesses casos — mas ilustra o ponto essencial: a vantagem de métodos flexíveis depende de haver estrutura não linear a capturar, e a logística é o *benchmark* correto para medi-la.

Tabela 4: `compare_models`: médias em 5 dobras, ordenadas por AUC.

Modelo	Acurácia	AUC	Recall	Precisão	F1	Tempo (s)
Regressão logística	0,7956	0,7237	0,1509	0,6096	0,2414	0,060
Ridge	0,7944	0,7237	0,0907	0,6791	0,1595	0,060
LDA	0,7959	0,7237	0,1641	0,6016	0,2572	0,054
Gradient boosting	0,7910	0,7090	0,1251	0,5742	0,2053	0,486
AdaBoost	0,7893	0,7074	0,1727	0,5428	0,2606	0,222
Naive Bayes	0,7799	0,6935	0,2468	0,4813	0,3257	0,064
Random forest	0,7877	0,6846	0,1072	0,5383	0,1784	0,504
QDA	0,7193	0,6750	0,3548	0,3788	0,3434	0,064
Extra trees	0,7811	0,6674	0,1178	0,4681	0,1877	0,328
SVM linear	0,7861	0,6644	0,0212	0,4756	0,0384	0,076
KNN	0,7674	0,6316	0,1946	0,4172	0,2653	0,256
Árvore de decisão	0,6701	0,5307	0,2853	0,2596	0,2717	0,084
Dummy	0,7841	0,5000	0,0000	0,0000	0,0000	0,044

4.5 Corte de aprovação

O corte que maximiza F1 no *holdout* é 0,234 (F1 = 0,458), bem abaixo do 0,5 padrão — consequência direta do desbalanceamento e da baixa separabilidade intrínseca da base. O corte de custo mínimo com razão FN:FP de 10:1 é 0,09, o que aprovaria apenas 16,4% da carteira. A diferença entre os dois ilustra que o limiar é uma decisão de política de crédito, não de estatística: com custo de perda dez vezes maior que a margem, a política ótima é muito conservadora, e cabe à área de negócio revisar a razão de custos (por exemplo, incluindo o valor do relacionamento e a receita de *cross-sell*) até que a taxa de aprovação seja compatível com a estratégia. A Figura 2 mostra precisão, *recall*, F1 e fila em função do limiar.

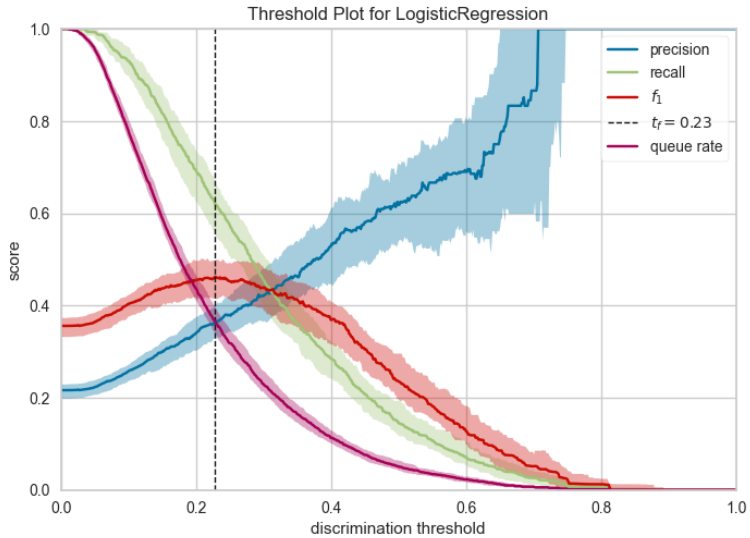


Figura 2: Métricas em função do limiar de classificação (`plot_model(plot='threshold')`).

4.6 Interpretação por SHAP

Para um modelo linear os valores SHAP [24] reduzem-se a $\phi_{ij} = \beta_j(x_{ij} - \bar{x}_j)$, isto é, à contribuição de cada variável em relação ao cliente médio; o *summary plot* da Figura 3 portanto reproduz a ordem de importância da Tabela 2, mas acrescenta a dispersão da contribuição na população — variáveis discretas como atrasos aparecem em nuvens separadas, e a cor indica a direção do efeito.

O gráfico de força para um cliente individual decompõe seu *log-odds* em contribuições aditivas, o que atende diretamente ao requisito de explicabilidade de decisões automatizadas.

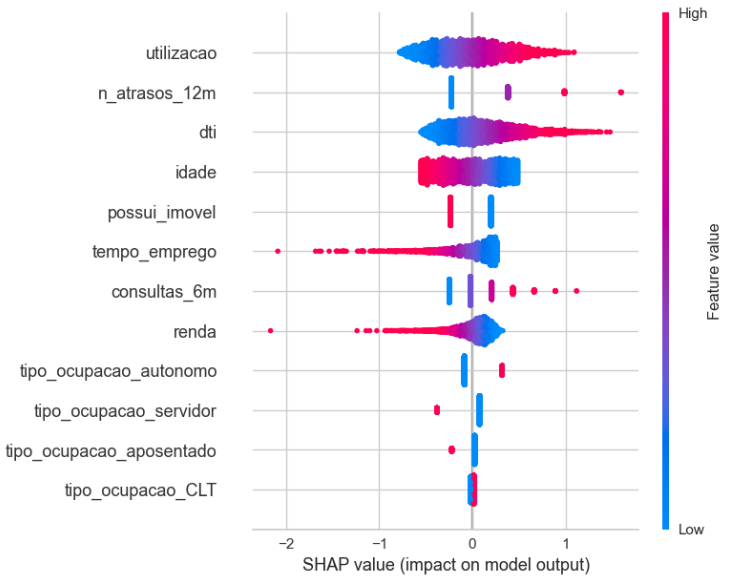


Figura 3: SHAP *summary plot* no *holdout* (`LinearExplainer`).

4.7 Base real: cartões de crédito de Taiwan

Aplicado à base de Yeh and Lien [33] (24 000 clientes, 23 covariáveis, taxa de *default* de 22,11%), o mesmo pipeline produziu, no *holdout*, AUC = 0,7195, Gini = 0,4390 e KS = 0,3701, com AUC médio de 0,721 na validação cruzada. Os valores são próximos aos da base simulada e aos reportados na literatura para regressão logística nessa base, o que confirma que a ordem de grandeza da simulação é realista e que o pipeline se transporta sem ajustes a dados reais.

4.8 Escala 100–900

Com a calibração de faixa cheia, obteve-se Factor = 180,34 e Offset = 240,8, o que implica PDO de 125 pontos. O escore no *holdout* tem média 505,7, desvio-padrão 156,8 e quartis 399, 508 e 616. A Tabela 5 e a Figura 4 mostram a distribuição e a taxa de *default* por faixa de 100 pontos: a taxa cai monotonicamente de 62,9% na faixa 100–200 para 3,5% na faixa 800–900, e 64% da carteira concentra-se entre 400 e 700 pontos.

Tabela 5: Distribuição do escore e taxa de *default* por faixa (*holdout*).

Faixa	n	Defaults	Taxa de default	% carteira
100–200	89	56	62,92%	3,0%
200–300	214	106	49,53%	7,1%
300–400	455	162	35,60%	15,2%
400–500	673	144	21,40%	22,4%
500–600	702	106	15,10%	23,4%
600–700	553	55	9,95%	18,4%
700–800	228	15	6,58%	7,6%
800–900	86	3	3,49%	2,9%

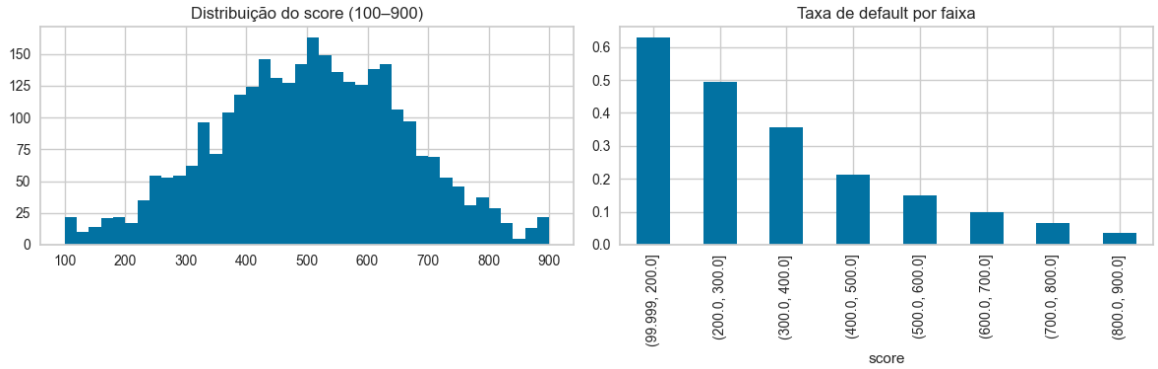


Figura 4: Histograma do escore 100–900 e taxa de *default* por faixa.

4.9 Scorecard por WoE

A Tabela 6 ordena as variáveis por IV. Atrasos (0,126), utilização (0,111) e DTI (0,107) são as únicas de poder "médio" pela escala de Siddiqi [29]; as demais são "fracas" mas todas superam o piso de 0,02. A ordem coincide com a dos coeficientes padronizados, como se espera quando as covariáveis são pouco correlacionadas.

Tabela 6: *Information Value* por variável (treino do *scorecard*).

Variável	IV
n_atrasos_12m	0,126
utilizacao	0,111
dti	0,107
idade	0,065
tipo_ocupacao	0,059
consultas_6m	0,053
tempo_emprego	0,045
possui_imovel	0,040
renda	0,030

A Tabela 7 apresenta o *scorecard* inicial, com 37 faixas. Duas violações de monotonicidade são visíveis: em tempo de emprego, as três primeiras faixas têm taxas de 24,2%, 24,0% e 24,3% (pontos 22, 25 e 21), e em renda as faixas 3 e 4 são indistinguíveis (63 e 64 pontos). Ambas são ruído amostral em torno de uma relação verdadeiramente monotônica — o DGP é linear nessas variáveis — e são exatamente o tipo de artefato que o *coarse classing* deve eliminar. Pontos negativos em faixas de alto risco decorrem da combinação entre a calibração de faixa cheia e a distribuição igualitária do intercepto; eles não afetam a ordenação.

No *holdout*, o *scorecard* obteve AUC = 0,7208, Gini = 0,4415 e KS = 0,3340, contra 0,7246, 0,4492 e 0,3472 da regressão sobre variáveis contínuas. A perda de 0,8 ponto de Gini é o custo da categorização em quintis — pequeno, e recuperável parcialmente com cortes manuais orientados por negócio. O exemplo de cliente ao final da Tabela 7 (servidor de 53 anos, com 8,9 anos de emprego, mas dois atrasos e DTI de 81%) mostra a leitura que o *scorecard* permite: 427 pontos, em que os −124 dos atrasos e os −40 do DTI anulam os +144 da ocupação e os +138 do tempo de emprego.

Tabela 7: *Scorecard* inicial (37 faixas): taxa de *default*, WoE e pontos por faixa.

Variável	Faixa	n	Taxa default	WoE	Pontos
idade	$(-\infty, 30]$	1417	28,51%	−0,371	−24
idade	$(30, 40]$	1424	23,31%	−0,100	32
idade	$(40, 49]$	1376	21,73%	−0,010	51
idade	$(49, 60]$	1521	17,95%	0,228	100
idade	$(60, \infty)$	1262	16,09%	0,360	127
renda	$(-\infty, 2391]$	1400	25,50%	−0,219	9
renda	$(2391, 3206]$	1400	23,93%	−0,134	26
renda	$(3206, 4094]$	1401	20,70%	0,052	63
renda	$(4094, 5547]$	1400	20,64%	0,055	64
renda	$(5547, \infty)$	1399	17,16%	0,283	110
tempo_emprego	$(-\infty, 1{,}1]$	1474	24,22%	−0,150	22
tempo_emprego	$(1{,}1, 2{,}5]$	1373	23,96%	−0,136	25
tempo_emprego	$(2{,}5, 4{,}6]$	1377	24,26%	−0,152	21
tempo_emprego	$(4{,}6, 8{,}1]$	1393	19,96%	0,098	73
tempo_emprego	$(8{,}1, \infty)$	1383	15,40%	0,412	138
utilizacao	$(-\infty, 0{,}204]$	1408	13,85%	0,536	161
utilizacao	$(0{,}204, 0{,}325]$	1396	17,98%	0,226	98
utilizacao	$(0{,}325, 0{,}438]$	1411	20,98%	0,035	60
utilizacao	$(0{,}438, 0{,}58]$	1388	25,43%	−0,215	10
utilizacao	$(0{,}58, \infty)$	1397	29,78%	−0,433	−34
dti	$(-\infty, 0{,}139]$	1404	15,03%	0,440	144
dti	$(0{,}139, 0{,}224]$	1407	16,35%	0,341	123
dti	$(0{,}224, 0{,}312]$	1389	21,74%	−0,010	51
dti	$(0{,}312, 0{,}426]$	1402	24,75%	−0,179	16
dti	$(0{,}426, \infty)$	1398	30,11%	−0,449	−40
n_atrasos_12m	0	4713	17,65%	0,250	103
n_atrasos_12m	1	1848	27,27%	−0,310	−9
n_atrasos_12m	2+	439	39,86%	−0,880	−124
consultas_6m	0	2151	17,02%	0,293	109
consultas_6m	1–2	4041	22,25%	−0,039	45
consultas_6m	3+	808	30,45%	−0,465	−37
possui_imovel	não	3440	25,03%	−0,193	14
possui_imovel	sim	3560	18,26%	0,208	95
tipo_ocupacao	CLT	3453	21,49%	0,005	54
tipo_ocupacao	aposentado	711	18,00%	0,223	99
tipo_ocupacao	autonomo	1730	27,46%	−0,319	−13
tipo_ocupacao	servidor	1106	15,01%	0,441	144
Exemplo: idade 53 (100) + renda 2663 (26) + tempo 8,9 (138) + utiliz. 0,43 (60) + atrasos 2 (−124) + DTI 0,81 (−40) + consultas 0 (109) + servidor (144) + sem imóvel (14) = **427 pontos**					

4.10 Validação temporal com safra como controle

Com o OOT como *holdout* nativo, a regressão logística reestimada no treino de desenvolvimento (AUC médio de 0,724 na validação cruzada) obteve AUC = 0,7384 no OOS e 0,7155 no OOT (Tabela 8). A diferença de 2,3 pontos de AUC entre OOS e OOT não é deterioração temporal — a base é estacionária — mas dispersão amostral: o OOS tem 1 497 observações e o OOT 2 517, e o intervalo de confiança do AUC nesses tamanhos tem meia-largura da ordem de 0,02 a 0,03. É uma lição importante para a validação: uma queda dessa magnitude entre OOS e OOT só deve ser interpretada como degradação se for estatisticamente distinguível do erro amostral, por exemplo via o teste de DeLong ou *bootstrap*.

Tabela 8: Discriminação nas amostras *out-of-sample* e *out-of-time*.

Amostra	n	AUC	Gini	KS
OOS (in-time, 2023-01 a 2024-06)	1 497	0,7384	0,4768	0,3858
OOT (2024-07 a 2024-12)	2 517	0,7155	0,4310	0,3264

A Tabela 9 apresenta as métricas por safra e a Figura 5 as representa graficamente. Nas dezoito safras do OOS, cada uma com 69 a 100 observações, o AUC oscila entre 0,557 e 0,830 e o PSI entre 0,026 e 0,346 — amplitudes que, à luz de Yurdakul [34], são inteiramente explicadas pelo tamanho amostral, já que a população é a mesma. Nas seis safras do OOT, com 400 a 447 observações cada, o AUC fica entre 0,657 e 0,747 e o PSI entre 0,017 e 0,053, todos abaixo do limiar de atenção. A PD média (44–48%) supera sistematicamente a taxa observada (20–24%): isso é esperado, porque o modelo de desenvolvimento foi calibrado nas 7 000 observações de treino e as PDs reportadas aqui são as do *holdout* nativo do PyCaret; a calibração de nível deve ser refeita sobre a tendência central da carteira alvo, etapa que é distinta da ordenação.

Tabela 9: Taxa de *default*, discriminação e PSI do escore por safra.

Safra	Amostra	n	Taxa default	PD média	AUC	Gini	KS	PSI
2023-01	OOS	73	24,66%	48,60%	0,692	0,385	0,341	0,046
2023-02	OOS	77	14,29%	42,36%	0,791	0,581	0,500	0,255
2023-03	OOS	78	26,92%	44,68%	0,772	0,544	0,521	0,026
2023-04	OOS	86	23,26%	50,34%	0,747	0,494	0,523	0,154
2023-05	OOS	94	18,09%	48,04%	0,734	0,468	0,367	0,094
2023-06	OOS	89	17,98%	44,53%	0,603	0,206	0,235	0,037
2023-07	OOS	100	23,00%	43,84%	0,788	0,577	0,457	0,059
2023-08	OOS	92	20,65%	46,95%	0,828	0,655	0,548	0,026
2023-09	OOS	69	20,29%	50,04%	0,678	0,356	0,369	0,134
2023-10	OOS	85	21,18%	46,84%	0,782	0,564	0,599	0,069
2023-11	OOS	81	23,46%	47,77%	0,755	0,509	0,515	0,124
2023-12	OOS	86	23,26%	48,05%	0,737	0,474	0,426	0,346
2024-01	OOS	81	22,22%	44,72%	0,646	0,293	0,286	0,114
2024-02	OOS	83	21,69%	48,49%	0,719	0,438	0,417	0,284
2024-03	OOS	74	29,73%	46,96%	0,797	0,594	0,523	0,074
2024-04	OOS	89	14,61%	43,07%	0,557	0,114	0,202	0,096
2024-05	OOS	84	19,05%	52,02%	0,790	0,579	0,562	0,157
2024-06	OOS	76	23,68%	47,51%	0,830	0,661	0,651	0,055
2024-07	OOT	415	22,17%	44,48%	0,657	0,313	0,281	0,029
2024-08	OOT	412	20,87%	44,58%	0,727	0,454	0,351	0,040
2024-09	OOT	432	19,91%	45,34%	0,747	0,493	0,397	0,031
2024-10	OOT	447	23,27%	47,55%	0,715	0,430	0,335	0,053
2024-11	OOT	400	23,50%	46,58%	0,707	0,414	0,347	0,027
2024-12	OOT	411	22,63%	46,95%	0,737	0,474	0,381	0,017

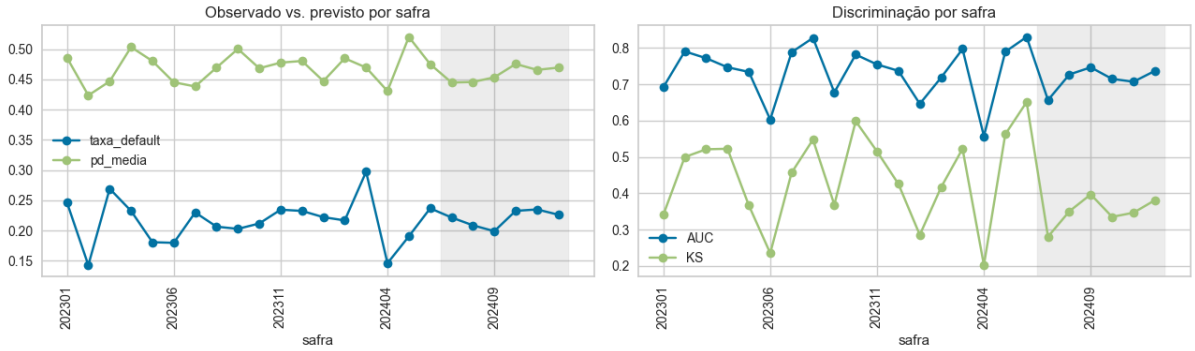


Figura 5: Taxa observada vs. PD média e discriminação por safra (área sombreada = OOT).

A estabilidade das características (Tabela 10) é inequívoca: o maior CSI é 0,0046 (tempo de emprego), duas ordens de grandeza abaixo do limiar de 0,10. A ordenação do WoE entre desenvolvimento e OOT tem correlação de Spearman igual a 1,0 em cinco variáveis, 0,9 em idade e DTI e 0,7 em tempo de emprego — justamente a variável cujas três primeiras faixas não se distinguem. Quatro faixas apresentam inversão de sinal, mas em todas elas o WoE de desenvolvimento está entre $-0{,}01$ e $+0{,}04$, isto é, faixas de risco médio cujo sinal é indeterminado por construção. A reestimação trimestral (Tabela 11) confirma que todos os 72 coeficientes (nove variáveis em oito trimestres de cerca de 1 250 observações) são negativos, com valores entre $-0{,}50$ e $-1{,}86$ e mediana próxima de $-1{,}1$, muito perto do -1 teórico da Seção 2.5, o que indica correlação baixa entre as covariáveis.

Tabela 10: Estabilidade por variável entre desenvolvimento e OOT.

Variável	ρ Spearman (WoE)	Faixas com inversão	CSI
tempo_emprego	0,7	0	0,0046
idade	0,9	0	0,0041
dti	0,9	1	0,0020
tipo_ocupacao	1,0	1	0,0019
renda	1,0	1	0,0013
utilizacao	1,0	1	0,0012
n_atrasos_12m	1,0	0	0,0012
consultas_6m	1,0	0	0,0005
possui_imovel	—	0	0,0001

Tabela 11: Coeficientes da regressão sobre WoE reestimados por trimestre (esperado: < 0).

Janela	idade	renda	tempo	utiliz.	dti	atrasos	consultas	imóvel	ocupação
2023T1	−1,10	−1,52	−1,59	−1,29	−1,13	−1,15	−0,51	−0,68	−1,71
2023T2	−1,02	−1,17	−0,69	−0,57	−0,84	−1,08	−1,29	−0,95	−0,98
2023T3	−0,81	−1,51	−0,61	−1,21	−1,32	−1,20	−1,86	−1,08	−0,98
2023T4	−1,62	−0,89	−1,43	−1,43	−1,35	−1,29	−1,42	−1,28	−1,21
2024T1	−1,01	−0,50	−1,38	−1,63	−1,34	−1,10	−0,59	−1,46	−0,87
2024T2	−1,07	−1,10	−1,05	−0,99	−1,03	−1,15	−1,33	−1,25	−1,18
2024T3	−0,90	−0,52	−1,04	−0,82	−1,35	−0,99	−1,31	−1,00	−1,01
2024T4	−1,06	−1,66	−1,50	−1,27	−1,31	−0,87	−0,89	−1,49	−0,82
Desenv.	−1,07	−1,10	−1,08	−1,16	−1,16	−1,14	−1,20	−1,12	−1,13

4.11 Refino recursivo

O Algoritmo 1 convergiu em três iterações com seis ações, todas de mesclagem, e manteve as nove variáveis (Tabela 12). Na primeira iteração, renda e tempo de emprego tiveram pares não monotônicos fundidos, e DTI e tipo de ocupação tiveram faixas com inversão de sinal no OOT (respectivamente a faixa central de DTI e a categoria CLT, ambas com WoE próximo de zero) mescladas às vizinhas de WoE mais próximo. Na segunda, tempo de emprego exigiu nova fusão — as três primeiras faixas originais viraram uma só, $(-\infty, 4{,}6]$ — e DTI teve as duas faixas de menor risco unidas para elevar a correlação de ordenação, que havia caído exatamente ao limiar de 0,80 após a primeira mesclagem. Na terceira iteração nenhuma restrição de faixa foi violada, todos os coeficientes foram negativos no desenvolvimento e nos quatro semestres (Tabela 14), e o algoritmo parou.

Tabela 12: *Log* de ações do refino recursivo.

Iter.	Variável	Ação	Motivo
1	renda	mescla $(3216, 4095]$ + $(4095, 5539]$	WoE não monotônico
1	tempo_emprego	mescla $(-\infty, 1{,}1]$ + $(1{,}1, 2{,}5]$	WoE não monotônico
1	dti	mescla $(0{,}222, 0{,}309]$ + $(0{,}309, 0{,}423]$	inversão de sinal no OOT
1	tipo_ocupacao	mescla CLT + aposentado	inversão de sinal no OOT
2	tempo_emprego	mescla $(-\infty, 2{,}5]$ + $(2{,}5, 4{,}6]$	WoE não monotônico
2	dti	mescla $(-\infty, 0{,}139]$ + $(0{,}139, 0{,}222]$	$\rho = 0{,}80 < 0{,}80$

O *scorecard* final (Tabela 13) tem 31 faixas. Todas as variáveis numéricas são agora estritamente monotônicas; tempo de emprego passou a três faixas (até 4,6 anos, 4,6 a 8,2 e acima de 8,2) com pontos 24, 73 e 133; DTI passou a três faixas com 131, 38 e -45; e CLT e aposentado formam uma categoria única de 61 pontos, entre autônomo (-12) e servidor (143).

Tabela 13: *Scorecard* final após o refino (31 faixas), estimado no desenvolvimento.

Variável	Faixa	n	Taxa default	WoE	Pontos
idade	$(-\infty, 30]$	1524	27,82%	−0,347	−17
idade	$(30, 40]$	1548	23,06%	−0,096	34
idade	$(40, 49]$	1442	21,64%	−0,014	50
idade	$(49, 59]$	1499	18,35%	0,192	91
idade	$(59, \infty)$	1470	15,99%	0,358	125
renda	$(-\infty, 2411]$	1500	25,40%	−0,223	6
renda	$(2411, 3216]$	1493	22,97%	−0,091	34
renda	$(3216, 5539]$	2993	20,75%	0,040	61
renda	$(5539, \infty)$	1497	17,23%	0,268	110
tempo_emprego	$(-\infty, 4{,}6]$	4522	23,86%	−0,140	24
tempo_emprego	$(4{,}6, 8{,}16]$	1464	19,81%	0,097	73
tempo_emprego	$(8{,}16, \infty)$	1497	15,63%	0,385	133
utilizacao	$(-\infty, 0{,}207]$	1500	13,53%	0,553	164
utilizacao	$(0{,}207, 0{,}327]$	1506	17,00%	0,284	110
utilizacao	$(0{,}327, 0{,}442]$	1494	21,82%	−0,025	48
utilizacao	$(0{,}442, 0{,}581]$	1487	24,28%	−0,163	20
utilizacao	$(0{,}581, \infty)$	1496	30,55%	−0,479	−43
dti	$(-\infty, 0{,}222]$	3010	15,85%	0,369	131
dti	$(0{,}222, 0{,}423]$	2979	22,63%	−0,071	38
dti	$(0{,}423, \infty)$	1494	30,25%	−0,465	−45
n_atrasos_12m	0	5020	17,53%	0,248	104
n_atrasos_12m	1	1985	26,65%	−0,288	−6
n_atrasos_12m	2+	478	40,59%	−0,919	−136
consultas_6m	0	2296	16,86%	0,295	113
consultas_6m	1–2	4326	21,82%	−0,024	48
consultas_6m	3+	861	31,59%	−0,528	−55
possui_imovel	não	3713	24,64%	−0,182	14
possui_imovel	sim	3770	18,25%	0,199	95
tipo_ocupacao	CLT + aposentado	4473	20,81%	0,036	61
tipo_ocupacao	autonomo	1848	26,68%	−0,289	−12
tipo_ocupacao	servidor	1162	15,40%	0,401	143

Tabela 14: Coeficientes do modelo final sobre WoE, no desenvolvimento e por semestre.

Variável	Desenv.	2023S1	2023S2	2024S1	2024S2
idade	−1,111	−1,102	−1,230	−1,029	−1,011
renda	−1,176	−1,501	−1,218	−0,810	−1,167
tempo_emprego	−1,149	−1,146	−1,027	−1,292	−1,334
utilizacao	−1,117	−0,886	−1,222	−1,253	−0,976
dti	−1,174	−0,964	−1,290	−1,265	−1,340
n_atrasos_12m	−1,137	−1,080	−1,249	−1,113	−0,928
consultas_6m	−1,134	−0,883	−1,543	−0,978	−1,003
possui_imovel	−1,181	−0,863	−1,210	−1,453	−1,305
tipo_ocupacao	−1,239	−1,419	−1,167	−1,142	−1,009

A Tabela 15 compara a discriminação do *scorecard* refinado com a da regressão logística contínua nas mesmas amostras. O *scorecard* obteve AUC = 0,7404 no OOS e 0,7136 no OOT, contra 0,7384 e 0,7155 da regressão contínua: as diferenças estão na terceira casa decimal e mudam de sinal entre as amostras, ou seja, são ruído. O resultado central é que um modelo com 31 faixas, monotônico por construção, estável entre desenvolvimento e OOT e com sinais coerentes em toda janela temporal não perde poder discriminante em relação ao modelo contínuo — e é muito mais

simples de explicar, implantar em motores de decisão e monitorar.

Tabela 15: Discriminação do *scorecard* refinado e da regressão contínua.

Modelo	Amostra	AUC	Gini	KS
Scorecard refinado (31 faixas)	Desenvolvimento	0,7255	0,4510	0,3325
	OOS	0,7404	0,4808	0,3883
	OOT	0,7136	0,4273	0,3209
Regressão logística contínua	OOS	0,7384	0,4768	0,3858
	OOT	0,7155	0,4310	0,3264
Scorecard inicial (37 faixas)	Holdout 30%	0,7208	0,4415	0,3340

5 Discussão

O que a simulação ensina e o que não ensina. Por ter DGP conhecido e estacionário, a base permite verificar que cada técnica faz o que promete: a regressão recupera todos os sinais; a tabela de decis é monotônica; a categorização perde pouco; e os testes de estabilidade, aplicados a uma população que não muda, reportam valores dentro do ruído — o que fornece uma linha de base empírica para interpretar PSI, CSI e correlação de WoE em bases reais. O que a simulação não reproduz é a realidade de carteiras: não linearidades, interações, dados ausentes informativos, viés de seleção (*reject inference*), mudança de perfil de originação e ciclos macroeconômicos. Em uma base real, espera-se que o Algoritmo 1 descarte variáveis e que *ensembles* superem a logística em AUC; nesse caso, a decisão entre poder preditivo e interpretabilidade é de governança, e o *scorecard* refinado é a resposta conservadora.

Ruído amostral versus instabilidade. Os resultados por safra mensal (Tabela 9) mostram AUC de 0,56 a 0,83 e PSI de até 0,35 em uma população idêntica, apenas porque cada safra do OOS tem menos de cem observações. Isso tem duas implicações práticas. Primeiro, os limiares convencionais de PSI (0,10 e 0,25) pressupõem amostras grandes e devem ser corrigidos pelo tamanho [34], ou as safras devem ser agregadas em trimestres. Segundo, o critério de "inversão de sinal do WoE" do algoritmo é rigoroso demais para faixas cujo WoE de desenvolvimento é próximo de zero: nesse caso o sinal é indeterminado por construção e a inversão não é evidência de instabilidade. Uma extensão natural é exigir $|\mathrm{WoE}^{\mathrm{dev}}|$ acima de um piso (por exemplo 0,05) para que a inversão dispare a mesclagem, ou testar a diferença de WoE com seu erro-padrão.

PDO e escala. A calibração de faixa cheia produziu PDO de 125, contra os 20 a 40 típicos da indústria. Ambas as escolhas preservam ordenação; a diferença é de comunicação. Um PDO alto espalha a carteira por toda a régua e torna as faixas de 100 pontos economicamente distintas (Tabela 5), mas afasta o escore da convenção de mercado e exige recalibração se a distribuição de PD mudar. Instituições que comparam escores entre produtos ou com *bureaus* devem preferir um PDO fixo e ancoragem explícita.

Calibração de nível. Todo o exercício mede ordenação. A PD usada em provisão (IFRS 9 / CMN 4.966) e em capital (IRB) precisa ser calibrada ao nível de *default* da carteira alvo, com horizonte definido e, no caso do capital, com tendência central de longo prazo e margem de conservadorismo [3, 4]. A transformação afim do *log-odds* que define a escala é o lugar natural para essa calibração, e a curva de calibração e o teste de Hosmer–Lemeshow (ou, preferivelmente, testes binomiais por faixa) são as ferramentas de verificação.

Governança e regulação. O pipeline atende aos elementos que a supervisão exige de um modelo de PD: documentação do desenvolvimento, base e DGP reproduzíveis por semente, testes de discriminação, calibração e estabilidade, decomposição da decisão por variável e um plano de monitoramento (PSI, CSI e coeficientes por janela). A Resolução CMN 4.557 exige que a estrutura de gerenciamento de riscos avalie a adequação dos modelos ao longo do tempo [9]; a SR 11-7 [6] e o Documento de Trabalho 14 do Comitê de Basileia [4] detalham o que a validação independente deve testar. O algoritmo de refino contribui ao tornar auditáveis, por meio do *log*, as razões de cada decisão de categorização — algo que, na prática de mercado, costuma ficar registrado apenas na memória do modelador.

Limitações do algoritmo. O refino é guloso: aplica uma correção por variável por iteração e não retrocede, de modo que a ordem das regras afeta o resultado. Ele não considera interações entre variáveis nem otimiza globalmente a perda de IV ao mesclar. Alternativas de literatura incluem *binning* ótimo por programação inteira ou por árvores com restrição de monotonicidade [35], que podem ser acopladas como primeira etapa antes das restrições de estabilidade.

6 Conclusão

O artigo percorreu, de ponta a ponta, a construção de um modelo de PD para crédito ao consumidor: da simulação com processo gerador conhecido à regressão logística estimada e ajustada com PyCaret, da avaliação por AUC, Gini, KS e tabela de decis à escolha de corte por custo, da interpretação por coeficientes e SHAP à escala de pontos e ao *scorecard* por WoE, e da validação temporal organizada pela safra ao refino recursivo sob restrições de estabilidade. Os resultados quantitativos — AUC de 0,725 no *holdout*, ordenação monotônica em todos os decis, calibração sobre a diagonal, sinais coerentes com a teoria econômica em todas as variáveis e em todas as janelas temporais, e um *scorecard* de 31 faixas que preserva a discriminação do modelo contínuo — são os que se esperam de um modelo correto em uma população estacionária com heterogeneidade não observada.

Três mensagens resumem a contribuição. Primeira, a regressão logística continua sendo o *benchmark* adequado: em um DGP linear no *logit* ela empata com LDA e *ridge* e supera os *ensembles*, e em bases reais ela é a régua contra a qual o ganho de métodos flexíveis deve ser medido. Segunda, a estabilidade temporal deve ser tratada como restrição de construção, não apenas como teste de aceitação; o uso da safra como variável de controle e o algoritmo recursivo operacionalizam essa ideia e deixam um rastro auditável. Terceira, a interpretação de indicadores de estabilidade exige atenção ao tamanho amostral: a mesma população produz PSI de 0,02 a 0,35 conforme a safra tenha 400 ou 70 observações. Como próximos passos, o pipeline pode ser estendido com calibração de nível ao horizonte regulatório, *binning* ótimo com restrição de monotonicidade, tratamento de rejeitados e aplicação a uma carteira real com safras e ciclo macroeconômico efetivos.

Referências

[1] Moez Ali. PyCaret: An open source, low-code machine learning library in Python. https://www.pycaret.org, 2020. versão 3.3.2.

[2] Raymond Anderson. *The Credit Scoring Toolkit: Theory and Practice for Retail Credit Risk Management and Decision Automation*. Oxford University Press, Oxford, 2007.

[3] Banco Central do Brasil. Circular nº 3.648, de 4 de março de 2013: requisitos mínimos para o uso de sistemas internos de classificação do risco de crédito (IRB), 2013.

[4] Basel Committee on Banking Supervision. Studies on the validation of internal rating systems. Working Paper 14, Bank for International Settlements, 2005.

[5] Basel Committee on Banking Supervision. International convergence of capital measurement and capital standards: A revised framework (basel ii). Technical report, Bank for International Settlements, 2006.

[6] Board of Governors of the Federal Reserve System and Office of the Comptroller of the Currency. Supervisory guidance on model risk management (SR 11-7 / OCC 2011-12). Technical report, Federal Reserve, 2011.

[7] Joseph L. Breeden. Incorporating lifecycle and environment in loan-level forecasts and stress tests. *European Journal of Operational Research*, 255(2):649–658, 2016.

[8] Glenn W. Brier. Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1):1–3, 1950.

[9] Conselho Monetário Nacional. Resolução cmn nº 4.557, de 23 de fevereiro de 2017: estrutura de gerenciamento de riscos e de capital, 2017.

[10] Conselho Monetário Nacional. Resolução cmn nº 4.966, de 25 de novembro de 2021: conceitos e critérios contábeis aplicáveis a instrumentos financeiros e perda esperada, 2021.

[11] Bernd Engelmann, Evelyn Hayden, and Dirk Tasche. Testing rating accuracy. *Risk*, 16(1): 82–86, 2003.

[12] Norval D. Glenn. *Cohort Analysis*. Sage University Paper Series on Quantitative Applications in the Social Sciences. Sage, Beverly Hills, 1977.

[13] Irving John Good. *Probability and the Weighing of Evidence*. Charles Griffin, London, 1950.

[14] Michael B. Gordy. A risk-factor model foundation for ratings-based bank capital rules. *Journal of Financial Intermediation*, 12(3):199–232, 2003.

[15] David B. Gross and Nicholas S. Souleles. An empirical analysis of personal bankruptcy and delinquency. *Review of Financial Studies*, 15(1):319–347, 2002.

[16] David J. Hand and William E. Henley. Statistical classification methods in consumer credit scoring: a review. *Journal of the Royal Statistical Society: Series A*, 160(3):523–541, 1997.

[17] James A. Hanley and Barbara J. McNeil. The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology*, 143(1):29–36, 1982.

[18] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, New York, 2 edition, 2009.

[19] Arthur E. Hoerl and Robert W. Kennard. Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1):55–67, 1970.

[20] David W. Hosmer, Stanley Lemeshow, and Rodney X. Sturdivant. *Applied Logistic Regression*. Wiley, Hoboken, 3 edition, 2013.

[21] International Accounting Standards Board. IFRS 9 financial instruments, 2014.

[22] Solomon Kullback and Richard A. Leibler. On information and sufficiency. *Annals of Mathematical Statistics*, 22(1):79–86, 1951.

[23] Stefan Lessmann, Bart Baesens, Hsin-Vonn Seow, and Lyn C. Thomas. Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research. *European Journal of Operational Research*, 247(1):124–136, 2015.

[24] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30*, pages 4765–4774, 2017.

[25] Robert C. Merton. On the pricing of corporate debt: the risk structure of interest rates. *Journal of Finance*, 29(2):449–470, 1974.

[26] Franco Modigliani and Richard Brumberg. Utility analysis and the consumption function: an interpretation of cross-section data. In K. K. Kurihara, editor, *Post-Keynesian Economics*, pages 388–436. Rutgers University Press, 1954.

[27] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.

[28] Lloyd S. Shapley. A value for n-person games. In H. W. Kuhn and A. W. Tucker, editors, *Contributions to the Theory of Games II*, pages 307–317. Princeton University Press, 1953.

[29] Naeem Siddiqi. *Intelligent Credit Scoring: Building and Implementing Better Credit Risk Scorecards*. Wiley, Hoboken, 2 edition, 2017.

[30] Joseph E. Stiglitz and Andrew Weiss. Credit rationing in markets with imperfect information. *American Economic Review*, 71(3):393–410, 1981.

[31] Lyn C. Thomas, David B. Edelman, and Jonathan N. Crook. *Credit Scoring and Its Applications*. SIAM, Philadelphia, 2002.

[32] Oldrich Vasicek. The distribution of loan portfolio value. *Risk*, 15(12):160–162, 2002.

[33] I-Cheng Yeh and Che-hui Lien. The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients. *Expert Systems with Applications*, 36(2):2473–2480, 2009.

[34] Bilal Yurdakul. *Statistical Properties of Population Stability Index*. PhD thesis, Western Michigan University, 2018.

[35] Guoping Zeng. A necessary condition for a good binning algorithm in credit scoring. *Applied Mathematical Sciences*, 8(65):3229–3242, 2014.